

Universidad Central

Facultad de Ingeniería y Ciencias Básicas

Maestría en Analítica de Datos



Procesamiento de lenguaje natural aplicado al análisis de opinión política para las elecciones
presidenciales en Colombia 2022

Tesis de Maestría

María Alejandra Castillo Pabón

David Alejandro Ballesteros Díaz

Trabajo de grado como requisito para optar el título de:

Magister

Bogotá, Colombia

2022

Universidad Central
Facultad de Ingeniería y Ciencias Básicas
Maestría en Analítica de Datos



Procesamiento de lenguaje natural aplicado al análisis de opinión política para las elecciones
presidenciales en Colombia 2022
Tesis de Maestría

María Alejandra Castillo Pabón
David Alejandro Ballesteros Díaz

Director
Carlos Isaac Zainea Maya

Bogotá, Colombia

2022

Aprobación

Director de Tesis



Carlos Isaac Zainea Maya

Jurados de la Tesis

Jurado

Jorge Mario Calvo Londoño

Jurado

Nelson Alirio Cruz Gutiérrez

Resumen

En Colombia, Twitter se ha utilizado por parte de usuarios y candidatos para realizar campañas para las elecciones de alcaldes, senadores, congresistas, presidentes, entre otros; esta práctica genera gran cantidad de datos e información que puede ser procesada y analizada para lograr identificar el perfil político de los candidatos y entender las reacciones que pueden llegar a producir en el entorno de la red social.

El siguiente trabajo tuvo como objetivo principal diseñar una herramienta para identificar el perfil de opinión de los siguientes precandidatos a la presidencia de Colombia para el año 2022: Gustavo Petro, Sergio Fajardo, Rodolfo Hernández, María Fernanda Cabal y Óscar Iván Zuluaga, a partir de un análisis de aceptación y rechazo por parte de los usuarios de Twitter y usando técnicas de procesamiento de lenguaje natural.

Para lo anterior, se realizaron extracciones de datos generados en la red social Twitter, mediante la creación de un bot que utiliza las librerías de Python selenium y la API tweepy, además se hizo uso de librerías como NLTK, spaCy, y Wordcloud para aplicar técnicas de tokenizado y lematizado, logrando identificar, entre otras cosas, las palabras más usadas por los precandidatos en sus discursos, la cantidad de palabras distintas que normalmente utilizan, y el total de palabras comunes. Adicionalmente, a través de un análisis de sentimientos utilizando el modelo RoBERTuito (basado en el modelo BETO), se logró identificar que tan positivo, neutro o negativo fue cada tweet; para finalizar, se diseñó un panel de visualización interactivo donde se muestran de forma gráfica los resultados obtenidos para cada uno de los análisis realizados.

Palabras clave: Procesamiento de lenguaje natural, análisis de sentimientos, tokenizado, lematizado, wordcloud, modelo RoBERTuito, scraping.

Abstract

In Colombia, users and candidates have used Twitter to campaign for the elections of mayors, senators, congressmen, presidents, among others; this practice generates a large amount of data and information that can be processed and analyzed in order to identify the candidates' political profile and understand the reactions they can produce in the environment.

The main objective of the following work was to design a tool to identify the opinion profile of the following pre-candidates for the presidency of Colombia in the year 2022: Gustavo Petro, Sergio Fajardo, Rodolfo Hernández, María Fernanda Cabal, and Óscar Iván Zuluaga, based on an analysis of acceptance and rejection by Twitter users and using natural language processing techniques.

For the above, extractions of data generated in the Twitter social network were performed, by means of the creation of a bot that uses the Python selenium libraries and the Tweepy API, libraries such as NLTK, spaCy, and Wordcloud were also employed to apply tokenization and lemmatization techniques, identifying, among other things, the words most used by the pre-candidates in their speeches, the number of different words they normally use, and the total number of common words. Additionally, through a sentiment analysis using the RoBERTuito model (based on the BETO model), it was possible to identify how positive, neutral or negative each tweet was; finally, an interactive visualization panel was designed to graphically show the results obtained for each of the analyses performed.

Keywords: Natural Language Processing, sentiment analysis, tokenizer, lemmatizer, wordcloud, RoBERTuito model, scraping.

Tabla de Contenido

Introducción	12
Planteamiento del Problema y Justificación.....	15
Objetivos	16
Objetivo general	16
Objetivos específicos	16
Antecedentes	17
Metodología	21
Fase 1: Extracción de datos	23
Fase 2: Entendimiento del problema	24
Fase 3: Entendimiento y preparación de los datos	26
Fase 4: Modelado.....	30
Fase 5: Evaluación.....	33
Fase 6: Despliegue	34
Resultados	36
Módulo 1: Información General	37
Módulo 2: Relación de usuarios que siguen.....	38
Módulo 3: Palabras más utilizadas.....	41
Módulo 4: Top de palabras lematizadas	42

Módulo 5: Correlación entre palabras comunes	43
Módulo 6: Sentimientos de los tweets.....	44
Discusión de los Resultados.....	47
Lista de Referencias.....	52
Anexos	54

Lista de Figuras

Figura 1. Proceso para el Análisis de Contenido de Redes Sociales. Elaboración propia.....	17
Figura 2. Fases de Implementación Metodología CRISP-DM	21
Figura 3. Flujo General del Procesos para la Generación de Resultados.	22
Figura 4. Flujo extracción de información de tweets.....	23
Figura 5. Datos e Información Obtenida.	27
Figura 6. Cantidad de Tweets por Candidato.	29
Figura 7. Resultados Relacionados en el Panel de Visualización.....	34
Figura 8. Módulos Panel de Visualización.	36
Figura 9. Cantidad de Seguidores y Usuarios Seguidos.	37
Figura 10. Usuarios Comunes que Siguen.....	38
Figura 11. Usuarios Importantes Comunes que Siguen.....	39
Figura 12. Ejemplo Palabras más Utilizadas por Candidato.	41
Figura 13. Ejemplo Top Palabras Lematizadas más Utilizadas por Candidato.....	42
Figura 14. Correlación Entre las Palabras Comunes de los Candidatos	43
Figura 15. Número de Palabras Comunes Entre los Candidatos	44
Figura 16. Ejemplo Análisis Sentimientos	45
Figura 17. Repositorio Documentación	54

Lista de Tablas

Tabla 1. Resultados Obtenidos Modelos Trabajo de Grado: Análisis de sentimiento en Twitter: El bueno, el malo y el >:(.....	19
Tabla 2. Resultados de Evaluación para Tareas de Clasificación en Español. Adaptado de (Pérez, Furman, Alonso, & Luque, 2021)	20
Tabla 3. Candidatos Presidenciales Objeto de Estudio.....	22
Tabla 4. Diccionario de Datos.....	28
Tabla 5. Cluster Modelo K-medias.	32
Tabla 6. Matriz de Confusión de los Clasificadores de Sentimientos	33
Tabla 7. Resultados de la Evaluación de las Tareas de Clasificación de Sentimientos	34

Glosario de Términos y Siglas

Término/Sigla	Descripción
CRISP-DM	Cross Industry Standard Process for Data Mining. Es una metodología para el desarrollo de trabajos de minería de datos.
PLN	Procesamiento de lenguaje natural. Rama de la inteligencia artificial que ayuda a las computadoras a interpretar el lenguaje humano.
NLTK	Natural Language Toolkit (Kit de herramientas de lenguaje natural). Es una herramienta para trabajar en lingüística computacional usando Python.
BERT	Bidirectional Encoder Representations from Transformers. Es un sistema basado en inteligencia artificial para ayudar a los algoritmos de Google Search a entender mejor el lenguaje utilizado por los usuarios en el momento de realizar una búsqueda.
RoBERTuito	Modelo pre-entrenado con textos en español extraídos principalmente de la red social de Twitter, este modelo se basa en el modelo BERT.
spaCy	Librería de Python para aplicar procesamiento de lenguaje natural.
Bolsa de palabras	Técnica de procesamiento de lenguaje natural para la extracción de características y representación de texto que describe la ocurrencia de palabras dentro de un documento. Con esta técnica se convierte un texto en su vector equivalente de números.
Tokenizado	Técnica de procesamiento de lenguaje natural que sirve para separar las palabras de un texto en entidades conocidas como tokens (piezas más pequeñas del texto).
Lematizado	Técnica de procesamiento de lenguaje natural usada para determinar el lema de cada palabra que aparece en un texto. El objetivo es reducir una palabra a su raíz, de modo que las palabras clave de una consulta o documento se representen por sus raíces en lugar de por las palabras originales.
Análisis de sentimientos	Consiste en evaluar las emociones, actitudes y opiniones utilizando técnicas de inteligencia artificial como procesamiento de lenguaje natural. Este análisis permite clasificar el texto como positivo, negativo o neutro.

Lista de Anexos

Anexo 1: Extraccion_Twitter.ipynb.....	24
Anexo 2: Limpieza_Transformacion_V2.ipynb.....	30
Anexo 3: Análisis_Sentimientos.ipynb.....	31
Anexo 4: Panel_Visualizacion.html.....	35
Anexo 5: Panel_Visualizacion.ipynb.....	35

Introducción

Las redes sociales son un canal de comunicación virtual, que sirven como medio para el intercambio de todo tipo de información de manera sencilla y rápida, a tan solo un clic, y si las personas tienen acceso a internet podrán conectarse entre sí, sin importar en que parte del mundo se encuentren. De acuerdo con una encuesta realizada por la empresa Branch Group en el año 2020, en los últimos años en Colombia se ha evidenciado un aumento considerable en el uso del internet, sobre todo en personas entre los 16 y 64 años de edad, los cuales pueden gastar en promedio entre 3 horas y 35 minutos diarios haciendo uso exclusivamente de las redes sociales. Dentro de las redes más visitadas se encuentran Facebook, WhatsApp, Instagram y Twitter (Group, 2020), donde diversas empresas o usuarios aprovechan para ofrecer productos o posicionar una marca o una imagen en particular; solo en Twitter los anuncios publicitarios alcanzaron potencialmente a 3.35 millones de personas.

Por ejemplo, en el ámbito político para las elecciones presidenciales del año 2010, la Ola Verde representada por el candidato Antanas Mockus tuvo gran protagonismo, y *“fue un fenómeno político electoral que llevó a una movilización que batió récords mundiales en internet y logró alcanzar un alto nivel de apoyo en las calles y en los medios de comunicación del país”* (Cáceres, 2018). El factor diferenciador de estas elecciones fue el uso de Facebook y Twitter, *“ya que el éxito de la campaña política por internet fue impulsado por los mismos usuarios y no siguió una estrategia de sus asesores”* (Blanquicett, 2014).

Actualmente, los diferentes precandidatos a la presidencia de Colombia para el año 2022, han venido aprovechando las redes sociales para comentar o exponer sus ideas frente a temas de interés como el medio ambiente, políticas públicas, manejo de recursos, salud, relaciones internacionales, entre otros, logrando así que los usuarios (seguidores o detractores) pueden

aceptar o rechazar los diferentes ideales, expresando sus opiniones a través de comentarios, emojis, imágenes o videos.

Al final todo el contenido de la red social se convierte en información, que acompañada de un contexto y análisis sirve para tomar decisiones para las campañas en el caso de los precandidatos, o identificar cual es el candidato idóneo por el cual votar.

Para lo anterior, es posible que desde la analítica de datos entendida como un *“proceso de examinar conjuntos de datos para encontrar tendencias y sacar conclusiones sobre la información que contienen”* (Stedman, 2021), se puedan utilizar herramientas y metodologías propias del procesamiento de lenguaje natural, para poder extraer la información que Gustavo Petro, Sergio Fajardo, Rodolfo Hernández, María Fernanda Cabal y Óscar Iván Zuluaga comparten en su red social de Twitter, y posteriormente analizar y lograr conocer o determinar la idea, juicio o concepto que una persona tiene o se forma acerca de los precandidatos. Esto último, para el objeto de este trabajo se denominará *“perfil de opinión”*. Dicho esto, el principal objetivo de este trabajo es diseñar una herramienta que permita identificar un perfil de opinión de los precandidatos a la presidencia de Colombia para el año 2022, a partir de un análisis de aceptación y rechazo por parte de los usuarios de Twitter y utilizando técnicas de procesamiento de lenguaje natural; de esta manera, se pretende ser una guía para futuras investigaciones en los campos social y político que deseen abordar la influencia de las redes sociales en procesos electorales futuros. Esta herramienta facilitará el análisis de grandes cantidades de información, resumiendo a través de la visualización y permitiendo la interpretación rápida de la misma.

El desarrollo del trabajo se realizará teniendo como base la metodología CRISP-DM, contemplando las fases de extracción de datos, entendimiento del problema y preparación de los datos, modelado, evaluación y despliegue. Toda la documentación del proyecto (gráficos, corpus,

libros Python, panel de visualización) se encuentra en el repositorio de GitHub:

<https://github.com/malejacp4/ProyectoGrado>.

Para el trabajo se tiene contemplado realizar las extracciones de datos generados en la red social Twitter, mediante la creación de un bot que utiliza las librerías de Python selenium y la API tweepy, automatizando el proceso de recolección de datos mediante la captura de información contenida en el HTML del tweet, y extrayendo información adicional a través de los servicios autorizados por Twitter. Se realizará además un proceso de limpieza de datos haciendo uso de expresiones regulares, y se crearán corpus para el análisis por cada precandidato. Adicionalmente, se seleccionará por cada precandidato los 3 tweets más comentados para realizar un análisis de sentimientos utilizando el modelo RoBERTuito, con el fin de identificar que tan positivo, neutro o negativo fueron los tweets. Por último, se construirá un panel de visualización interactivo que permita la consulta de los resultados obtenidos para cada uno de los análisis realizados.

Planteamiento del Problema y Justificación

Las redes sociales han sido utilizadas negativa o positivamente para incrementar o disminuir el número de seguidores y opositores de un candidato en particular; por ejemplo, en el año 2013 la empresa Cambridge Analytica dedicada al análisis de datos para desarrollar campañas para marcas comerciales y políticos, diseñó un test de personalidad para aplicarlo a través de Facebook y poder obtener datos de 87 millones de usuarios (BBC News, 2019), dicha información fue utilizada para *“influenciar los resultados de las elecciones presidenciales de 2016 en EE.UU. y el referendo del Brexit en Reino Unido ese mismo año”* (BBC News, 2019). En este año, el presidente electo de EE.UU. fue Donald Trump, logrando su candidatura haciendo uso de las redes sociales.

A partir de lo anterior, se evidencia que mediante el procesamiento y análisis de la información que se puede extraer desde las redes sociales, se pueden ejecutar diferentes estrategias de campaña.

En Colombia, cada cuatro años los ciudadanos deben elegir por votación el presidente del país, antes de esta elección diferentes candidatos representantes de partidos políticos realizan campañas a través de diversos medios de comunicación, dentro de los que encuentra la red social Twitter.

Teniendo en cuenta lo anterior, *¿es posible identificar un perfil de opinión político de los precandidatos presidenciales a través de la información obtenida de la red social Twitter?*

Objetivos

Objetivo general

Diseñar una herramienta que permita identificar un perfil de opinión de los principales precandidatos a la presidencia de Colombia para el año 2022, a partir de un análisis de aceptación y rechazo por parte de los usuarios de Twitter, utilizando técnicas de procesamiento de lenguaje natural.


Objetivos específicos

- Construir un proceso que permita la recopilación, procesamiento y visualización del análisis de los tweets de cada precandidato.
- Crear un corpus para el almacenamiento y procesamiento de los datos recolectados a través de la red social de Twitter.
- Identificar y medir indicadores que permitan determinar que tan negativo, positivo o neutro reaccionan los usuarios de Twitter frente a los comentarios realizados por los precandidatos a la presidencia de Colombia.
- Comparar el rendimiento de los diferentes candidatos de acuerdo con las métricas definidas.
- Crear tablero / reporte que permita la visualización de los resultados obtenidos.

Antecedentes

El uso del procesamiento de lenguaje natural (PLN), considerado como una rama de la analítica de datos que se enfoca en la comprensión mediante ordenador del lenguaje humano y abarca una gran parte de la Ciencia de Datos, Inteligencia Artificial y la Lingüística Computacional, ha permitido en diferentes ámbitos de estudio el desarrollo de aplicaciones como chatbots, resumen de textos, análisis de sentimientos, entre otros (Bagnato, 2018). De hecho, se han conocido diversos estudios y trabajos, en donde gracias a la aplicación de técnicas de PLN se ha podido simplificar el entendimiento del hombre con las máquinas, como es el caso de estudios enfocados en el análisis de contenido y opinión en redes sociales, donde normalmente han seguido el proceso descrito a continuación:

Figura 1. Proceso para el Análisis de Contenido de Redes Sociales. Elaboración propia.



Hay estudios que buscan predecir a través del análisis de sentimientos de los usuarios de las redes sociales, la intención de voto o ideología de candidatos políticos a través de la aplicación

de técnicas de minería de datos o procesamiento de lenguaje natural, como se evidencia en el trabajo de grado de Carrillo, Ureña, Forero, & Caicedo (2016), donde se habla de un análisis de sentimiento para medir los efectos de la opinión pública presente en las redes sociales, acerca de las elecciones para la alcaldía de Bogotá de 2015. En el anterior trabajo, se realizó un modelo y un desarrollo de software que permitió hacer comparaciones con encuestas de opinión basadas en los datos disponibles en las redes sociales para las elecciones de la alcaldía; la técnica utilizada fue la de vectorización “*que consiste en sumar la calificación de cada palabra del tweet para darle el sentimiento correspondiente*” (Carrillo, Ureña, Forero, & Caicedo, 2016).

En Argentina, en el trabajo de grado de Llampá, Farfán, & Rodríguez (2018), se plantea la necesidad de analizar el sentimiento de los comentarios expuestos en Youtube, a través de su clasificación y análisis, utilizando un algoritmo de aprendizaje supervisado y librerías de Python como spaCy, scikit-learn y matplotlib. Por otro lado, se realiza una vectorización de palabras para finalmente utilizar modelos de clasificación a través de máquinas de soporte vectorial (SMV).

En este mismo país, se desarrolló el trabajo de grado “*Análisis de sentimiento en Twitter: El bueno, el malo y el >:(*” elaborado por Becerra (2016), en donde se propone una solución compuesta para estudiar las opiniones que compartieron distintos usuarios de Twitter; para lo cual, se extrajo la información a través de la API de Twitter, y posteriormente se generó un cluster para realizar un análisis de sentimientos utilizando diferentes métodos de clasificación; adicionalmente, se aplicó la técnica de K-fold cross-validation (validación cruzada de K iteraciones) como metodología de evaluación de los modelos, logrando conocer la “*opinión de los usuarios sobre cada tema haciendo uso de las palabras más frecuentes y los sentimientos*

asociados (positivo o negativo) a cada una de ellas según la clasificación de sentimiento de los tweets” (Becerra, 2016), y obteniendo los siguientes resultados:

Tabla 1. Resultados Obtenidos Modelos Trabajo de Grado: Análisis de sentimiento en Twitter: El bueno, el malo y el >:(. Adaptado de (Becerra, 2016)

Modelo	Parámetros	Precisión
SVM	Penalidad C de 100 y utilizando la función de pérdida “hinge”	87.15 %
Árboles de Decisión	Criterio “entropy” y con un máximo de 6 niveles de profundidad	66.85 %
Clasificador Bayesiano Ingenuo	Distribución multinomial y con un factor alpha de 0.	84.60 %

En España, en el trabajo de grado de Flores (2015), en donde a partir del análisis del discurso de un paciente se pretende obtener información acerca de sus emociones y sentimientos, producto de sus contenidos psicológicos, se logra desarrollar un algoritmo aplicando PLN a través del uso de la librería de Python NLTK y empleando el test de Sacks de frases incompletas para determinar rasgos caracterológicos.

A nivel de clasificadores de temas políticos, se pueden encontrar trabajos como el de Zirn, - Glavas, Nanni, Eichorst, & Stuckenschmidt (2016), en donde a través del uso de un modelo de red lógico de Markov, se realizó etiquetado de secuencias que permitió obtener un buen rendimiento de clasificación de temas o tópicos políticos a nivel de oración, logrando detectar el tema y cambios de opinión en las oraciones de manifiestos políticos.

Finalmente, en el trabajo de González (2020), se realiza un análisis de sentimientos sobre tweets en español a través de la aplicación del modelo BERT, logrando clasificar los tweets en negativos, positivos y neutros, y demostrando la precisión del modelo para el uso de corpus en el lenguaje español. El modelo BERT conocido desde el año 2018, es un modelo semi-supervisado de entrenamiento, que toma como base el uso de transformadores que se habían utilizado previamente en modelos como GPT (Alammar, 2018); este modelo se ha convertido en el referente actual para comprensión del lenguaje natural y el análisis de sentimientos. Sin embargo, para idiomas como el español, estos modelos reducen drásticamente su efectividad, es por esto que el trabajo realizado por Pérez, Furman, Alonso, & Luque (2021) donde presentan un modelo de lenguaje entrenado con más de 500 millones de tweets denominado “*RoBERTuito*” y basado en el modelo BERT, cobra gran importancia al tener un rendimiento competitivo frente a modelos monolingües en tareas de inglés. A continuación, se presentan los resultados de clasificación expresados como la puntuación media de Macro F1 de 10 ejecuciones de los experimentos:


Tabla 2. Resultados de Evaluación para Tareas de Clasificación en Español. Adaptado de (Pérez, Furman, Alonso, & Luque, 2021)

Modelo	Discurso de odio	Análisis de sentimientos	Análisis de emociones	Detección de ironía	Puntaje
RoBERTuito	80.1	70.7	55.1	73.6	69.9
RoBERTa	76.6	66.9	53.3	72.3	67.3
BERTin	76.7	66.5	51.8	71.6	66.7
BETO	75.7	64.9	52.1	52.1	52.1

Metodología

Teniendo en cuenta que es un proyecto de análisis de datos, para el desarrollo y cumplimiento de los objetivos del mismo se decide seguir y adaptar la metodología CRISP-DM, ya que contempla desde el entendimiento de los datos hasta la puesta en marcha y despliegue del panel de visualización. La metodología sigue las siguientes fases:

Figura 2. Fases de Implementación Metodología CRISP-DM. Adaptado de (IBM, 2021)




Antes de iniciar con la implementación de las fases, se hizo la selección de los precandidatos que iban ser parte del objeto de estudio, para esto se consultaron noticias en diferentes medios de comunicación, y finalmente se seleccionaron los candidatos que al mes de agosto del 2021 eran los más buscados en Google (El Tiempo, 2021). A partir de esto, se seleccionaron los siguientes candidatos:

Tabla 3. Candidatos Presidenciales Objeto de Estudio.

Candidato	Partido Político
Gustavo Petro	
Sergio Fajardo	
Rodolfo Hernández	
María Fernanda Cabal	
Óscar Iván Zuluaga	

Una vez seleccionados los candidatos, se realizó el siguiente proceso para la ejecución del trabajo, haciendo uso del lenguaje de programación de Python:


Figura 3. Flujo General del Procesos para la Generación de Resultados.

Fase 1: Extracción de datos

El primer objetivo específico está enfocado en la recopilación de la información que los precandidatos comparten en Twitter, para esto se creó un bot utilizando la librería selenium, permitiendo automatizar el proceso de recolección de datos mediante la captura de información contenida en el HTML del tweet, debido a que la API oficial de Twitter tiene un límite para descargar información gratuita.

Como primera medida, se realizó la instalación de la librería selenium y la configuración del controlador para Microsoft Edge, ya que este navegador presenta un mayor rendimiento al momento de la extracción de la información de una página HTML. En segundo lugar, se crearon unas funciones personalizadas para el logueo automático a Twitter, para la búsqueda y extracción de los tweets escritos por cada precandidato en el periodo comprendido entre julio del 2020 a agosto del 2021, así como para extraer la repuesta de los usuarios a algunos tweets. En el siguiente flujo se describe el proceso realizado para la extracción de la información de los tweets:

Figura 4. Flujo extracción de información de tweets



*A corte de octubre del 2021, a través de la función personalizada “*Obtener tweet*” del Anexo 1: Extraccion_Twitter.ipynb, se podrá conocer la parametrización usada para recorrer y extraer la información correspondiente a cada parte del tweet.

La extracción de la información se hizo por periodos de 2 a 3 meses, teniendo en cuenta los recursos de máquina y la banda ancha de internet.

Por otra parte, se realizó la conexión a la API de Twitter haciendo uso de la librería de tweepy, con el fin de extraer la información general de cada precandidato, como lo es la cantidad de seguidores, la descripción personal y el nombre de la cuenta.

Para consultar el detalle y el código desarrollado ver Anexo 1: Extraccion_Twitter.ipynb (ruta: https://github.com/malejacp4/ProyectoGrado/blob/main/datos/modelo/Extraccion_Twitter.ipynb)

Fase 2: Entendimiento del problema

El uso de las redes sociales se ha convertido en tendencia, ya que facilitan la comunicación y aprendizaje de diversos temas de interés. Twitter, es una de las redes sociales reconocidas por ser un canal para la divulgación y expresión de opinión en Colombia, sobre todo para temas políticos, donde los precandidatos a la presidencia tienen la oportunidad de hacer campaña y divulgar sus opiniones o propuestas, así como se evidencia en la investigación de Duque Giraldo & Salazar Martínez (2021), donde se “*estudia el proceso de transferencia que se produce entre el programa electoral de un candidato a un cargo público, la campaña política y su correspondiente impacto en las redes sociales*” (Duque Giraldo & Salazar Martínez, 2021), en el

análisis se estudiaron las elecciones para la alcaldía de Medellín y Bogotá de 2019, en donde los ganadores fueron Daniel Quintero y Claudia López respectivamente. En dicha investigación, se concluye que el uso de las redes sociales genera vínculos con la opinión pública y ayudan a que una campaña sea más efectiva, si se utilizan de forma correcta.

Un factor clave a tener en cuenta al querer analizar la información que reposa en Twitter, es que existen limitantes para la extracción de los datos (cantidades e información) a través de la API de Twitter, además de conocer que los datos que se obtienen son de tipo no estructurado, lo que dificulta el análisis del texto y la visualización de resultados; es por eso, que se recurrió al desarrollo de un bot como método alternativo para la extracción de los datos y para realizar un proceso de estructuración de los mismos, por otro lado, se construyó un panel de visualización en HTML.

Otro factor clave a tener en cuenta, es que, para realizar un análisis de sentimientos de un texto es importante tener claro el idioma, teniendo en cuenta que la mayoría de modelos desarrollados para la clasificación de sentimientos, tienen una efectividad alta si se procesa con textos en el idioma inglés.

Para esta fase, fue necesario realizar consultas bibliográficas sobre cada uno de los candidatos seleccionados, con el objeto de conocer la posición política e identificar características particulares; adicionalmente, se consultó bibliografía sobre los métodos para realizar análisis de sentimiento con datos en español, y otras técnicas para el procesamiento de lenguaje natural. El detalle de esta fase se puede consultar en la sección de Antecedentes.

Fase 3: Entendimiento y preparación de los datos

Para el cumplimiento del segundo objetivo y teniendo en cuenta que en la extracción de los datos se generó más de un archivo con los tweets de cada candidato, se procede a consolidar la información en cinco (5) archivos, uno por cada candidato:

- df_tweets_consolidado_MariaFdaCabal.csv: Consolidado de los tweets escritos o generados por María Fernanda Cabal.
- df_tweets_consolidado_OIZuluaga.csv: Consolidado de los tweets escritos o generados por Óscar Iván Zuluaga.
- df_tweets_consolidado_ingrodolfohdez.csv: Consolidado de los tweets escritos o generados por Rodolfo Hernández.
- df_tweets_consolidado_petrogustavo.csv: Consolidado de los tweets escritos o generados por Gustavo Petro.
- df_tweets_consolidado_sergio_fajardo.csv: Consolidado de los tweets escritos o generados por Sergio Fajardo.

Además de los archivos anteriores, fueron generados los siguientes:

- Inf_General_Candidatos_Twitter.csv: Contiene la información general de las cuentas de los candidatos (id, usuario, nombre, fecha de creación de la cuenta, entre otros).
- entorno_consolidado.csv: Contiene la información de los seguidores de los candidatos.


Adicionalmente, se pudo obtener por cada candidato la cantidad de comentarios y likes que los tweets tenían, por lo que se decide seleccionar los tres (3) tweets con el mayor número de comentarios, y posteriormente descargar una muestra de los comentarios generados por los

usuarios, con el propósito de realizar un análisis de sentimientos (explicado en la Fase 4: Modelado).

Por otra parte, se hizo necesario clasificar de forma manual, el tipo de usuario de las personas que siguen los candidatos, es decir, identificar si el usuario era periodista, medio de comunicación, político, religión, PEP (persona públicamente expuesta) o empresa. Esta clasificación se realizó tomando como referencia palabras claves, similares o comunes para cada grupo.

A partir de los procesos anteriores, se obtuvo la siguiente información:

Figura 5. Datos e Información Obtenida.



Para comprender cada uno de los atributos obtenidos en la extracción, se construyó un diccionario de datos que permitiera unificar los términos; a continuación, se relaciona el diccionario general de los datos:

Tabla 4. Diccionario de Datos.

Columna	Descripción
cantidad_comentarios	Conteo de las opiniones u observaciones que recibió el Tweet.
cantidad_likes	Conteo de “me gustas” que recibió el tweet por parte de los usuarios.
cantidad_retweets	Conteo de las veces en que se publica nuevamente un Tweet a través de otros usuarios.
cantidad_seguidores	Conteo de los usuarios que siguen a un usuario de Twitter.
cantidad_sigue	Conteo de los usuarios que un usuario de Twitter sigue.
descripcion	Texto de la información del perfil de este usuario (también conocida como biografía).
emoticon	Secuencia de caracteres ASCII que expresan emociones y se encuentran dentro del Tweet.
fecha	Hora de creación del Tweet.
fecha_creacion	La fecha y hora en que se creó la cuenta de usuario en Twitter.
id	Identificador único del usuario.
link	Dirección del Tweet único en la Web de Twitter.
mencion	Corresponde a la identificación de usuarios que son referenciados dentro del texto.
nombre	Denominación por la cual se reconoce el usuario del perfil de Twitter. Necesariamente no es el nombre de la persona.
texto	Texto del Tweet en codificación UTF-8.
usuario	Denominación por la cual se reconoce en pantalla, siendo un identificador o alias de Twitter. Los nombres de usuario son únicos y normalmente tiene un @ al inicio.

Para consultar los archivos extraídos y consolidados dirigirse al repositorio del proyecto en la ruta <https://github.com/malejacp4/ProyectoGrado/tree/main/datos%20>.

Una vez consolidados los archivos para cada precandidato, se procede a realizar la limpieza de datos, a través de la aplicación de expresiones regulares, para eliminar caracteres especiales y

emojis relacionados en el texto de los tweets; posteriormente, se eliminaron los registros nulos y se creó la siguiente lista de palabras para luego eliminarlas del texto de los tweets de los candidatos, debido a que no generaban valor para el estudio:

```
Lista=["sergio", "fajardo", "sergio fajardo", "sergiofajardo", "petro", "gustavo petro", "gustavo", "cabal", "maría fernanda", "mariafernandacabal", "maria", "fernanda", "zuluaga", "iván zuluaga", "óscar iván", "ingrordolfo", "ingeniero", "ing", "Rodolfo hernández", "rodolfo", "hernández", "hernandez", "ingrodolfohdez", "ingrodolfo", "lunes", "sr", "vez", "óscar", "iván"]
```

Con el proceso anterior, se obtuvo un total de 5,645 tweets, distribuidos de la siguiente manera:

Figura 6. Cantidad de Tweets por Candidato.



Por otra parte, se creó una nube de palabras con el texto de los tweets de cada candidato a través de la librería de NLTK, la cual contiene una lista de palabras vacías (stopwords) comunes para el idioma español. Se adicionaron a esta lista otras palabras que no representaban o generaban valor agregado para el objeto de estudio, y otras palabras como “duque” y “bogotá”, ya que, en el periodo de extracción de los datos dichas palabras fueron utilizadas bastante debido a la situación que se estaba generando en el país, referente a la reforma tributaria y el paro de diferentes gremios, por lo que no se quiso sesgar el análisis:

```
("jul", "agost", "oct", "jun", "tweet", "com", "quote", "cita", "nov", "aug", "may", "citar", "q", "ago", "si", "pm", "años", "Colombia", "país", "colombia", "and", "que", "twitter", "va", "co", "www", "others", "día", "hoy", "show", "hace", "hacer", "youtube", "facebook", "año", "quier en", "viernes", "días", "vale", "solo", "bogotá", "duque", "dec", "así", "cómo", "sep", "sino", "thread", "toda", "debe", "columna", "ésta", "elt iempo", "sido", "cómo", "toda", "parte", "alaire", "hora", "página", "media", "revista semana", "próximo")
```

Posteriormente, se realizó un análisis exploratorio para comenzar con la construcción de las métricas que hacen parte del desarrollo del tercer objetivo específico, para lo cual se requirió realizar tokenizado y lematizado de palabras, buscando facilitar el conteo de las palabras más utilizadas por los candidatos dentro de sus discursos; para este proceso, se trabajó con la librería Python spaCy, teniendo en cuenta que esta librería ya contiene un modelo entrenado en español con componentes como tok2vec, morphologizer, parser, sender, attribute_ruler, lemmatizer y ner; el modelo utilizado para realizar el paso anterior fue “*es_core_news_md*”, el cual tiene una precisión de 1 para tokenizado y de 0.96 para el lematizado (spacy.io, 2020).

Teniendo el texto lematizado y tokenizado, se eliminaron las palabras vacías y se creó una nube de palabras con los lemas (una por cada candidato); por otro lado, con el texto tokenizado (texto dividido en palabras) se crearon métricas como cantidad de palabras distintas por candidato, cantidad de palabras totales, top de palabras más usadas, total de palabras comunes entre candidatos y correlación entre el discurso de los candidatos.

Para consultar el detalle del proceso realizado en esta fase ver Anexo 2:

Limpieza_Transformacion_V2.ipynb (ruta:

https://github.com/malejap4/ProyectoGrado/blob/main/datos/modelo/Limpieza_Transformacion_V2.ipynb)

Fase 4: Modelado

Para dar continuidad con el desarrollo del tercer objetivo, en esta fase se realizó un análisis de sentimientos para determinar si los tweets de los candidatos generaban sentimientos positivos, negativos o neutros, debido a esto se seleccionaron por cada candidato los tres (3) tweets con

mayor número de comentarios, para posteriormente a través del bot construido en la fase 1, extraer los comentarios que los usuarios realizaron, teniendo como limitante que Twitter en su página HTML solo deja visualizar entre 200 y 250 comentarios.

Inicialmente, se intentó realizar el análisis de sentimientos haciendo uso de las librerías de NLTK y spaCy, sin embargo, al clasificar los tweets se identificó que la precisión no era buena, ya que estas librerías no funcionan muy bien para la clasificación de sentimientos con textos en el lenguaje español, por esta razón, la mayoría de tweets siempre eran clasificados como neutros. Se realizó entonces, el análisis de sentimiento haciendo uso de la librería pysentimiento, la cual *“cuenta con un preprocesador de tweets especialmente adecuado para la clasificación de tweets con modelos basados en transformadores”* (Pérez, Giudici, & Luque, 2021), esta librería utiliza el modelo RoBERTuito, que ha sido *“pre-entrenado para contenido generado por usuarios en español, entrenado siguiendo las pautas de RoBERTa en 500 millones de tweets”* (Pérez, Giudici, & Luque, 2021).

Para consultar el detalle y la aplicación del modelo, ver Anexo 3: Análisis_Sentimientos.ipynb (ruta: https://github.com/malejap4/ProyectoGrado/blob/main/datos/modelo/An%C3%A1lisis_Sentimientos.ipynb)

Por otra parte, se desarrolló un modelo descriptivo de redes, haciendo uso de la librería de Python pyvis, en donde se construyeron gráficos de red con el objeto de visualizar el entorno de los candidatos y sus seguidores, para esto fue necesario previamente eliminar los registros nulos del dataframe y se tomó la decisión de filtrar los datos teniendo en cuenta:

- Que los usuarios siguieran 2 o más candidatos.
- Que los usuarios tuvieran desde 1,000,000 de seguidores.

Ver Anexo 2: Limpieza_Transformacion_V2.ipynb, sección “Entorno de usuarios de los precandidatos” (ruta:

https://github.com/malejacp4/ProyectoGrado/blob/main/datos/modelo/Limpieza_Transformacion_V2.ipynb)

Finalmente, se quiso aplicar un modelo clasificación no supervisada para identificar patrones en los textos generados por los precandidatos; para esto se ejecutó inicialmente el modelo de K-medias, obteniendo los siguientes resultados:

Tabla 5. Cluster Modelo K-medias.

Cluster 1	Cluster 2	Cluster 3	Cluster 4	Cluster 5
gobierno	com	colombia	gustavo	bogotá
política	tweet	and	hoy	tweet
colombia	uribe	humana	com	this
salud	respuesta	amor	petro	thread
debe	país	seguimos	vivo	show
si	hoy	país	facebook	quote
social	justicia	trabajando	columna	policía
ser	citar	hoy	ingeniero	claudia
duque	presidente	democrático	hora	ciudad
país	si	others	entrevista	may
covid	semana	the	columnas	lópez
vacunas	paz	necesitamos	cuarto	colombia
sociedad	juan	jóvenes	programa	sep
tweet	colombia	trabajar	cuartodehora	esmad
vacuna	ser	tweet	rodolfo	hoy
cambio	farc	distinta	youtube	view
solo	siempre	othersgracias	pscp	includes
puede	gracias	centro	tv	content

Como se observa en la Tabla 5, en cada uno de los clusters generados a partir del modelo, no se identifica un patrón de agrupación producto de las palabras escritas por los precandidatos, por esta razón no se continúa con el análisis de este modelo.

Fase 5: Evaluación

Teniendo en cuenta la aplicación del análisis de sentimientos a través de las librerías NLTK, spaCy y pysentimiento, se hizo una validación aleatoria de los resultados seleccionando una muestra del 5% de los tweets (comentarios) realizados por los usuarios, con el fin de validar de manera supervisada si la clasificación de los sentimientos (negativo, positivo, neutro) era adecuada, y poder determinar el modelo que mejor clasificación realizaba sobre el texto; a partir de lo anterior, se obtuvo la siguiente matriz de confusión:

Tabla 6. Matriz de Confusión de los Clasificadores de Sentimientos

		Valores actuales			Total
		Neutros	Positivos	Negativos	
RoBERTuito	Neutros	41	8	15	165
	Positivos	3	51	4	
	Negativos	3	2	38	
NLTK	Neutros	30	15	19	165
	Positivos	9	39	10	
	Negativos	7	11	25	
spaCy	Neutros	34	17	15	165
	Positivos	8	43	7	
	Negativos	4	8	29	

Posteriormente, a través de la métrica de evaluación de precisión, se identificó que la librería pysentimiento, a través de su modelo entrenado RoBERTuito, presentó los mejores resultados en cada uno de los clasificadores de sentimiento, como se evidencia a continuación:


Tabla 7. Resultados de la Evaluación de las Tareas de Clasificación de Sentimientos

Modelos de sentimiento	Precisión		
	Neutros	Positivos	Negativos
RoBERTuito	0.64	0.88	0.88
NLTK	0.47	0.67	0.58
spaCy	0.52	0.74	0.71

Fase 6: Despliegue

Realizadas las fases anteriores y como cumplimiento del quinto objetivo, se realiza la creación y despliegue de un panel de visualización en formato HTML que permite ver los siguientes resultados:

Figura 7. Resultados Relacionados en el Panel de Visualización.



Para la creación del panel de visualización, se utilizó en una primera instancia la librería `ipython`, la cual permitió estructurar dentro del Jupyter Notebook de Python una página web en código HTML, haciendo un llamado a las diferentes gráficas e imágenes almacenadas el repositorio del proyecto; el HTML conserva la siguiente estructura:

- Encabezado.
- Descripción general del panel de visualización.
- Cuadros dinámicos con la foto e información general de cada candidato.
- Pestañas interactivas por cada una de las secciones, las cuales cuentan con la siguiente estructura:
 - Descripción general de la sección
 - Título y gráficos de la sección
 - Botón interactivo del análisis general de los resultados evidenciados en la(s) gráfica(s) de la sección.

Posteriormente, a través de `voila` y la habilitación de su extensión en Jupyter, se genera la salida de un único archivo denominado “*Panel_Visualizacion.html*” (ver Anexo 4:

Panel_Visualización.html. Ruta:

https://rawcdn.githack.com/malejacp4/ProyectoGrado/main/despliegue/Panel_Visualizacion.html

), el cual brinda la posibilidad de que se descargue en extensión HTML.

Para consultar el detalle y el desarrollo de esta fase, ver Anexo 5: *Panel_Visualización.ipynb* (ruta: https://github.com/malejacp4/ProyectoGrado/blob/main/datos/modelo/Panel_Visualizacion.ipynb)

Resultados

Como resultado de la aplicación de las fases descritas en la metodología, se obtuvo un panel de visualización que se divide en seis módulos principales, a los que se puede acceder dando clic sobre cada uno de ellos:

Figura 8. Módulos Panel de Visualización.




A continuación, se presentan los resultados por cada módulo del panel de visualización:

Módulo 1: Información General

En este módulo se crearon dos gráficas donde se representa la cantidad de usuarios que sigue cada candidato y la cantidad de seguidores:

Figura 9. Cantidad de Seguidores y Usuarios Seguidos.



Con estas gráficas se puede dar una idea del alcance que podría tener el discurso de cada candidato, al realizar campaña a través de Twitter. Se observa entonces, que no hay una relación directa entre la cantidad de seguidores y la cantidad de usuarios que los precandidatos siguen, normalmente los candidatos tienen más seguidores que usuarios seguidos.


Los resultados de estas gráficas dejan ver que Gustavo Petro es el candidato más activo en la red social, en comparación con los otros candidatos, y aunque Sergio Fajardo se unió a la red en el mismo año que Petro (2009) la diferencia de seguidores supera los 2'000,000. Rodolfo Hernández, a corte de agosto de 2021 cuenta con el menor número de seguidores, se debe tener en cuenta que él es el único candidato que no pertenece a un partido político y que se unió a Twitter cuatro años después (en el 2013) que Fajardo y Petro.

Módulo 2: Relación de usuarios que siguen

En este módulo se encuentran dos grafos de red que representan la relación de usuarios comunes que los candidatos siguen en sus redes sociales, con el objeto de tener un mayor entendimiento de la red con la que interactúan en Twitter. En dichos grafos, se hizo una clasificación para identificar el “*tipo de usuario*” y poderlo representar a través de colores diferentes. Por otra parte, se desplegaron las gráficas de tal forma que al pasar el cursor por cada nodo se pueda obtener información del nombre del usuario y la cantidad de seguidores, de esta manera poder obtener un gráfico dinámico que permita analizar diferentes puntos de vista y algunos resultados generales:

- **Usuarios comunes que siguen**

Figura 10. Usuarios Comunes que Siguen.



Para la generación de este gráfico, se filtró la base por los usuarios comunes que tuvieran más de un millón de seguidores. Se puede observar en el gráfico un distanciamiento mayor de la precandidata presidencial María Fernanda Cabal con respecto al resto de precandidatos, aunque el más cercano a ella es Óscar Iván Zuluaga ya que siguen varios usuarios en común. También se puede apreciar que todos los precandidatos siguen en gran medida a usuarios inmersos en la política y medios de comunicación, encontrando relaciones que en el ámbito político pueden ser extrañas debido a los ideales expresados por los precandidatos, como son:

- **Político**

- Álvaro Uribe (ideología de derecha) quien tiene más de 5'000,000 de seguidores, es seguido por todos los precandidatos a excepción de Gustavo Petro.
- Barack Obama (demócrata) quien tiene más de 130'000,000 de seguidores, es seguido por todos los precandidatos a excepción de María Fernanda Cabal.
- Antanas Mockus (ideología de centro) quien tiene más de 2'123,000 de seguidores, es seguido por todos los precandidatos a excepción de María Fernanda Cabal.
- Lenin Moreno (ideología de izquierda) quien tiene más de 1'000,000 de seguidores, es seguido por Gustavo Petro y María Fernanda Cabal.

- **Periodista o Medio de Comunicación**

- Vicky Dávila (ideología de derecha) quien tiene más de 3'000,000 de seguidores, es seguida por todos los precandidatos.
- Revista Semana quien tiene más de 4'700,000 de seguidores, es seguido solo por María Fernanda Cabal y Óscar Iván Zuluaga

Módulo 3: Palabras más utilizadas

A través de los tweets escritos por cada precandidato en su red, se pudieron identificar las palabras que normalmente usan para expresar sus ideas, en este módulo se creó por cada candidato, una nube con las palabras más utilizadas dentro de sus discursos:

Figura 12. Ejemplo Palabras más Utilizadas por Candidato.



Para el proceso de la elaboración de la nube de palabras, fue necesario tokenizar los textos de los tweets y eliminar las palabras vacías, a partir de esto, se pudo realizar un conteo del total de palabras, y un conteo de palabras distintas utilizadas por cada candidato, en donde al hallar la diferencia entre estos dos valores, se identificó el porcentaje de palabras reutilizadas. Este detalle se puede conocer pasando el cursor del mouse sobre cada nube de palabras.


Como resultado de estas gráficas, se logra identificar que a pesar de que Rodolfo Hernández es el candidato que menos palabras utiliza, ya sea porque ha publicado menos tweets o porque estos son más cortos, es el que más palabras distintas utiliza; mientras que Gustavo Petro, que es

el candidato que más palabras utiliza, resulta siendo el que menos palabras distintas usa, lo que indica que su discurso tiende a ser el mismo normalmente.

Módulo 4: Top de palabras lematizadas

Como se ha indicado anteriormente, la lematización es un proceso que ayuda a identificar el lema o raíz de una palabra, facilitando la agrupación y conteo de palabras de un texto. Para este módulo, fue necesario eliminar los artículos, pronombres, preposiciones y todas las palabras que no aportaban ningún tipo de información (stopwords). En las gráficas creadas en esta sección, se representan las palabras lematizadas más utilizadas por los precandidatos en sus discursos:

Figura 13. Ejemplo Top Palabras Lematizadas más Utilizadas por Candidato.




A partir del análisis de estas gráficas, se puede identificar que todos los candidatos utilizan palabras que son normales en el lenguaje político, como lo son las palabras como paz, salud, educación y justicia. Adicionalmente, se identifica que candidatos como Sergio Fajardo y Óscar Iván Zuluaga a pesar de pertenecer a partidos políticos diferentes, comparten dentro de su top de palabras la palabra “jóvenes” y normalmente hablan de “solucionar” o dar “respuesta” a algo en

particular, esta similitud en el uso de palabras podría estar relacionado a la formación académica que tienen, matemático y economista respectivamente.


Módulo 5: Correlación entre palabras comunes

A partir de la lematización de las palabras, se realizó una correlación entre estas con el fin de identificar la similitud entre el perfil de los candidatos, partiendo de la idea que, si dos candidatos escriben de forma similar, tenderán a utilizar las mismas palabras y con frecuencias similares. En este módulo, se representa esta información a través de una matriz de correlación, la cual maneja una escala de 0 a 1, lo que significa que entre mayor sea el número, la correlación es más fuerte, es decir que existe una similitud entre los perfiles:

Figura 14. Correlación Entre las Palabras Comunes de los Candidatos



Por otra parte, se creó un diagrama de barras que representa el total de palabras comunes entre los diferentes candidatos:

Figura 15. Número de Palabras Comunes Entre los Candidatos

Como resultado, se puede observar que entre Gustavo Petro y María Fernanda Cabal existe una correlación muy fuerte en las palabras que utilizan (0.72), y esto se debe a que utilizan alrededor de 5,144 palabras comunes entre las cuales se pueden destacar: gobierno, Uribe, Petro, política, presidente, nacional, pandemia, dinero, justicia y poder.

En una segunda instancia, se identifica que entre Gustavo Petro y Sergio Fajardo existe otra correlación muy fuerte en las palabras que utilizan (0.64), y esto se debe a que utilizan alrededor de 2,983 palabras comunes entre las cuales se pueden destacar: familia, democracia, fuerza, jóvenes, malos, paz y reforma.


Por otra parte, se identifica que Rodolfo Hernández es el candidato que en general tiene menor similitud con los perfiles de los otros candidatos.

Módulo 6: Sentimientos de los tweets

Para el análisis de sentimientos, se seleccionó por cada candidato los tres (3) tweets que mayor número de comentario obtuvieron y posteriormente se identificó que tan positivo, neutro o negativo fue para los usuarios.

Este módulo se encuentra dividido en cinco (5) secciones, una por cada candidato, en donde se identifica para cada tweet analizado, la cantidad de comentarios, likes y retweets; además se relaciona un gráfico de torta que representa el sentimiento (neutro, negativo y positivo) general de los usuarios:

Figura 16. Ejemplo Análisis Sentimientos



A nivel general, se identifica que los tweets generan más opiniones negativas, sobre todo cuando los candidatos hacen referencia a palabras como reforma, izquierda, socialismo, comunismo, pacto, financiación, Colombia Humana y Gustavo Petro; por el contrario, se generan opiniones positivas si los tweets hablan de la protección de niños, paz y democracia. Adicionalmente, se puede evidenciar que los candidatos Sergio Fajardo y Óscar Iván Zuluaga, son los que generan opiniones más negativas frente al resto de candidatos, lo que puede ser el resultado de utilizar palabras similares dentro de sus discursos. Por otra parte, a pesar de que Gustavo Petro y María Fernanda Cabal comparten un perfil de opinión similar (como se

demuestra en el módulo anterior), se observa que Gustavo Petro tiende a tener menos comentarios negativos.

Discusión de los Resultados

De acuerdo con los resultados obtenidos a partir de la herramienta construida, podrá ser punto de avance para el entendimiento de un perfil de opinión de figuras públicas, a través del análisis de información de la red social de Twitter, ya que se pudo realizar un análisis desde los siguientes frentes:

- Cantidad de seguidores y usuarios seguidos.
- Grafos de relación de usuarios comunes seguidos.
- Palabras más utilizadas.
- Correlación entre las palabras que usan los diferentes candidatos.
- Sentimientos de los tweets con mayor repercusión de los usuarios.

En contra posición de investigaciones y trabajos de grado en el ámbito nacional, como los fueron la de *“Radiografía del Twitter: determinantes de la interacción en los mensajes de Álvaro Uribe y Juan Manuel Santos en la campaña por el plebiscito ”* (Cáceres, 2018) y *“Análisis de sentimiento en Twitter: El bueno, el malo y el >:()”* (Becerra, 2016) , los cuales basaron sus resultados en análisis de información descriptiva como: cantidad de likes, retweets, comentarios, palabras más utilizadas y la aplicación de análisis de sentimientos sobre los comentarios o respuestas a los tweets, sin complementar aspectos como el entorno de los candidatos a través de grafos de los usuarios que siguen en común o la correlación de palabras utilizadas entre estos, estos últimos sirven para ahondar en el entendimiento del usuario y su relación directa o indirecta con otros, ayudando así a obtener un perfil de opinión del usuario más robusto.

Adicionalmente, estas investigaciones previas se basaron en la generación de modelos de

lenguajes pre-entrenados para el análisis de sentimientos, a través del uso de máquinas de soporte vectorial, los cuales en la actualidad se encuentran un escalón por debajo a modelos que utilizan redes neuronales o transformadores, como en el caso del modelo BERT, el cual es semi-supervisado y de entrenamiento para el análisis de sentimientos. Dicho modelo en su versión mejorada al español denominada “*RoBERTuito*”, fue utilizado para el desarrollo de la herramienta, teniendo en cuenta que es un modelo pre-entrenado con tweets en español, por lo que contempla el uso de expresiones informales o coloquiales del lenguaje.

Conclusiones y Recomendaciones

- Mediante la aplicación de técnicas de procesamiento de lenguaje natural, se pudo llegar a conocer el perfil de opinión de los candidatos a la presidencia, teniendo en cuenta, que a través de estas prácticas se lograron identificar y conocer diferentes aspectos del candidato, como por ejemplo las palabras más utilizadas dentro de los discursos, red de seguidores y seguidos, cantidad de seguidores, entre otros. Adicionalmente, se logró identificar el tipo de opinión, ya sea negativa, positiva o neutra que los candidatos producen en los usuarios mediante los tweets compartidos en la red.
- Es interesante cómo a través de la aplicación y creación de diferentes gráficas, se logró identificar patrones comunes o diferentes entre los diferentes candidatos analizados. Por ejemplo, a partir de la construcción de gráficos de red, se pudo identificar no solo el tipo de usuarios que siguen los candidatos (políticos, medios de comunicación, PEP), sino que también se lograron identificar relaciones entre los mismos candidatos; dichas relaciones se encuentran divididas en dos grupos, el primero conformado por María Fernanda Cabal y Óscar Iván Zuluaga, quienes pertenecen al partido político Centro Democrático, y el segundo grupo integrado por Gustavo Petro, Sergio Fajardo y Rodolfo Hernández. Por otra parte, mediante la creación de la matriz de correlación, se logró identificar que Rodolfo Hernández es el candidato que menor similitud tiene con los perfiles de los otros candidatos, mientras que Gustavo Petro y María Fernanda Cabal, a pesar de pertenecer a partidos y posiciones políticas totalmente opuestos, son los que mayor relación tienen en cuanto a las palabras que utilizan en sus discursos.

- Con relación al análisis de sentimientos realizado, se identificó de manera general que cuando los candidatos hacen uso de palabras relacionadas con posiciones de la izquierda, estos generan opiniones negativas; mientras que, si hablan de paz y democracias, las opiniones tienden a ser más positivas. Adicionalmente, se logró identificar que Sergio Fajardo y Óscar Iván Zuluaga son los candidatos que generan mayor número de opiniones negativas, en comparación con los candidatos.
- El modelo “*RoBERTuito*” utilizado para el análisis de sentimientos, logró realizar una clasificación adecuada de los textos analizados, esto debido a que el modelo fue pre-entrenado con corpus en español extraídos de redes sociales, principalmente de Twitter; de hecho, actualmente este modelo sigue en construcción, con el objeto de incluir mayor número de datos en el idioma español, permitiendo mejorar los resultados cada vez más.
- La creación del panel de visualización sobre HTML, se considera una buena solución para la exhibición de los resultados, teniendo en cuenta que las gráficas e información pueden ir embebidas en el HTML, permitiendo generar un archivo único que puede ser consultado en cualquier navegador; por otro lado, no requiere la instalación o intervención de software adicionales para su construcción y procesamiento.
- Si bien es cierto que la API de Twitter en su versión gratuita tiene limitantes a la hora de la extracción de datos e información, se puede recurrir al uso de otras herramientas o librerías de Python, como por ejemplo selenium, mediante la cual se logró construir el bot que permitió la recolección de datos. Sin embargo, para el análisis de sentimientos, en

donde fue necesario extraer los comentarios que los usuarios hicieron sobre los tweets de los candidatos, se tuvo la limitante de que únicamente se pudieron extraer entre 200 y 300 tweets, por lo que se recomienda para próximas aplicaciones, si el estudio estará enfocado únicamente en análisis de sentimientos, tener acceso a la versión premium de la API de Twitter, con el fin de contar con un mayor número de tweets.

Lista de Referencias

Alammar, J. (3 de December de 2018). *GitHub*. Obtenido de jalammar:

<http://jalammar.github.io/illustrated-bert/>

Bagnato, J. I. (Diciembre de 2018). *Aprende Machine Learning*. Obtenido de

<https://www.aprendemachinellearning.com/procesamiento-del-lenguaje-natural-nlp/>

BBC News. (Julio de 2019). Obtenido de <https://www.bbc.com/mundo/noticias-49093124>

Becerra, C. M. (2016). *Análisis de sentimiento en Twitter: El bueno, el malo y el >:(*. Argentina:

Universidad Nacional de Córdoba.

Blanquicett, E. H. (2014). *El uso de las redes sociales en las elecciones presidenciales*. Bogotá.

Cáceres, M. A. (2018). *Radiografía del Twitter: Determinantes de la Interacción en los Mensajes de Álvaro Uribe y Juan Manuel Santos en la Campaña por el Plebiscito*. Bogotá.

Carrillo, A. C., Ureña, J. C., Forero, J. D., & Caicedo, L. E. (2016). *Análisis del sentimiento político mediante la aplicación de herramientas de minería de datos a través del uso de redes sociales*. Bogotá: Universidad Javeriana.

Duque Giraldo, S., & Salazar Martínez, C. (2021). Del programa electoral a la campaña política en Twitter Análisis de los datos suscritos a la interacción en Twitter de las campañas ganadoras en Medellín y Bogotá para 2019. *Comunicación*, 30-50.

El Tiempo. (Agosto de 2021). Obtenido de <https://www.eltiempo.com/tecnosfera/novedades-tecnologia/elecciones-2022-petro-y-los-precandidatos-mas-buscados-en-google-613084>

- Flores, D. O. (2015). *Procesamiento de lenguaje natural aplicado a la evaluacin de personalidad por medio de test proyectivos de frases incompletas*. Catalunya: Universidad de las Fuerzas Armadas.
- González, I. C. (2020). *Procesamiento del lenguaje natural con BERT: Análisis de sentimientos en tuits*. Colmenarejo: Universidad Carlos III de Madrid.
- Group, B. (2020). *branch*. Obtenido de <https://branch.com.co/marketing-digital/estadisticas-de-la-situacion-digital-de-colombia-en-el-2019-y-2020/>
- IBM. (17 de Agosto de 2021). Obtenido de <https://www.ibm.com/docs/es/spss-modeler/SaaS?topic=dm-crisp-help-overview>
- Llampa, Á., Farfán, J., & Rodríguez, M. (2018). *Análisis de Sentimiento aplicado a la detección de Ciberacoso en YouTube como Red Social*. Argentina: Universidad Nacional de Jujuy.
- Pérez, J. M., Giudici, J. C., & Luque, F. (2021). Obtenido de <https://github.com/pysentimiento/pysentimiento>
- Pérez, J., Furman, D., Alonso, L., & Luque, F. (2021). RoBERTuito: a pre-trained language model for social media text in. *Google Scholar*, 1.
- spacy.io*. (2020). Obtenido de https://spacy.io/models/es#es_core_news_md
- Stedman, C. (2021). *ComputerWeekly.es*. Obtenido de <https://www.computerweekly.com/es/definicion/Analisis-o-analitica-de-datos>
- Zirn, C., Glavas, G., Nanni, F., Eichorst, J., & Stuckenschmidt, H. (2016). *Classifying Topics and Detecting Topic Shifts in Political Manifestos*. Mannheim: University of Mannheim.

Anexos

Todos los anexos incluyendo el material de apoyo, desarrollo de la herramienta y el panel de visualización, se encuentran documentados en el repositorio del proyecto creado en GitHub. Para mayor detalle dirigirse a la ruta: <https://github.com/malejacp4/ProyectoGrado>.

Figura 17. Repositorio Documentación

