



Definición de un lenguaje controlado para el análisis de sentimientos en Twitter para mensajes en inglés

Karen Yessenia Espinosa Zuluaga

Universidad Nacional de Colombia
Facultad de Minas
Medellín, Colombia
2019

Definición de un lenguaje controlado para el análisis de sentimientos en Twitter para mensajes en inglés

Karen Yessenia Espinosa Zuluaga

Tesis de investigación presentada como requisito parcial para optar al título de:

Magister en Ingeniería de Sistemas

Director:

Ph.D. Carlos Mario Zapata Jaramillo

Línea de Investigación:

Ingeniería de Software

Grupo de Investigación:

Lenguajes Computacionales

Universidad Nacional de Colombia

Facultad de Minas

Medellín, Colombia

2019

A mi madre, por su amor, paciencia y apoyo incondicional.

Agradecimientos

Agradezco infinitamente al profesor Carlos Mario Zapata Jaramillo, director de la investigación, por sus enseñanzas, motivación y confianza depositada en mí.

Al profesor Gabriel Alberto Awad Aubad por sus consejos y apoyo constante.

A Alejandro López, que siempre estuvo a mi lado incondicionalmente y me alentó a seguir adelante.

Igualmente, quiero expresar mi gratitud a todos aquellos que de alguna manera me apoyaron y que fueron de vital importancia en este trabajo.

Resumen

El análisis de sentimientos, también conocido como minería de opinión, surge con el fin de determinar la polaridad de un texto dado. Es el campo de estudio que permite analizar la respuesta emocional de los usuarios en redes sociales, con el fin de ayudar en la toma de decisiones en ámbitos sociales, económicos, políticos, laborales y financieros. Una de las redes sociales que está ganando más popularidad en el análisis de sentimientos es Twitter, ya que es una herramienta de *microblogging* social que permite a los usuarios expresar opiniones e ideas en textos cortos (280 caracteres) y concisos, lo cual es ideal para extraer estadísticas de temas específicos. Sin embargo, el vocabulario que se utiliza en redes sociales posee problemas inherentes al lenguaje natural. Tradicionalmente, en lingüística computacional se solucionan estos problemas utilizando lenguajes controlados. Un lenguaje controlado es un subconjunto del lenguaje natural que posee restricciones en la terminología, lo cual permite reducir la ambigüedad y aporta precisión para posteriores análisis. Para entender el significado que tienen las palabras en un vocabulario, es necesario recurrir a los términos de connotación y denotación. La connotación de una palabra incluye elementos de carácter subjetivo e implica interpretación. Por su parte, la denotación, es la expresión formal y objetiva, es decir, el significado universal que se le da a una palabra. En lo relativo a la función que realizan las palabras dentro de una oración, el análisis sintáctico suministra apoyo en cuanto a describir cómo las palabras de la oración se relacionan y la categoría gramatical que tiene cada una de estas. Para realizar el análisis sintáctico se puede utilizar un árbol de constituyentes. Comúnmente, en la minería de opinión se utiliza el preprocesamiento de datos para eliminar ruidos y/o inconsistencias, con el fin de preparar los datos para un posterior análisis. Esta intervención y transformación se realiza mediante los siguientes pasos: tokenización, eliminación de datos ruidosos, eliminación de palabras de jerga, revisión ortográfica y, por último, *stemming*. En las aproximaciones encontradas en la literatura para el análisis de sentimientos se encuentran métodos basados en léxico, los cuales contienen enfoques basados en diccionarios. En esas aproximaciones se aprecian análisis de ciertos elementos de los corpus de diferentes redes sociales, pero, debido a la falta de un lenguaje

controlado, requieren una mayor intervención y transformación del mensaje antes de definir su polaridad. Esto se debe a que el lenguaje natural utilizado en las redes sociales posee características como la polisemia y sinonimia que plantean desafíos en el análisis computacional y, además, tiene datos ruidosos como emoticones, *hashtags*, caracteres especiales, hipervínculos o etiquetas HTML. Debido a lo anterior, se pierde parte de la información que puede ser relevante a la hora de definir la polaridad de un mensaje. Adicionalmente, los enfoques basados en diccionarios fallan a la hora de relacionar términos y analizar el contexto en que las palabras se escriben. Por ello, en esta Tesis de Maestría se propone la definición de un lenguaje controlado para el análisis de sentimientos en Twitter para mensajes en inglés, el cual tiene como finalidad transformar las opiniones de los usuarios en una estructura que facilite su clasificación en polaridades negativas o positivas mediante reglas sintácticas, representando el lenguaje natural en textos controlados que se podrían utilizar para mejorar los métodos existentes en la literatura para el análisis de sentimientos. Una vez se implementa el lenguaje controlado, las palabras adquieren valor sintáctico, se estandariza la terminología y el formato de la información, por lo cual los mensajes son más precisos e inequívocos y, por consiguiente, son útiles como punto de partida para la automatización del razonamiento.

Palabras clave: Twitter, Análisis de sentimientos, Lingüística computacional, Lenguaje natural, Lenguaje controlado, Tuits en inglés.

Abstract

Sentiment analysis—SA, also known as opinion mining—is intended to determine the polarity of a given text. SA is the field of study for analyzing the emotional response of social network users in order to help decision making in social, economic, political, labor, and financial fields. One of the social networks gaining more popularity in sentiment analysis is Twitter, since it is a social microblogging tool which allows users for expressing their opinions and ideas in concise and short (280 characters) texts ideal to draw statistics from specific topics. The vocabulary used in social networks has inherent problems regarding natural language. Commonly, such problems are solved in computational linguistics by using controlled languages. A controlled language is a subset of natural language with restrictions in terminology for reducing ambiguity and providing accuracy to future analyses. Concepts of connotation and denotation are needed to understand the meaning words have in certain vocabulary. Connotation of a word includes subjective elements and it implies interpretation. On the other hand, denotation is defined as a formal and objective expression, *i.e.*, the universal meaning a word. Related to the function of words within a text, the syntax analysis supports the way the words in a sentence are interrelated and the grammatical category of each word. Syntax trees can be used for carrying out a syntax analysis. In opinion mining, data pre-processing is commonly used for removing noise/inconsistencies in order to prepare data for a future analysis. Pre-processing has some steps: tokenization, deletion of noisy data, deletion of jargon words, spell checking, and finally stemming. Previous work about sentiment analysis includes lexicon-based methods with dictionary-based methods. In such methods, analysis of different corpus elements is estimated in some social networks, but it requires a greater intervention and transformation of the message before defining its polarity due to the lack of a controlled language. Also, natural language used in social networks has challenges in its computational analysis, because it presents polysemy and synonymy, and noisy data—*e.g.*, emojis, hashtags, special characters, hyperlinks, and HTML tags. As a result, part of

the information relevant at the time of defining the polarity of a message is lost. In addition, dictionary-based methods fail in relating concepts and analyzing the context in which the words are written. For this reason, in this M.Sc. thesis we propose the definition of a controlled language for sentiment analysis in Twitter English messages. We intend to transform the user opinion into a structure for easing their classification into negative/positive polarities by using syntax rules. We represent natural language in controlled texts to be used for improving the existing sentiment analysis methods of the state of the art. Once controlled language is implemented, the words acquire syntactic value, the terminology and the format of the information are standardized, and consequently the messages are more precise and unambiguous. So, they are useful for the reasoning automation.

Keywords: Twitter, Sentiment analysis, Computational linguistics, Natural language, Controlled language, Tweets in English.

Contenido

1. Introducción	1
2. Marco teórico.....	6
2.1 Análisis de sentimientos	6
2.2 Twitter	9
2.3 Lenguaje natural	10
2.3.1 Lenguaje controlado	11
2.3.2 Preprocesamiento de datos	12
2.3.1.1 Tokenización	13
2.3.1.2 Eliminación de datos ruidosos	13
2.3.1.3 Eliminación de palabras de jerga	14
2.3.1.4 Corrección ortográfica y eliminación de palabras.....	15
2.3.1.5 Stemming	15
2.4 Connotación	15
2.5 Denotación	16
2.6 Análisis sintáctico	16
3. Antecedentes.....	19
4. Propuesta de solución	27
4.1 Estructura de la solución	27
4.2 Reglas sintácticas para el lenguaje controlado	31
4.2.1 Regla 1	32
4.2.1.1 Patrón 1.....	33
4.2.1.2 Patrón 2.....	33
4.2.1.3 Patrón 3.....	34
4.2.2 Regla 2	36
4.2.3 Regla 3	37
4.2.4 Regla 4	39
4.3 Taxonomía de adjetivos y verbos	40
4.3.1 Adjetivos	40
4.3.2 Verbos	43
4.3.3 Sustantivos adjetivados	43
4.3.4 Adverbios.....	43
5. Validación	45
5.1 Aplicación.....	45
5.1.1 Regla 1	45
5.1.1.1 Patrón 1.....	45

5.1.1.2	Patrón 2	46
5.1.1.3	Patrón 3	47
5.1.2	Ejemplo regla 2	48
5.1.3	Ejemplo regla 3	49
5.1.4	Ejemplo regla 4	50
5.2	Resultados.....	50
5.2.1	Precisión del lenguaje controlado	51
6.	Conclusiones y trabajo futuro	55
6.1	Conclusiones	55
6.2	Trabajo futuro	56

Lista de figuras

	Pág.
Figura 2-1 Interés a lo largo del tiempo sobre el análisis de sentimientos.....	8
Figura 2-2 Diagrama de flujo del preprocesamiento de datos.	13
Figura 2-3 Ejemplo de tokenización.....	13
Figura 2-4 Ejemplo de eliminación de datos ruidosos.....	14
Figura 2-5 Ejemplo de corrección ortográfica y eliminación de palabras.....	15
Figura 2-6 Ejemplo árbol de constituyentes.....	17
Figura 3-1 Técnicas de clasificación de sentimientos.....	20
Figura 3-2 Arquitectura propuesta en elecciones en Delhi de enfoque basado en diccionario.....	21
Figura 3-3 Arquitectura propuesta con teléfonos inteligentes de enfoque basado en diccionario.....	22
Figura 3-4 Arquitectura propuesta en caso de la India digital de enfoque basado en diccionario.....	23
Figura 4-1 Diagrama de flujo de la solución.....	31
Figura 5-1 Base de datos para la validación.....	45

Lista de tablas

Pág.

Tabla 3-1 Resumen de los problemas y desafíos presentes en la revisión de la literatura.	
.....	25
Tabla 4-1 Conversión de abreviaciones.	28
Tabla 4-2 Etiquetas específicas para palabras.	28
Tabla 4-3 Reglas XOR.	30
Tabla 4-4 Reglas para la negación.	30
Tabla 4-5 Etiquetas y significados para expresiones regulares.	32
Tabla 4-6 Operadores y cardinalidades para expresiones regulares.	32
Tabla 4-7 Regla 1, patrón 1: ejemplo.	33
Tabla 4-8 Regla 1, patrón 2: ejemplo.	34
Tabla 4-9 Regla 1, patrón 3: ejemplo.	35
Tabla 4-10 Regla 2: patrón y ejemplo.	37
Tabla 4-11 Regla 5: patrón y ejemplo.	38
Tabla 4-12 Regla 3: patrón y ejemplo.	39
Tabla 4-13 Taxonomía de adjetivos, categoría tiempo.	40
Tabla 4-14 Taxonomía de adjetivos, categoría velocidad.	40
Tabla 4-15 Taxonomía de adjetivos, categoría tamaño.	41
Tabla 4-16 Taxonomía de adjetivos, categoría Forma.	41
Tabla 4-17 Taxonomía de adjetivos, categoría cantidad.	41
Tabla 4-18 Taxonomía de adjetivos, categoría dificultad.	41
Tabla 4-19 Taxonomía de adjetivos, categoría cualidad.	42
Tabla 4-20 Taxonomía de adjetivos, categoría percepción.	42
Tabla 4-21 Taxonomía de adjetivos, categoría valor.	42
Tabla 4-22 Taxonomía de adjetivos, categoría temperatura/clima.	43
Tabla 4-23 Taxonomía de verbos, categoría gusto/preferencia.	43
Tabla 4-24 Taxonomía de sustantivos adjetivados.	43
Tabla 4-25 Taxonomía adverbios, categoría cantidad.	43
Tabla 4-26 Taxonomía adverbios, categoría intensidad.	43
Tabla 4-27 Taxonomía de adverbios, categoría modo.	44
Tabla 5-1 Número de ocurrencias por cada una de las reglas y patrones.	50
Tabla 5-2 Categorías de sentimientos.	51
Tabla 5-3 Métricas discriminadas por sentimiento.	52

Lista de abreviaturas

<i>Abreviatura</i>	<i>Término</i>
<i>O</i>	Oración
<i>D</i>	Determinante
<i>AD</i>	Adjetivo
<i>A</i>	Adverbio
<i>P</i>	Preposición
<i>V</i>	Verbo
<i>S</i>	Sustantivo
<i>SN</i>	Sintagma Nominal
<i>SV</i>	Sintagma Verbal
<i>API</i>	<i>Application Programming Interface</i>
<i>NLTK</i>	<i>Natural Language Toolkit</i>
<i>JSON</i>	<i>JavaScript Object Notation</i>

1.Introducción

El análisis de sentimientos es el campo de estudio que permite analizar las opiniones, sentimientos, valoraciones, actitudes y emociones de los usuarios en un texto dado. Para este fin, el texto se puede clasificar en varias categorías, siendo positivo, negativo y neutral las más comunes (Tellez *et al.*, 2017; Pozzi *et al.*, 2017). El análisis de sentimientos se extiende fuera de la informática a ciencias de la administración y ciencias sociales, debido a su importancia en los negocios y en la mayoría de las dinámicas sociales, económicas, políticas, laborales y financieras (Neppalli *et al.*, 2017; Al Mohanna & Al-Khalifa, 2014; Jose & Chooralil, 2015; Liu *et al.*, 2018; Im *et al.*, 2013; Pozzi *et al.*, 2017), ya que las opiniones son fundamentales en casi todas las actividades humanas y son factores importantes de influencia en los comportamientos, las creencias, percepciones y decisiones que establecen la forma en que otros ven y evalúan el mundo (Pozzi *et al.*, 2017).

Twitter se está transformando en una fuente valiosa de datos. Esta herramienta de *microblogging* social contiene mensajes cortos instantáneos denominados tuits, que son publicaciones de 280 caracteres o menos. Los usuarios publican regularmente sobre temáticas actuales y proveen sus puntos de vista sobre diferentes temas. Twitter contiene una enorme cantidad de publicaciones de contenido y se desarrolla cada día (Algur & Patil, 2017; Murthy, 2013). Debido a lo anterior, esta herramienta tiene gran acogida en el tema de análisis de sentimientos, ya que es una fuente ideal de información para extraer estadísticas sociales, pues permite opinar de manera breve y concisa sobre cualquier tema (Algur & Patil, 2017).

El análisis de sentimientos enfrenta desafíos en entornos no controlados y con vocabularios genéricos como el que se encuentra en las redes sociales. El lenguaje natural que utilizan los seres humanos al comunicarse posee desafíos que disminuyen la capacidad de las herramientas utilizadas para el análisis de sentimientos (Gelbukh & Sidorov, 2010; Zapata & Rosero, 2008). Entre estos desafíos se encuentra la ambigüedad

de los mensajes, la polisemia y sinonimia y la necesidad de una mayor intervención y transformación antes de ser útiles como punto de partida para la automatización del razonamiento (Zapata & Rosero, 2008; Glynn & Robinson, 2014; Gelbukh & Sidorov, 2010). Dado que en los algoritmos la capacidad de procesamiento del lenguaje es limitada, es necesario crear un puente que haga posible la conexión entre el lenguaje natural y el lenguaje que se interpreta con los algoritmos (Zapata & Rosero, 2008). Para hacer este puente, desde la lingüística computacional se proponen los denominados lenguajes controlados. Según Mitamura y Nyberg (1995), un lenguaje controlado es un subconjunto del lenguaje natural con sintaxis, semántica y terminología restringidas (Gelbukh & Sidorov, 2010; Zapata & Rosero, 2008). En un lenguaje controlado se reduce la ambigüedad y se usa una representación lógica que aporta precisión y ayuda en el análisis por medio de las reglas morfosintácticas y la estandarización del mensaje (Zapata & Rosero, 2008). Al utilizar estos lenguajes controlados se transforman las opiniones de los usuarios en representaciones aptas para razonar y tomar decisiones (Zapata & Rosero, 2008).

La connotación y la denotación desempeñan un papel vital en el aprendizaje y comprensión del lenguaje. La connotación implica interpretación, que se da en el contexto, remite a otras ideas no presentes en la denotación y permite expresar sentimientos y emociones. Es decir, las personas aportan sus experiencias sociales y culturales que aprenden a lo largo del tiempo para dar una asociación de sentimiento positivo o negativo a una palabra. Por otro lado, la denotación alude directamente al objeto referido, tiene un significado universal y es una forma de expresión formal y objetiva. Es por esto que dos expresiones pueden tener el mismo significado denotativo pero diferente significado connotativo (Czeżowski, 1979).

En el análisis sintáctico se construye la estructura de la oración de un lenguaje gráfico. Su tarea principal es describir cómo las palabras de la oración se relacionan y cuál es la función que cada palabra realiza en la oración (Bird *et al.*, 2009; Gelbukh & Sidorov, 2010; Chomsky, 1965). Las posibles frases de un lenguaje natural se tratan como secuencias gramaticales. Además, con este análisis se puede realizar la verificación de las distintas reglas de formación de un lenguaje. Los resultados de dicho análisis se pueden representar gráficamente mediante una estructura jerárquica o de árbol (Gelbukh & Sidorov, 2010; Chomsky, 1965).

En la minería de opinión se considera el preprocesamiento de datos como una etapa esencial del proceso de descubrimiento de información, debido a que el uso de datos de baja calidad implica un proceso de análisis con pobres resultados. En esta intervención y transformación se realizan los siguientes pasos: tokenización, en la que se divide la información en palabras individuales; eliminación de datos ruidosos, específicamente emoticones, *hashtags* (Algur & Patil, 2017), caracteres especiales, hipervínculos o etiquetas HTML; eliminación de palabras de jerga, las cuales se reemplazan con palabras con mayor significado para el análisis, debido a que las palabras de jerga no se encuentran en los diccionarios; corrección ortográfica, en la que se corrigen las palabras mal escritas, debido a que pueden cambiar totalmente el significado de una oración; y por último, *stemming*, en el cual se convierten las palabras en palabras raíz (Gharatkar *et al.*, 2017).

En las aproximaciones encontradas en la literatura para el análisis de sentimientos se encuentran los métodos basados en léxico, los cuales se basan en el supuesto de que la polaridad general de una oración o documento es la suma de las polaridades de las frases o palabras individuales. Gran parte de la investigación basada en el léxico se centra en el uso de adjetivos como indicadores de la orientación de la polaridad de un texto. Para ello se utilizan los diccionarios, los cuales contienen palabras etiquetadas con polaridades que indican un sentimiento (Hulliyah *et al.* 2017; Ashna & Sunny, 2017).

Las opiniones no estructuradas representan una de las mayores dificultades en el análisis de sentimientos en redes sociales. En los métodos encontrados en la literatura se utilizan diccionarios y tareas de preprocesamiento de datos (Gatti *et al.*, 2016; Xia *et al.*, 2014; Jose & Chooralil, 2015; Akundi *et al.*, 2018; Mishra *et al.*, 2016). Debido a que los enfoques que incluyen diccionarios se basan en la suma de la polaridad de las palabras, estos métodos fallan a la hora de relacionar términos y analizar el contexto en que las palabras se escriben (Khan *et al.*, 2015). Además, el preprocesamiento para eliminar los datos ruidosos implica un trabajo minucioso antes de analizar los datos y se pierde parte de la información que puede ser relevante a la hora de definir la polaridad de un mensaje.

Debido a la falta de un lenguaje controlado en las redes sociales, antes de utilizar los algoritmos y las herramientas especializadas para análisis de sentimientos se debe intervenir y transformar el mensaje. Este preprocesamiento del mensaje se hace necesario ya que el lenguaje natural posee características que plantean desafíos en su análisis

computacional. Estas características son la polisemia, dada la variedad de significados que tiene una misma palabra en el vocabulario y, además, sinonimia, dado que varias palabras pueden tener un significado similar o idéntico, pero escritura y ortografía diferente (Glynn & Robinson, 2014). Estos dos aspectos inherentes al lenguaje natural dificultan la identificación y validación en las opiniones de los usuarios.

En esta Tesis de Maestría se define un lenguaje controlado para el análisis de sentimientos en Twitter para mensajes en inglés. El flujo de trabajo que se utiliza para lograr este fin consta de los siguientes pasos: adquisición de los tuits, tokenización, etiquetado gramatical de las palabras, identificación de patrones del lenguaje controlado en las oraciones y, por último, polarización del mensaje teniendo en cuenta la taxonomía de adjetivos, sustantivos adjetivados, adverbios y verbos. Se proponen seis patrones y cuatro reglas sintácticas que permiten formalizar la estructura del lenguaje natural. Además, se proponen diez grupos de adjetivos, un grupo de verbos, un grupo de sustantivos adjetivados y tres grupos de adverbios que son indispensables para la polarización.

Una vez se implementa el lenguaje controlado, las palabras adquieren valor sintáctico, lo cual permite relacionar términos y analizar el contexto en el que las palabras se escriben. Además, después de pasar por las reglas morfosintácticas de un lenguaje controlado, los mensajes son más precisos e inequívocos y, por consiguiente, son útiles como punto de partida para la automatización del razonamiento. El lenguaje controlado permite realizar restricciones para simplificar la estructura del mensaje y estandarizar su terminología y formato, lo cual permite representar los conceptos de forma unívoca y sin ambigüedades.

Esta Tesis de Maestría se organiza así: en el Capítulo 2 se presenta el marco teórico que abarca el análisis de sentimientos, Twitter, lenguaje controlado, lenguaje natural, connotación, denotación, análisis sintáctico y preprocesamiento de datos; en el Capítulo 3 se exponen los acercamientos a los métodos basados en léxico, específicamente los basados en diccionario que se proponen en la literatura; en el Capítulo 4 se propone el lenguaje controlado y la polarización de mensajes teniendo en cuenta taxonomías de adjetivos, sustantivos adjetivados, adverbios y verbos; en el Capítulo 5 se presenta la validación de la propuesta de la solución mediante una base de datos encontrada en la

literatura; finalmente, en el Capítulo 6 se plantean las conclusiones y el trabajo futuro a partir de esta Tesis de Maestría.

2.Marco teórico

El objetivo de este Capítulo es presentar los aspectos teóricos que permiten contextualizar el tema de investigación de esta Tesis de Maestría. Primero, se abarca la descripción del análisis de sentimientos y sus aplicaciones. Luego, se relata la dinámica que utilizan los usuarios de Twitter para dar sus opiniones frente a diferentes temas. A continuación, se presenta el lenguaje natural y sus respectivos retos, además, como una alternativa de solución para dichos retos, se introduce el lenguaje controlado. Seguido a esto, se detalla el preprocesamiento de datos que se utiliza comúnmente en los métodos de análisis de sentimientos. Luego, se describe la connotación y la denotación con el fin de dar contexto sobre los significados que tienen las palabras en un vocabulario. Por último, se presenta el análisis sintáctico donde se describe la función que realizan las palabras dentro de una oración.

2.1 Análisis de sentimientos

El análisis de sentimientos tiene como objetivo definir herramientas automáticas capaces de extraer información subjetiva de textos en lenguaje natural, con el fin de crear conocimiento estructurado y accionable para utilizarlo en la toma de decisiones (Pozzi *et al.*, 2017). Para este fin, las categorías más comunes para clasificar el texto son positivo, negativo y neutral (Tellez *et al.*, 2017).

En la literatura, se encuentran aplicaciones del análisis de sentimientos en cinco campos:

- **Social:** en la literatura de análisis de sentimientos se encuentran aplicaciones en el campo de respuesta a desastres; hacer que los datos de las redes sociales sean útiles para los servicios de emergencia es uno de los focos de investigación. Las personas que están en el sitio de un desastre están en una posición única para compartir información y pueden tener conocimiento sobre las características

geográficas o culturales del área afectada. Además, pueden ser útiles para aquellos que responden fuera del área (Neppalli *et al.*, 2017). Neppalli *et al.* (2017) realizan un análisis de sentimientos de las publicaciones de los usuarios en Twitter durante el huracán Sandy y visualizan los sentimientos en un mapa geográfico centrado alrededor del huracán. En el estudio se muestra cómo los sentimientos de los usuarios cambian con su ubicación y en función de la distancia relativa al desastre.

- **Económico:** las empresas necesitan encontrar y analizar las opiniones de los consumidores sobre sus productos o servicios. Conocer las opiniones de los usuarios respecto de un producto específico también es interesante para los consumidores individuales, ya que esta información es útil para decidir si se compra el producto o servicio (Pozzi *et al.*, 2017). Al Mohanna y Al-Khalifa (2014) estudian un sitio web de reseñas de restaurantes árabes ubicados en Arabia Saudita. Las puntuaciones ponderadas que se manejan en este sitio para los restaurantes se derivan del número de “me gusta” y “no me gusta”. Los autores investigan la correlación entre la puntuación ponderada calculada y la puntuación derivada del análisis del sentimiento de las revisiones. Los autores parten del hecho de que las personas tienen en cuenta la cantidad de “me gusta” y “no me gusta” de los restaurantes y el contenido de las reseñas. Al final, los autores descubren que los sentimientos tienen un efecto sobre la posición de un restaurante en la lista de los mejores.
- **Político:** en el mundo de la política existe una nueva forma de comunicación entre los candidatos y los votantes gracias a las redes sociales. Las redes sociales brindan la oportunidad de que se comparta información relacionada con las elecciones. Por ejemplo, en las elecciones presidenciales de 2008 en Estados Unidos, Barack Obama utiliza el análisis de sentimientos como estrategia de campaña para evaluar los sentimientos de los votantes (Pozzi *et al.*, 2017). Jose y Choorail (2015) extraen tuits sobre dos candidatos durante tres semanas en los días de las elecciones de 2015. Los autores emplean *SentiWordNet*, *WordNet* y desambiguación del sentido de las palabras para encontrar sentimientos políticos a partir de tuits en tiempo real. Al final, la técnica muestra una precisión del 78.6%.

- **Laboral:** en la literatura de análisis de sentimientos se encuentran aplicaciones en el campo de la atención médica. El análisis y resolución de problemas en los sistemas de registro de citas médicas son de gran importancia para mejorar la calidad de los servicios hospitalarios y mejorar la experiencia de los pacientes (Liu *et al.*, 2018). Es por esto que Liu *et al.* (2018) utilizan el análisis de sentimientos para mejorar el sistema de reservaciones de un hospital de acuerdo con la experiencia del usuario, con el fin de mejorar la calidad del servicio del hospital. Para esto, las opiniones e inquietudes de los usuarios se analizan utilizando el método del diccionario de sentimientos.
- **Financiero:** el análisis de sentimientos se usa para medir el estado de ánimo y la percepción del mercado y para respaldar el análisis de eventos financieros a gran escala. En la mayoría de los casos, las noticias financieras y de negocios pueden afectar indirectamente el rendimiento de una acción en particular. Sin embargo, es necesario analizar varios artículos de noticias para llegar a una determinada decisión de compra o venta (Im *et al.*, 2013). Es por esto que Im *et al.* (2013) presentan un enfoque basado en léxico utilizado para análisis de sentimientos en noticias financieras, para polaridades positivas y negativas.

En la Figura 2-1 se presentan datos de *Google Trends* relacionados con el volumen de búsquedas afines con el análisis de sentimientos a lo largo de los años. Con estos datos se demuestra el interés continuo sobre este campo.




Figura 2-1 Interés a lo largo del tiempo sobre el análisis de sentimientos.

Fuente: *Google Trends* (<https://www.google.com/trends>).

2.2 Twitter

Twitter es una herramienta de *microblogging* social que permite a usuarios tener una conversación pública mediante el uso de mensajes de 280 caracteres o menos. El *microblogging* es una variante de los *blogs* y su principal diferencia radica en la brevedad de sus mensajes y en su facilidad de publicación. El objetivo de Twitter es que los usuarios respondan en un mensaje a la pregunta “¿qué está pasando?”. Estos mensajes, denominados tuits, se publican automáticamente en el perfil del usuario. Además, el usuario puede decidir si lo que comparte lo hace público. Asimismo, el mensaje se envía automáticamente a todos sus seguidores, es decir, a todos los usuarios que escogen la opción de recibirlos. El lenguaje que utilizan los usuarios en Twitter incluye algunas herramientas que provee este *microblogging* social, las cuales son los prefijos “@” y “#”, que cumplen un papel importante en la dinámica de las conversaciones de los usuarios (Algur & Patil, 2017; Murthy, 2013). Un usuario puede emplear Twitter para conectarse con otras personas y enviar mensajes. Cuando una persona quiere dirigir un tuit a otra persona u organización, se debe utilizar el prefijo “@” seguido del nombre del usuario objetivo (Algur & Patil, 2017). Twitter tiene métodos simples para conectar tuits con temas más grandes. Se puede utilizar el carácter “#” precediendo una palabra que alude a un tema, evento o asociación. A eso se le llama *hashtag*, que es una parte importante de Twitter y se utiliza para vincular conversaciones de extraños. Al incluir un *hashtag* en el tuit, el mensaje se incluye en una conversación más amplia que consiste en la recopilación todos los tuits con el mismo *hashtag*. La estructura de comunicación mediante *hashtags* facilita las interacciones improvisadas de usuarios en estas conversaciones. Como los *hashtags* representan una agregación de tuits etiquetados, las conversaciones se crean de manera más orgánica (Algur & Patil, 2017).

En Twitter se utilizan algoritmos para detectar qué temas son los que están recibiendo más menciones con los *hashtags* y, por lo tanto, los que los usuarios más comentan. El termino *trending topic* en Twitter significa que mucha gente está escribiendo comentarios sobre lo que está pasando acerca de ese tema. Debido a lo anterior, Twitter se está convirtiendo en una fuente notable de datos, ideal para extraer información con análisis de sentimientos (Algur & Patil, 2017; Murthy, 2013).

2.3 Lenguaje natural

El lenguaje natural es la lengua que normalmente utilizan los individuos para comunicarse entre sí y expresar conocimiento. El lenguaje natural tiene una gran riqueza comunicativa, flexibilidad y gran cantidad de combinaciones entre palabras y expresiones. Sin embargo, este lenguaje es demasiado complejo para ser útil como punto de partida para la automatización del razonamiento; además, no es un producto idóneo para áreas donde se requiera exactitud y precisión. El lenguaje natural es altamente informal, por lo cual posee problemas en cuanto a ambigüedad, presenta desafíos referentes a la polisemia y sinonimia e implica mayor intervención y transformación para posteriores análisis (Gelbukh & Sidorov, 2010; Zapata & Rosero, 2008).

- **Ambigüedad:** todos los lenguajes naturales conocidos en todos sus niveles presentan ambigüedad. La ambigüedad ocurre cuando una entrada puede tener más de una interpretación. Este problema impide que con un sistema se hagan las inferencias necesarias para comprender lo que se quiere decir. La ambigüedad se produce cuando cada nivel del lenguaje (palabras, oraciones y texto) se consideran fuera del contexto. Es por esto que el principal problema de la ambigüedad radica en que algo puede tener varios sentidos y no está claro cuál sentido se usa en el contexto (Gelbukh & Sidorov, 2010; Zapata & Rosero, 2008).

Gelbukh y Sidorov (2010) presentan dos ejemplos para explicar la ambigüedad:

- La oración “veo al gato con el telescopio” se puede interpretar de dos maneras: alguien usa el telescopio para ver al gato o alguien ve al gato que tiene el telescopio.
- La palabra “fuera” se puede interpretar como:
 - La forma morfológica de ser: como si fuera esta noche la última vez. Subjuntivo, tercera persona, singular.
 - La forma morfológica de ir: como si se fuera a la escuela. Subjuntivo, tercera persona, singular.

- Adverbio: está fuera de la ciudad.
- **Polisemia:** según Glynn y Robinson (2014), una palabra es polisémica si se necesita más de una definición para explicar su significado. Un ejemplo de esto es: Banco → tipo de silla o entidad financiera.
- **Sinonimia:** según Glynn y Robinson (2014) dos palabras tienen sinonimia si al reemplazar una palabra por la otra, no cambia el significado semántico de la frase. Un ejemplo de esto es: Esposo/marido.
- **Intervención y transformación:** con el fin de crear un puente que haga posible la conexión entre el lenguaje natural y el lenguaje que interpretan los algoritmos, es necesario intervenir y transformar el lenguaje natural en una representación precisa e inequívoca. Para esto, se utilizan los lenguajes controlados (Zapata & Rosero, 2008).

2.3.1 Lenguaje controlado

Según Mitamura y Nyberg (1995), un lenguaje controlado es un subconjunto del lenguaje natural con sintaxis, semántica y terminología restringidas. Los lenguajes controlados se deben especificar a partir de bloques de construcción muy simples; esta representación ayuda a captar la estructura intuitiva del lenguaje natural, que debe ser precisa e inequívoca.

- **Sintaxis:** la sintaxis se dedica a analizar las relaciones entre las palabras dentro de la frase (Gelbukh & Sidorov, 2010).
- **Semántica:** con la semántica se pretende entender la frase. Hay que definir el sentido de todas las palabras e interpretar las relaciones sintácticas. Los resultados de la definición de los sentidos de las palabras existen en forma de diccionarios (Gelbukh & Sidorov, 2010).
- **Terminología restringida:** elementos propios del lenguaje natural como palabras, reglas y puntuaciones representadas de manera limitada y formal (Gelbukh &

Sidorov, 2010). Un lenguaje controlado incluye un glosario definido y unas reglas de escritura de la documentación. Lo anterior conlleva a una reducción importante en fenómenos lingüísticos indeseables como la ambigüedad (Zapata & Rosero, 2008).

Un lenguaje controlado debe ser lo suficientemente rico para poder expresar todo el conocimiento, pero lo suficientemente simple para ser útil en un posterior análisis mediante un computador y lo suficientemente conciso para evitar ambigüedades y redundancias. Por ejemplo, las oraciones que parecen ser estructuralmente similares deben tener representaciones estructurales similares y los significados de dos oraciones que son paráfrasis entre sí se deben relacionar estrechamente entre sí (Gelbukh & Sidorov, 2010). Para la creación del lenguaje controlado se requiere un análisis previo, que es lo que se suele hacer en la actualidad con un proceso manual y subjetivo (Zapata & Rosero, 2008). Algunas razones para la utilización de lenguajes controlados son, entre otras:

- Reduce la ambigüedad.
- Es una representación lógica.
- Aporta precisión.
- Ayuda en el análisis.

Todo eso se logra con la consistencia y estandarización de la terminología, con la simplificación de la estructura de la oración y con la estandarización del formato para la creación del documento (Zapata & Rosero, 2008).

2.3.2 Preprocesamiento de datos

En el análisis de sentimientos, el preprocesamiento de datos se considera una etapa esencial del proceso de descubrimiento de información. Con el preprocesamiento se preparan los datos que se utilizan en un posterior análisis. La justificación de este proceso radica en que los datos se encuentran con ruidos y/o inconsistencias (Gharatkar *et al.*, 2017) ya que el lenguaje natural que utilizan los usuarios en redes sociales se caracteriza

por su género informal y su estilo de escritura libre. En la Figura 2-2 se presenta el diagrama de flujo del preprocesamiento de datos.




Figura 2-2 Diagrama de flujo del preprocesamiento de datos.

Fuente: Elaboración propia a partir de Gharatkar *et al.* (2017).

2.3.1.1 Tokenización

Es el proceso de dividir la secuencia de la cadena en palabras individuales, palabras clave, frases y símbolos llamados *tokens* (Gharatkar *et al.*, 2017). En la Figura 2-3 se presenta un ejemplo de la tokenización.

“This is a coool #dummysmile: -): -P <3 and some arrows < > -> <-”



[‘This’, ‘is’, ‘a’, ‘coool’, ‘#dummysmile’, ‘:’, ‘:-)’ ,
‘:-P’, ‘<3’, ‘and’, ‘some’, ‘arrows’, ‘<’, ‘>’, ‘->’, ‘<-’]

Figura 2-3 Ejemplo de tokenización.

Fuente: Adaptado de Gharatkar *et al.* (2017).

2.3.1.2 Eliminación de datos ruidosos

La cadena de texto puede contener datos ruidosos. En este paso se eliminan emoticones, *hashtags*, caracteres especiales e hipervínculos o etiquetas HTML (Gharatkar *et al.*, 2017). En la Figura 2-4 se presenta un ejemplo de la eliminación de datos ruidosos.

```
['This', 'is', 'a', 'coool', '#dummysmiley', ':', ':-)',  
':-P', '<3', 'and', 'some', 'arrows', '<', '>', '->', '<-']
```



```
["This", "is", "a", "cooooI", "dummysmiley", "P", "3",  
"and", "some", "arrows", ""]
```

Figura 2-4 Ejemplo de eliminación de datos ruidosos.

Fuente: Adaptado de Gharatkar *et al.* (2017).

- **Emoticones:** son imágenes o signos digitales que representan un sentimiento o estado de ánimo de una persona. Ejemplo: 😊 😐 😞
- **Hashtags:** herramienta otorgada por Twitter que consiste en el carácter “#” precediendo una palabra que alude a un tema, evento o asociación (Algur & Patil, 2017). Ejemplo: #Twitter.
- **Caracteres especiales:** tipo de dato que no pertenece a los datos alfanuméricos. Ejemplo: @i\$%^&*()_+=
- **Hipervínculos:** cadena de texto que permite enlazar páginas web. Ejemplo: www.twitter.com

2.3.1.3 Eliminación de palabras de jerga

En este paso se eliminan las palabras de jerga que se encuentran dentro de la cadena de texto. Las palabras de jerga no existen en los diccionarios comunes y su significado es diferente, por lo tanto, estas palabras se reemplazan por otras que tengan mayor sentido y significado correcto para un mejor análisis. En ocasiones, se utilizan diccionarios especializados en palabras de jerga que contienen su significado (Gharatkar *et al.*, 2017). Ejemplos:

- **Headdesk**: frustración suprema.
- **Facepalm**: abreviatura de "Ugh, idiota".

2.3.1.4 Corrección ortográfica y eliminación de palabras

Se corrigen las palabras mal escritas en la cadena de texto, ya que éstas pueden cambiar completamente el significado de una oración. Además, se eliminan los *stop words*, que son palabras que carecen de significado por sí solas. Este último paso se hace porque se considera que no son necesarias para un posterior análisis (Gharatkar *et al.*, 2017). En la Figura 2-5 se presenta un ejemplo de corrección ortográfica y eliminación de palabras.

“‘This’, ‘is’, ‘a’, ‘cooooI’, ‘dummysmiley’, ‘P’, ‘3’,
‘and’, ‘some’, ‘arrows’,”



‘This’, ‘cool’, ‘dummy’ ‘smiley’, ‘some’, ‘arrows’,

Figura 2-5 Ejemplo de corrección ortográfica y eliminación de palabras.

Fuente: Adaptado de Gharatkar *et al.* (2017).

2.3.1.5 Stemming

En este paso se convierten los *tokens* o palabras en palabras raíz. Para hacer esto, en las reglas normales se eliminan, ed, e, es y ly, entre otras (Gharatkar *et al.*, 2017). Ejemplo: *runned* – *run*.

2.4 Connotación

El término connotación implica interpretación, que se da por el contexto y permite expresar sentimientos y emociones. Es decir, se utiliza para referirse a la interpretación sociocultural y personal que una persona le da a una palabra. La connotación es, a menudo, de naturaleza emocional y asociación imaginativa y, por lo tanto, tiene el propósito de influir en las reacciones emocionales de una persona. Además, la connotación remite a otras ideas no presentes en la denotación. Es decir, es la mezcla del conocimiento enciclopédico

de una palabra y las asociaciones emocionales que le da la persona (Czeżowski, 1979).
Ejemplo: Corazón → Connotación: El corazón es el símbolo del amor y el afecto.

2.5 Denotación

El termino denotación se utiliza para referirse al significado explícito de una palabra con una forma de expresión formal y objetiva. Es el significado universal que reconocen todas las personas que hablan una misma lengua; por lo tanto, se extiende más allá del contexto en el que se emplea, sin que se generen interpretaciones erróneas (Czeżowski, 1979).
Ejemplo: Corazón → Denotación: Órgano muscular que bombea sangre.

2.6 Análisis sintáctico

El análisis sintáctico se ocupa de la formación y estructura de las oraciones, para describir cómo las palabras de la oración se relacionan y cuál es la función que se asigna a cada palabra, con el fin de dar lugar a una oración bien formada, regularizando su estructura. Los resultados de dicho análisis se pueden representar gráficamente mediante de una estructura jerárquica o de árbol (Gelbukh & Sidorov, 2010; Chomsky, 1965).

Una de las representaciones gráficas del análisis sintáctico es el árbol de constituyentes. Según Gelbukh y Sidorov (2010), en el árbol de constituyentes las oraciones se analizan mediante un proceso de segmentación y clasificación. El primer paso es dividir la oración en palabras individuales; a estas palabras se les asigna la categoría gramatical a la que pertenecen. Luego, estas palabras se agrupan en sus partes constituyentes mediante reglas de producción; este último paso se repite cuantas veces sea necesario hasta que no haya más constituyentes por formar (Gelbukh & Sidorov, 2010; Chomsky, 1965). En la Figura 2-6 se presenta un ejemplo del árbol de constituyentes.




Figura 2-6 Ejemplo árbol de constituyentes.

Fuente: Chomsky (1965).

Las categorías gramaticales que se emplean para crear el árbol de constituyentes son las siguientes:

- **Oración (O):** conjunto de palabras que contiene un sentido completo (Chomsky, 1965). Ejemplo: El perro come el hueso.
- **Determinante (D):** se utiliza para aportar información de los sustantivos. Ejemplo: la, mi, ese, etc. (Bird *et al.*, 2009).
- **Adjetivo (AD):** se usa para describir sustantivos y se pueden usar como modificadores o predicados. Ejemplos: nuevo, bueno, alto, etc. (Bird *et al.*, 2009).
- **Adverbio (A):** se usa para modificar verbos para especificar el tiempo, modo, lugar o la dirección del evento. Los adverbios también pueden modificar adjetivos. Ejemplos: todavía, temprano, ahora, etc. (Bird *et al.*, 2009).
- **Preposición (P):** se usa para enlazar dos palabras u oraciones, y expresar la relación entre ellas. Ejemplos: en, de, por, etc. (Bird *et al.*, 2009).

- **Verbo (V)**: se usa para describir eventos y acciones. Ejemplos: conseguir, correr, ver, etc. (Bird *et al.*, 2009).
- **Sustantivo (S)**: se refiere a personas, lugares, cosas o conceptos. Ejemplos: casa, paloma, audífonos, etc. (Bird *et al.*, 2009).
- **Sintagma Nominal (SN)**: unidad sintáctica que tiene como núcleo un sustantivo (Chomsky, 1965). Ejemplo: El perro.
- **Sintagma Verbal (SV)**: unidad sintáctica que tiene como núcleo un verbo (Chomsky, 1965). Ejemplo: Come el hueso.

Algunas de las reglas de formación para el árbol de constituyentes son (Chomsky, 1965):

- $O \rightarrow SN\ SV$
- $SV \rightarrow V\ SN$
- $SN \rightarrow D\ N$

3. Antecedentes

En las aproximaciones encontradas en la literatura para análisis de sentimientos, se encuentran los métodos basados en léxico. El enfoque basado en el léxico parte del supuesto de que la polaridad general de una oración o documento es la suma de las polaridades de las frases o palabras individuales. Este método se basa en encontrar la polaridad del texto al referirse al léxico o los diccionarios. Estos léxicos o diccionarios permiten identificar la etiqueta positiva, negativa o neutral y en algunas ocasiones puntajes de sentimientos para definir la polaridad de cada palabra. Además, se pueden crear de forma manual o automática con la ayuda de palabras clave (Ashna & Sunny, 2017; Hulliyah *et al.*, 2017). En la Figura 3-1 se presentan de forma esquemática las técnicas de clasificación de sentimientos. Algunos de los diccionarios que se utilizan para este fin son:

- **SentiWordNet:** es un recurso léxico en inglés que incluye *synsets* que se asocian con tres puntajes numéricos Obj(s), Pos(s) y Neg(s) que van de 0 a 1, con los cuales se describe qué tan objetivo, negativo y positivo es cada *synset*. *SentiWordNet* aumenta a *WordNet* con información de sentimiento, es decir, agrega las tres puntuaciones descritas a cada elemento de *WordNet*. Está disponible gratuitamente para fines de investigación y tiene una interfaz gráfica de usuario basada en la Web (Gatti *et al.*, 2016).
 - **WordNet:** es un diccionario que agrupa palabras en inglés en conjuntos de sinónimos llamados *synsets* e incluye definiciones cortas y ejemplos de uso. *WordNet* incluye adjetivos, sustantivos, verbos y adverbios. Este diccionario no tiene información de sentimiento (Gatti *et al.*, 2016).
- **SentiWords:** es un recurso léxico que contiene palabras en inglés asociadas con una puntuación de sentimiento incluida entre -1 y 1. Las puntuaciones se relacionan con *SentiWordNet* y las palabras se alinean con *WordNet* (Gatti *et al.*, 2016).

- **SenticNet:** es un recurso léxico que contiene conceptos de una o varias palabras en inglés, junto con una puntuación de polaridad cuantitativa en el rango de -1 a 1 (Xia *et al.*, 2014).




Figura 3-1 Técnicas de clasificación de sentimientos.

Fuente: Adaptado de Hulliyah *et al.* (2017).

En los métodos encontrados en la literatura se utilizan diccionarios y tareas de preprocesamiento de datos:

Jose y Choorailil (2015) proponen una aplicación de análisis de sentimientos en las elecciones de Delhi del 2015. Los tres módulos del sistema son:

- **Adquisición de datos:** los autores utilizan una API (*Application Programming Interface*) de Twitter para acceder en tiempo real a los tuits relacionados con las elecciones en Delhi.
- **Preprocesamiento:** los autores identifican y eliminan URL, nombres de usuario con la forma @nombredeusuario, *hashtags* y caracteres especiales
- **Clasificación del sentimiento:** los autores clasifican las opiniones de los usuarios utilizando SentiWordNet y WordNet.

El resultado final es la comparación del sentimiento que tienen las personas hacia dos políticos en las elecciones en Delhi, donde se extraen 12000 tuits y se calcula el puntaje total de sentimientos positivos y negativos. La arquitectura propuesta se puede observar en la Figura 3-2.




Figura 3-2 Arquitectura propuesta en elecciones en Delhi de enfoque basado en diccionario.

Fuente: Adaptado de Jose y Chooralil (2015).

Akundi *et al.* (2018) proponen una aplicación de análisis de sentimientos para comprender cómo los tuits sobre teléfonos inteligentes (Apple, Samsung y Huawei) pueden influir cuando los usuarios hacen una compra. La arquitectura propuesta se puede observar en la Figura 3-3. Los autores identifican los *hashtags* relevantes de los teléfonos inteligentes: #iPhone, #Samsung y #Huawei, los cuales se utilizan en un inicio para buscar los tuits. Sobre la base de datos de los tuits obtenidos, los *hashtags* se refinan aún más para capturar más tuits. Para limpiar los tuits obtenidos, los autores eliminan datos irrelevantes en el texto como puntuaciones, *stop words*, espacios en blanco, URL y números. Una vez se hace la limpieza de los tuits, estos se dividen en palabras para su posterior análisis. Las palabras de los mensajes se emparejan con un léxico de sentimiento. Además, para la polaridad del mensaje, se utiliza *SentiWord*. El resultado de la aplicación arroja para #iPhone 650 palabras de sentimiento, para #Samsung 1188 palabras de sentimiento y 496 palabras de sentimiento para #Huawei. Al finalizar, con el análisis de los tuits recogidos se

muestra que el sentimiento para Samsung y Huawei fue positivo en comparación con el de iPhone.




Figura 3-3 Arquitectura propuesta con teléfonos inteligentes de enfoque basado en diccionario.

Fuente: Adaptado de Akundi *et al.* (2018).

Mishra *et al.* (2016) proponen una aplicación de análisis de sentimientos para la campaña digital de Modi ji's en India. La arquitectura propuesta se puede observar en la Figura 3-4.

Para la recopilación de datos, los autores utilizan una API de Twitter con el *hashtag* #DigitalIndia. En la fase de preprocesamiento de datos, los autores utilizan NLTK (*Natural Language Toolkit*) para eliminar prefijos, *stop words* y realizar tokenización. En la extracción de características, los autores especifican el tipo de características utilizadas para el análisis de sentimientos, los diferentes tipos son: término de frecuencia, término de co-ocurrencia y *Part of Speech*. Por último, para la clasificación de la polaridad de los tuits, los autores utilizan *SentiWordNet*. Los resultados de la clasificación muestran que los autores recuperan 250 opiniones positivas, 150 neutrales y 100 negativas.




Figura 3-4 Arquitectura propuesta en caso de la India digital de enfoque basado en diccionario.

Fuente: Adaptado de Mishra *et al.* (2016).

Gayo-Avello (2013) y Metaxas *et al.* (2011) sentencian que el análisis de sentimientos basado en léxico es ligeramente mejor que un clasificador aleatorio. Para respaldar lo anterior, ponen como ejemplo, entre otros, un método basado en léxico propuesto por O'Connor *et al.* (2010).

O'Connor *et al.* (2010) discuten la posibilidad de utilizar los datos de Twitter como sustitutos de las encuestas tradicionales en predicciones electorales. Los dos pasos que utilizan para llegar a este objetivo son:

- Recuperación de mensajes: los autores identifican los mensajes relacionados con un tema que se quiera evaluar. Para esto, sólo usan los mensajes que contienen una palabra clave del tema.
- Estimación de opinión: los autores determinan si los mensajes recuperados, se basan en opiniones positivas o negativas sobre un tema en específico. O'Connor *et al.* (2010) obtienen los puntajes del sentimiento contando los mensajes positivos y negativos. Las palabras positivas y negativas se definen mediante el léxico de subjetividad de *OpinionFinder*, una lista de palabras que contiene

aproximadamente 1.600 y 1.200 palabras etiquetadas como positivas y negativas. Un mensaje se define como positivo si contiene una palabra positiva y negativo si contiene una palabra negativa. Los autores expresan que lo anterior da resultados similares al solo contar palabras positivas y negativas en un día dado, ya que los mensajes de Twitter son muy cortos.

En el método de O'Connor *et al.* (2010) se puede evidenciar que tiene los mismos problemas de los métodos de análisis de sentimiento tradicionales basados en léxico, donde se buscan palabras con polaridades sin tener en cuenta la estructura sintáctica de las oraciones que publican los usuarios.

Uno de los problemas que tienen estos métodos es que, si en una oración, por ejemplo, se mezclan varios sustantivos y varios adjetivos, al final no se tiene una trazabilidad de cual adjetivo está calificando a cuál sustantivo y se llega a una polaridad errónea del tema que se está evaluando. Por ejemplo, si se están buscando opiniones de un candidato a la presidencia llamado *Candidate1* y en la recuperación de mensajes se encuentra la siguiente oración:

Candidate2 is better than Candidate1.

Al momento de estimar la opinión se recupera la palabra “*better*” y se polariza como positiva; como en la recuperación de los mensajes se están buscando opiniones del *Candidate1*, es decir, oraciones que contengan la palabra “*Candidate1*”, se asevera que el mensaje es positivo para dicho candidato, lo cual se considera un error.

Otro de los desafíos que presentan estos métodos basados en léxico es la polisemia. Esto se presenta al no tener un análisis sintáctico que permita identificar las relaciones entre las expresiones que denotan sentimiento y los sustantivos. Por ejemplo, si se buscan opiniones del *Candidate1* y en la recuperación de mensajes se encuentra la siguiente oración:

Candidate1 talks like Candidate2.

En este caso, con el método se asevera que el mensaje es positivo al encontrar la palabra *like*, siendo esto un error ya que, por la estructura sintáctica de la oración, se puede evidenciar que “*like*” no denota sentimiento, sino que es una comparación.

En resumen, en las aproximaciones encontradas en la literatura para análisis de sentimientos, se encuentran los métodos basados en léxico que combinan el uso de diccionarios y preprocesamiento de datos para analizar las polaridades de los mensajes. Estas aproximaciones solo se enfocan en definir la polaridad mediante el uso de diccionarios, dejando a un lado una serie de análisis que son necesarios para trabajar con lenguajes naturales. Los diccionarios fallan a la hora de relacionar términos y analizar el contexto en el que las palabras se escriben (Khan *et al.*, 2015).

Debido a la falta de un lenguaje controlado, se requiere mayor intervención y transformación del mensaje. Esto se debe a que el lenguaje natural que utilizan los usuarios tiene características como la polisemia y sinonimia que plantean desafíos en el análisis computacional. Además, debido a la presencia de datos ruidosos, se debe hacer un preprocesamiento donde se pierde parte de la información que es relevante a la hora de definir la polaridad de un mensaje (Zapata & Rosero, 2008). En la Tabla 3-1 se presenta el resumen de los problemas y desafíos que se encuentran en la revisión de la literatura para análisis de sentimientos.

Problemas y desafíos	Jose y Chooralil (2015)	Akundi <i>et al.</i> (2018)	Mishra <i>et al.</i> (2016)	O'Connor <i>et al.</i> (2010)
Ausencia de relación de términos y análisis del contexto en que las palabras se escriben.	X	X	X	X
Presencia de polisemia.	X	X	X	X
Presencia de sinonimia.	X	X	X	X
Mayor intervención y transformación del mensaje.	X	X	X	
Pérdida de información.	X	X	X	X
Presencia de datos ruidosos.	X	X	X	

Tabla 3-1 Resumen de los problemas y desafíos presentes en la revisión de la literatura.

Fuente: Elaboración propia a partir de Khan *et al.* (2015); Zapata y Rosero (2008).

4.Propuesta de solución

En esta Sección se propone el lenguaje controlado para el análisis de sentimientos en Twitter para mensajes en inglés. Esta Sección se estructura así: en la Sección 4.1 se propone la estructura del sistema de análisis de sentimientos en Twitter para mensajes en inglés, en la Sección 4.2 se proponen las reglas sintácticas para el lenguaje controlado; finalmente, en la Sección 4.3 se propone la taxonomía de adjetivos, verbos, sustantivos adjetivados y adverbios que complementan el lenguaje controlado.

4.1 Estructura de la solución

La estructura del sistema que se utiliza para hacer el análisis de sentimientos se propone en el diagrama de flujo de la Figura 4-1 y se detalla seguidamente:

- La propuesta de la solución se realiza en Python.
- Adquisición de datos: se importa la base de datos con tuits.
- Lectura de archivos para la taxonomía: se leen los archivos donde se encuentran las palabras que conforman la taxonomía de adjetivos, verbos, sustantivos adjetivados y adverbios. Cada uno de estos archivos tiene palabras con su polaridad, ya sea positiva o negativa: (+) o (-) según sea el caso.
- Tokenización: para realizar la tokenización de los mensajes, se utiliza *TweetTokenizer* de la librería NLTK de Python.
- Etiquetado: se realiza etiquetado de las palabras con su respectivo rol sintáctico. Este paso es importante debido a que de él depende el éxito, al permitir la identificación de los patrones del lenguaje controlado. La correcta identificación de los patrones es directamente proporcional al buen etiquetado de las palabras. Para este fin se utiliza el *pos_tag* de NLTK de Python. La librería NLTK tiene restricciones en cuanto abreviaciones, ya que no incluye la respectiva etiqueta que le debe asignar. Es por esto que se debe hacer una fase de limpieza de los mensajes. En la Tabla 4-1 se detalla la conversión de las abreviaciones.

Abreviación	Conversión
isn't	is not
aren't	are not
wasn't	was not
weren't	were not
didn't	did not
doesn't	does not
don't	do not
haven't	have not
hasn't	has not

Tabla 4-1 Conversión de abreviaciones.

Fuente: Elaboración propia basada en Bird *et al.* (2009).

Existen algunas palabras que se etiquetan correctamente con la librería TweetTokenizer, pero se hace necesario una distinción más detallada además de la categoría gramatical. Por lo tanto, se utiliza una función que incluye dichas etiquetas y las reemplaza con una etiqueta más específica. En la Tabla 4-2 se detallan las palabras con sus respectivas etiquetas específicas.

Palabra	Etiqueta específica
no, not	NEG
is, are, was, were	TOBE
have, has, had	HAVE
do, does, did	DO
than	THAN
and	AND

Tabla 4-2 Etiquetas específicas para palabras.

Fuente: Elaboración propia basada en Bird *et al.* (2009).

- Para facilitar la búsqueda de los patrones, se reemplazan las etiquetas (que tienen más de una letra) con un carácter único de la A la Z. Al asignar la letra queda una oración convertida que se puede comparar con una expresión regular y así, encontrar los patrones propuestos.
- Identificación de patrones: Para esta fase se tienen tres ciclos:
 - Se recorren los mensajes de la base de datos.
 - En cada uno de esos mensajes se buscan todos los patrones propuestos en esta Tesis de Maestría. Cada uno de los patrones puede estar presente más de una vez en un mensaje.

- Para cada una de las oraciones identificadas con los patrones, se compara si cada oración hallada corresponde a la oración más larga que cumple cualquiera de los patrones. En caso de ser la oración más larga, se evalúa y se realiza, si es necesario, una subdivisión en oraciones más concretas de acuerdo con las reglas propuestas. Esta subdivisión se realiza para los patrones 2 y 3 de la regla 1 propuestos en la sección 4.2. A continuación, se detalla en pseudocódigo cómo se hace la subdivisión de oraciones en otras más concretas:

Negación = none

Para cada palabra en patrón encontrado hacer:

Si categoría(palabra) = TOBE, entonces:

VerboToBe = palabra

Si categoría(palabra) = NEG, entonces:

Negación = palabra

Obtener todos los sustantivos del patrón encontrado.

Obtener todos los adjetivos del patrón encontrado.

Para cada Sustantivo hacer:

Para cada una de las palabras anteriores al Sustantivo hacer:

Si categoría(palabra) != Sustantivo, entonces:

Determinante = none

break

de lo contrario, si categoría(palabra) = Determinante, entonces:

Determinante = palabra

break

de lo contrario:

continúe

Para cada Adjetivo hacer:

Para cada una de las palabras anteriores al Adjetivo hacer:

Si categoría(palabra) != Adjetivo, entonces:

Adverbio = none

break

de lo contrario, si categoría(palabra) = Adverbio, entonces:

Adverbio = palabra

break

de lo contrario:

continúe

VerboToBe = Cambiar tiempo y número gramatical.

OracionSubdividida= Armar oración (determinante, Sustantivo, VerboToBe, Negacion, Adverbio, Adjetivo)

Agregar OracionSubdividida a lista de OracionesSubdivididas.

- Polarización: se polarizan los mensajes, los patrones encontrados y las subdivisiones de las oraciones que salen de los patrones. En caso de que se tengan dos o más polaridades en una oración, se utilizan las reglas de las Tablas 4-3 y 4-4. Es decir, la polaridad de todas las oraciones subdivididas genera la polaridad del patrón encontrado; a su vez, la polaridad de los patrones encontrados da lugar a la polaridad del mensaje. En caso de que un mensaje no tenga los patrones propuestos en esta Tesis de Maestría, se le asigna polaridad neutral. En la Sección 4.2 se muestran con más detalle.
- Resultados: se retorna un JSON (*JavaScript Object Notation*) por cada mensaje en la base de datos. Los elementos más significativos de este JSON son: mensaje original, polaridad encontrada, polaridad original, patrones encontrados y oraciones subdivididas. En la Sección 5.1 se muestran ejemplos para cada una de las reglas.

XOR		
a	b	a <u>xor</u> b
+	+	+
+	-	-
-	+	-
-	-	+

Tabla 4-3Reglas XOR.

Fuente: Elaboración propia basada en Bird *et al.* (2009).

Negación	
a	$\neg a$
+	-
-	+

Tabla 4-4 Reglas para la negación.

Fuente: Elaboración propia basada en Bird *et al.* (2009).




Figura 4-1 Diagrama de flujo de la solución.

Fuente: Elaboración propia.

4.2 Reglas sintácticas para el lenguaje controlado

En la fase de identificación de las reglas sintácticas que componen el lenguaje controlado, se parte del supuesto de que las categorías gramaticales que expresan sentimientos son los adjetivos, adverbios, verbos y sustantivos adjetivados. Así, se procede a realizar una revisión de bases de datos de análisis de sentimientos en Twitter sobre diferentes temas. Para esta revisión se realiza el etiquetado de las palabras de las oraciones con su respectivo rol sintáctico, con el fin de identificar los patrones que siguen los usuarios a la hora de expresar sus opiniones. En el transcurso de dicha revisión se establecen las reglas sintácticas que se describen a continuación.

Para encontrar los patrones de las reglas sintácticas, se elaboran expresiones regulares. En la Tabla 4-5 se especifican las etiquetas utilizadas pertenecientes al *POS tag* de NLTK de Python.

Etiqueta	Significado
JJ	Adjetivo.
JJR	Adjetivo comparativo.
JJS	Adjetivo superlativo.
NN	Sustantivo singular.
NNS	Sustantivo plural.
NNP	Nombre propio singular.
NNPS	Nombre propio plural.
DT	Determinante.
PRP	Pronombre personal.
PRP\$	Pronombre posesivo.
VB	Verbo en presente.
VBD	Verbo en pasado.
VBZ	Verbo en presente, en tercera persona del singular.
VBP	Verbo en presente, no en tercera persona del singular.
NEG	Palabras no, not.
TOBE	Palabras is, are, was, were.
HAVE	Palabras have, has, had.
DO	Palabras do, does, did.
THAN	Palabra than.
AND	Palabra and.
RB	Adverbio.
RBR	Adverbio comparativo.
RBS	Adverbio superlativo.

Tabla 4-5 Etiquetas y significados para expresiones regulares.

Fuente: Elaboración propia basada en Bird *et al.* (2009).

Además, las cardinalidades de las palabras en las expresiones regulares se especifican con los operadores descritos en la Tabla 4-6.

Operador	Cardinalidad
*	Busca el carácter precedente 0 (cero) o más veces. Es equivalente a {0,}.
+	Busca el carácter precedente 1 o más veces. Es equivalente a {1,}.
?	Busca el carácter precedente 0 (cero) o 1 (una) vez. Es equivalente a {0,1}.

Tabla 4-6 Operadores y cardinalidades para expresiones regulares.

Fuente: Elaboración propia basada en Bird *et al.* (2009).

4.2.1 Regla 1

Esta regla se puede aplicar en temas sociales, económicos, políticos, laborales o financieros. Además, permite tener la trazabilidad de las palabras califican a cada uno de los sustantivos.

4.2.1.1 Patrón 1

Los adjetivos constituyen una de las formas en que se expresan sentimientos en el lenguaje natural que utilizan los usuarios en Twitter. Uno de los patrones que se encuentra es:

determinante + sustantivo + verbo 'to be' + **negación** + **adverbio** + adjetivo

- El determinante, la negación y el adverbio tienen una cardinalidad de cero o una vez en cada una de sus apariciones.
- El sustantivo, verbo 'to be' y adjetivo tienen una cardinalidad de una vez en cada una de sus apariciones.

En la Tabla 4-7 se presenta un ejemplo para el patrón 1, correspondiente a la regla 1.

Patrón 1	D + N + V 'to be' + neg + A + AD
Ejemplo	<pre> graph TD O((O)) --- SN[SN] O --- SV[SV] SN --- N[N] N --- Memory[Memory] SV --- V[V] V --- is[is] SV --- AD[AD] AD --- small[small] </pre> Memory is small

Tabla 4-7 Regla 1, patrón 1: ejemplo.

Fuente: Elaboración propia.

A continuación, se presenta el patrón en pseudocódigo de la expresión regular.

`(PRP|PRP$)?DT?(NN|NNS|NNP|NNPS){1}(TOBE){1}NEG?(RB|RBR|RBS)?(JJ|JJR|JJS){1}`

4.2.1.2 Patrón 2

Otra de las formas en que se encuentran los sentimientos expresados con adjetivos consiste en el siguiente patrón:

negación + **adverbio** + adjetivo + sustantivo

- El sustantivo y el adjetivo tienen una cardinalidad de una o más veces en cada una de sus apariciones.
- El adverbio y la negación tienen una cardinalidad de cero o más veces.

El patrón AD + N se reescribe con el patrón 1 de la regla 1 con el fin de estandarizar los mensajes.

En la Tabla 4-8 se presenta el patrón y el ejemplo.



	Inicio	Objetivo
Patrón 2	neg + A + AD + N	N + V 'to be' + neg + A + AD
Ejemplo	 <pre> graph TD SN --> AD SN --> N AD --- AD_text[AD] N --- N_text[N] AD_text --- AD_val[Small] N_text --- N_val[memory] </pre>	 <pre> graph TD O --> SN O --> SV SN --> N SV --> V SV --> AD N --- N_text[N] V --- V_text[V] AD --- AD_text[AD] N_text --- N_val[Memory] V_text --- V_val[is] AD_text --- AD_val[small] </pre>

Tabla 4-8 Regla 1, patrón 2: ejemplo.

Fuente: Elaboración propia.

A continuación, se presenta el patrón en pseudocódigo de la expresión regular.

NEG?(RB|RBR|RBS)?(JJ|JJR|JJS)+(PRP|PRP\$)?DT?(NN|NNS|NNP|NNPS)+

4.2.1.3 Patrón 3

A continuación, se listan dos patrones de agregación:

1. **determinante** + sustantivo + conjunción(*and*) + **determinante** + sustantivo + verbo 'to be' + **negación** + **adverbio** + adjetivo
 2. **determinante** + sustantivo + verbo 'to be' + **negación** + **adverbio** + adjetivo + conjunción(*and*) + **negación** + **adverbio** + adjetivo
- La conjunción, el determinante, la negación y el adverbio tienen una cardinalidad de cero o una vez en cada una de sus apariciones.
 - El sustantivo y el adjetivo tienen una cardinalidad de una o más veces en cada una de sus apariciones.
 - El verbo tiene una cardinalidad de una vez en cada una de sus apariciones.

En la Tabla 4-9 se presenta el patrón y el ejemplo.

	Inicio	Objetivo
Patrón 3	1. D + N + conjunción(<i>and</i>) + D + N + V 'to be' + neg + A + AD 2. D + N + V 'to be' + neg + A + AD + conjunción(<i>and</i>) + neg + A + AD	D + N + V 'to be' + neg + A + AD
Ejemplo	<pre> graph TD O --> SN O --> SV SN --> N1[N] SN --> C[C] SN --> N2[N] SV --> V[V] SV --> AD[AD] N1 --- N1_text[N] C --- C_text[C] N2 --- N2_text[N] V --- V_text[V] AD --- AD_text[AD] N1_text --- C_text --- N2_text --- V_text --- AD_text N1_text --- C_text --- N2_text --- V_text --- AD_text --- Sentence1[Display and keyboard are excellent] </pre> <i>Display and keyboard are excellent</i>	<pre> graph TD O1 --> SN1 O1 --> SV1 SN1 --> N1[N] SV1 --> V1[V] SV1 --> AD1[AD] N1 --- N1_text[N] V1 --- V1_text[V] AD1 --- AD1_text[AD] N1_text --- V1_text --- AD1_text --- Sentence2[Display is excellent] O2 --> SN2 O2 --> SV2 SN2 --> N2[N] SV2 --> V2[V] SV2 --> AD2[AD] N2 --- N2_text[N] V2 --- V2_text[V] AD2 --- AD2_text[AD] N2_text --- V2_text --- AD2_text --- Sentence3[Keyboard is excellent] </pre> <i>Display is excellent</i> <i>Keyboard is excellent</i>

Tabla 4-9 Regla 1, patrón 3: ejemplo.

Fuente: Elaboración propia.

A continuación, se presentan los patrones en pseudocódigo de la expresión regular.

1. (PRP|PRP\$)?DT?(NN|NNS|NNP|NNPS)+AND?
(PRP|PRP\$)?DT?(NN|NNS|NNP|NNPS)+TOBE{1}NEG?(RB|RBR|RBS)?(JJ|JJR|
JJS)+

2. (PRP|PRP\$)?DT?(NN|NNS|NNP|NNPS)+(TOBE){1}NEG?(RB|RBR|RBS)?(JJ|JJR|
JJS)+AND? NEG?RB?(JJ|JJR|JJS)+

4.2.2 Regla 2

En el lenguaje natural que utilizan los usuarios en Twitter se encuentran comparaciones entre sustantivos. Uno de los patrones que se encuentra es:

determinante + sustantivo + verbo *'to be'* + **negación** + **adverbio** + adjetivo comparativo
+ conjunción(*than*) + **determinante** + sustantivo

- El determinante, el adverbio y la negación tienen una cardinalidad de cero o una vez en cada una de sus apariciones.
- El sustantivo y el adjetivo tienen una cardinalidad de una o más veces en cada una de sus apariciones.
- La conjunción y el verbo tienen una cardinalidad de una vez en cada una de sus apariciones.

En la Tabla 4-10 se presenta el patrón y el ejemplo para la regla 2.


Patrón	D + N + V 'to be' + neg + A + AD comparativo + conjunción(<i>than</i>) + D + N
Ejemplo	 <pre> graph TD O --> SN1[SN] O --> SV[SV] O --> SN2[SN] SN1 --> N1[N] N1 --> iPhone[iPhone] SV --> V[V] V --> is[is] SV --> AD[AD] AD --> better[better] SN2 --> C[C] C --> than[than] SN2 --> N2[N] N2 --> Samsung[Samsung] </pre> <i>iPhone is better than Samsung</i>

Tabla 4-10 Regla 2: patrón y ejemplo.

Fuente: Elaboración propia.

A continuación, se presenta el patrón en pseudocódigo de la expresión regular.

```
(PRP|PRP$)?DT?(NN|NNS|NNP|NNPS)+TOBE{1}NEG?(RB|RBR|RBS)?(
JJ|JJR|JJS)+THAN{1}(PRP|PRP$)?DT?(NN|NNS|NNP|NNPS)+
```

Esta regla se puede aplicar en temas sociales, económicos, políticos, laborales o financieros. Además, permite tener la trazabilidad del sentimiento que expresa una persona para los diferentes sustantivos que se están comparando.

4.2.3 Regla 3

En el lenguaje natural que utilizan los usuarios en Twitter se encuentran oraciones en las cuales se expresa el sentimiento mediante verbos. Uno de los patrones que se encuentra es:

sustantivo + **negación** + verbo + **determinante** + sustantivo

- El determinante y la negación tienen una cardinalidad de cero o una vez en cada una de sus apariciones.
- El sustantivo tiene una cardinalidad de una o más veces en cada una de sus apariciones.
- El verbo tiene una cardinalidad de una vez en cada una de sus apariciones.

En la Tabla 4-11 se presenta el patrón y el ejemplo para la regla 3.

Patrón	N + neg + V + D + N
Ejemplo	<pre>graph TD O --> SV O --> SN1[SN] SV --> SN2[SN] SV --> V SN2 --> N1[N] V --> V1[V] SN1 --> N2[N] N1 --- I[I] V1 --- love[love] N2 --- MS[Microsoft]</pre> <i>I love #Microsoft</i>

Tabla 4-11 Regla 5: patrón y ejemplo.

Fuente: Elaboración propia.

A continuación, se presenta el patrón en pseudocódigo de la expresión regular.

(PRP|PRP\$)?DT?(NN|NNS|NNP|NNPS)+DO?NEG?(VB|VBD|VBZ|VBP){1}(PRP|PRP\$)?
DT?(NN|NNS|NNP|NNPS)+

Esta regla se puede aplicar en temas sociales, económicos, políticos, laborales o financieros. Además, permite tener la trazabilidad del sustantivo que se está calificando con el verbo.

4.2.4 Regla 4

En el lenguaje natural que utilizan los usuarios en Twitter se encuentran oraciones en las cuales se expresan los sentimientos mediante sustantivos adjetivados. Uno de los patrones que se encuentra es:

determinante + sustantivo + negación + *has/have/is/are* + negación + determinante + sustantivo adjetivado

- El determinante y la negación tienen una cardinalidad de cero o una vez en cada una de sus apariciones.
- El sustantivo y el sustantivo adjetivado tienen una cardinalidad de una o más veces en cada una de sus apariciones.
- *has/have/is/are* tienen una cardinalidad de una vez en cada una de sus apariciones.

En la Tabla 4-12 se presenta el patrón y el ejemplo para la regla 4.

Patrón	D + N + neg + <i>has/have/is/are</i> + neg + D + N (sustantivo adjetivado)
Ejemplo	<pre>graph TD O --> SV O --> SN1[SN] SV --> SN2[SN] SV --> V SN2 --> N1[N] V --> has[has] SN1 --> N2[N] N1 --> Norton[Norton] has --> has_text[has] N2 --> bugs[bugs]</pre>

Tabla 4-12 Regla 3: patrón y ejemplo.

Fuente: Elaboración propia.

A continuación, se presenta el patrón en pseudocódigo de la expresión regular.

```
(PRP|PRP$)?DT?(NN|NNS|NNP|NNPS)+DO?NEG?(HAVE|TOBE){1}NEG?(PRP|PRP$)?
DT?(NN|NNS|NNP|NNPS)+
```

Esta regla se puede aplicar en temas sociales, económicos, políticos, laborales o financieros. Además, permite tener la trazabilidad de cómo se está calificando al sustantivo, ya sea mediante la palabra tener o ser.

4.3 Taxonomía de adjetivos y verbos

Para las reglas definidas en la Sección 4.2 es necesario acotar los adjetivos, verbos, sustantivos adjetivados y adverbios, pues no todos ellos connotan sentimientos. Las palabras que se definen en las taxonomías pertenecen a la base de datos que proponen Lakkaraju *et al.* (2011) y Go *et al.* (2009). Estas palabras se etiquetan manualmente con la polaridad. Además, algunas de ellas son sinónimos o antónimos de las palabras encontradas en las bases de datos. Por ello, se define la taxonomía para asegurar que las oraciones tengan una polaridad definida. A continuación, se expone una muestra de las taxonomías utilizadas en el método propuesto.

4.3.1 Adjetivos

<i>Fast (+)</i>	<i>Late (-)</i>	<i>Immediate (+)</i>
<i>Old (-)</i>	<i>Slow (-)</i>	<i>Swift (+)</i>
<i>Outdated (-)</i>	<i>Ancient (-)</i>	<i>Brief (+)</i>
<i>Early (+)</i>	<i>Busy (-)</i>	
<i>Old-fashioned (-)</i>	<i>Modern (+)</i>	

Tabla 4-13 Taxonomía de adjetivos, categoría tiempo.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

<i>Quick (+)</i>	<i>Slow (-)</i>	<i>Nippy (+)</i>
<i>Fleet (+)</i>	<i>Zappy (+)</i>	
<i>Quiet (+)</i>	<i>Instant (+)</i>	

Tabla 4-14 Taxonomía de adjetivos, categoría velocidad.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

<i>Huge (+)</i>	<i>Little (-)</i>	<i>Majestic (+)</i>
<i>Massive (+)</i>	<i>Puny (-)</i>	<i>Thin (+)</i>
<i>Scrawny (-)</i>	<i>Light (+)</i>	<i>Wide (-)</i>
<i>Deep (+)</i>	<i>Least (-)</i>	<i>Bulky (+)</i>
<i>Macro (+)</i>	<i>Thick (+)</i>	<i>Thickset (+)</i>
<i>Tiny (+)</i>	<i>Wide (-)</i>	<i>Vast (+)</i>
<i>Narrow (-)</i>	<i>Shallow (-)</i>	<i>Bony (-)</i>
<i>Colossal (+)</i>	<i>Beefy (+)</i>	<i>Cosmic (+)</i>
<i>Gaunt (-)</i>	<i>Extensive (+)</i>	<i>Scanty (-)</i>
<i>Slim (+)</i>	<i>Whopping (+)</i>	<i>Towering (+)</i>

Tabla 4-15 Taxonomía de adjetivos, categoría tamaño.

Fuente: Elaboración propia basada en Lakkaraju et al. (2011) y Go et al. (2009).

<i>Curved (-)</i>	<i>Crooked (-)</i>	<i>Warped (-)</i>
<i>Flat (-)</i>	<i>Asymmetrical (-)</i>	<i>Congruent (+)</i>
<i>Corrugated ()</i>	<i>Deformed (-)</i>	<i>Fitted (+)</i>
<i>Forked (-)</i>	<i>Malformed (-)</i>	<i>Misshapen (-)</i>
<i>Peaked (-)</i>	<i>Proportioned (+)</i>	<i>Regular (+)</i>
<i>Rugged (-)</i>	<i>Sculptured (+)</i>	<i>Shapely (+)</i>
<i>Symmetrical (+)</i>	<i>Twisted (-)</i>	<i>Hollow (-)</i>
<i>Steep (-)</i>	<i>Straight (+)</i>	
<i>Well-rounded (+)</i>	<i>Well-turned (+)</i>	

Tabla 4-16 Taxonomía de adjetivos, categoría Forma.

Fuente: Elaboración propia basada en Lakkaraju et al. (2011) y Go et al. (2009).

<i>Single (-)</i>	<i>Little (-)</i>	<i>Slight (+)</i>
<i>Few (-)</i>	<i>Several (-)</i>	<i>Only (-)</i>
<i>Less (-)</i>	<i>Full (+)</i>	<i>Multiple (+)</i>
<i>Countless (-)</i>	<i>Major (+)</i>	<i>Some (+)</i>
<i>Any (-)</i>	<i>Many (+)</i>	<i>Much (+)</i>
<i>Most (+)</i>	<i>None (-)</i>	<i>Enough (+)</i>
<i>All (+)</i>	<i>Substantial (+)</i>	<i>Whole (+)</i>
<i>Insufficient (-)</i>	<i>Sufficient (+)</i>	<i>Abundant (+)</i>
<i>Empty (-)</i>	<i>Numerous (+)</i>	

Tabla 4-17 Taxonomía de adjetivos, categoría cantidad.

Fuente: Elaboración propia basada en Lakkaraju et al. (2011) y Go et al. (2009).

<i>Hard (-)</i>	<i>Complicated (-)</i>	<i>Arduous (-)</i>
<i>Tedious (-)</i>	<i>Impossible (-)</i>	<i>Easy (+)</i>

Tabla 4-18 Taxonomía de adjetivos, categoría dificultad.

Fuente: Elaboración propia basada en Lakkaraju et al. (2011) y Go et al. (2009).

<i>Warm (+)</i>	<i>Calm (+)</i>	<i>Serene (+)</i>
<i>Gentle (+)</i>	<i>Skeptical (-)</i>	<i>Smart (+)</i>
<i>Friendly (+)</i>	<i>Intuitive (+)</i>	<i>Decent (+)</i>
<i>Clear (+)</i>	<i>Compassionate (+)</i>	<i>Strong (+)</i>
<i>Classy (+)</i>	<i>Happy (+)</i>	<i>Portable (+)</i>
<i>Wireless (+)</i>	<i>Hefty (+)</i>	<i>Professional (+)</i>
<i>Livable (+)</i>	<i>Powerful (+)</i>	<i>Mindless (-)</i>
<i>Incapable (-)</i>	<i>Silent (-)</i>	<i>Able (+)</i>
<i>Creative (+)</i>	<i>Impressionable (+)</i>	<i>Hysterical (-)</i>
<i>Melancholic (-)</i>	<i>Nervous (-)</i>	
<i>Lazy (-)</i>	<i>Indolent (-)</i>	

Tabla 4-19 Taxonomía de adjetivos, categoría cualidad.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

<i>Rancid (-)</i>	<i>Putrid (-)</i>	<i>Acidic (-)</i>
<i>Sleek (+)</i>	<i>Soft (+)</i>	<i>Crappy (-)</i>
<i>Fiery (-)</i>	<i>Glossy (+)</i>	<i>Cracking (+)</i>
<i>Hushing ()</i>	<i>Doughy (-)</i>	<i>Mellow (+)</i>
<i>Spicy (-)</i>	<i>Earthy (-)</i>	<i>Acrid (-)</i>
<i>Fishy (-)</i>	<i>Moist (-)</i>	<i>Stale (-)</i>
<i>Aromatic (+)</i>	<i>Moldy (-)</i>	<i>Raw (-)</i>
<i>Sugary (-)</i>	<i>Fresh (+)</i>	<i>Bitter (-)</i>
<i>Oily (-)</i>	<i>Salty (-)</i>	<i>Abrasive (-)</i>
<i>Fluffy (+)</i>	<i>Furry (-)</i>	<i>Silky (+)</i>

Tabla 4-20 Taxonomía de adjetivos, categoría percepción.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

<i>Good (+)</i>	<i>Bad (-)</i>	<i>Right (+)</i>
<i>Nice (+)</i>	<i>Unable (-)</i>	<i>Cheap (+)</i>
<i>Expensive (-)</i>	<i>Free (+)</i>	<i>Modest (-)</i>
<i>Irritating (-)</i>	<i>Available (+)</i>	<i>Affordable (+)</i>
<i>Obvious (+)</i>	<i>Additional (+)</i>	<i>Competitive (+)</i>
<i>Advanced (+)</i>	<i>Fun (+)</i>	<i>Handy (+)</i>
<i>Frustrating (-)</i>	<i>Terrible (-)</i>	<i>New (+)</i>
<i>Great (+)</i>	<i>Horrible (-)</i>	<i>Ideal (+)</i>
<i>Basic (+)</i>	<i>Durable (+)</i>	<i>Constant (+)</i>
<i>Intact (+)</i>	<i>Convenient (+)</i>	<i>Superb (+)</i>
<i>Amazing (+)</i>	<i>Awesome (+)</i>	<i>Perfect (+)</i>
<i>Delighted (+)</i>	<i>Dead (-)</i>	<i>Outstanding (+)</i>
<i>Unbeatable (-)</i>	<i>Satisfied (+)</i>	<i>Wonderful (+)</i>
<i>Vibrant (+)</i>	<i>Amazed (+)</i>	<i>Questionable (-)</i>
<i>Unprotected (-)</i>	<i>Extraordinary (+)</i>	<i>Stunning (+)</i>
<i>Usable (+)</i>	<i>Weird (-)</i>	<i>Terrific (-)</i>

Tabla 4-21 Taxonomía de adjetivos, categoría valor.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

<i>Freezing</i> (-)	<i>Chilly</i> (-)	<i>Cold</i> (-)
<i>Cool</i> (+)	<i>Lukewarm</i> (-)	<i>Boiling</i> (-)
<i>Muggy</i> (+)	<i>Hot</i> (+)	<i>Warm</i> (+)
<i>Rainy</i> (-)	<i>Stormy</i> (-)	<i>Sunny</i> (+)
<i>Windy</i> (-)	<i>Snowy</i> (+)	<i>Damp</i> (-)
<i>Dry</i> (-)	<i>Icy</i> (-)	<i>Foggy</i> (-)
<i>Overcast</i> (-)	<i>Cloudy</i> (-)	<i>Mild</i> (+)

Tabla 4-22 Taxonomía de adjetivos, categoría temperatura/clima.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

4.3.2 Verbos

<i>Love</i> (+)	<i>Recommend</i> (+)	<i>Like</i> (+)
<i>Desire</i> (+)	<i>Avoid</i> (-)	<i>Disappoint</i> (-)
<i>Hate</i> (-)	<i>Appreciate</i> (+)	<i>Detest</i> (-)
<i>Dislike</i> (-)	<i>Replace</i> (-)	<i>Ease</i> (+)

Tabla 4-23 Taxonomía de verbos, categoría gusto/preferencia.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

4.3.3 Sustantivos adjetivados

<i>Bugs</i> (-)	<i>Problems</i> (-)
-----------------	---------------------

Tabla 4-24 Taxonomía de sustantivos adjetivados.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

4.3.4 Adverbios

<i>Little</i> (-)	<i>Much</i> (+)	<i>Very</i> (+)
<i>Too</i> (+)	<i>Less</i> (-)	<i>Quite</i> (+)

Tabla 4-25 Taxonomía adverbios, categoría cantidad.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

<i>Extremely</i> (+)	<i>Really</i> (+)	<i>Pretty</i> (+)
----------------------	-------------------	-------------------

Tabla 4-26 Taxonomía adverbios, categoría intensidad.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

<i>Carefully</i> (+)	<i>Easily</i> (+)	<i>Slowly</i> (-)
<i>Simply</i> (+)	<i>Happily</i> (+)	<i>Clearly</i> (+)

Tabla 4-27 Taxonomía de adverbios, categoría modo.

Fuente: Elaboración propia basada en Lakkaraju *et al.* (2011) y Go *et al.* (2009).

5. Validación

5.1 Aplicación

Para la validación de esta Tesis de Maestría se usa la base de datos de entrenamiento de *Sentiment140* que contiene mensajes de usuarios de Twitter. La base de datos tiene 497 revisiones (Go *et al.*, 2009). El esquema de las revisiones se muestra en la Figura 5-1.




Figura 5-1 Base de datos para la validación.

Fuente: Elaboración propia a partir de Go *et al.* (2009).

5.1.1 Regla 1

5.1.1.1 Patrón 1

A continuación, se presenta un ejemplo del Patrón1 – Regla1 aplicado a una oración de la base de datos que proponen Go *et al.* (2009).

```
{
  "sentence": "just changed my default pic to a Nike basketball cause bball is
awesome!!!!\n",
  "polarity_found": 1,
  "polarity_original": 4,
  "patterns": [
    {
      "name": "pattern 0",
      "polarity": 1,
      "matches": [
        {
          "matched_sentence": "bball is awesome",
          "sentence_tagged": [["bball", "NN"], ["is", "TOBE"], ["awesome", "JJ"]],
          "polarity": 1
        }
      ],
      "matches_count": 1
    }
  ]
}
```

5.1.1.2 Patrón 2

A continuación, se presenta un ejemplo del Patrón2 – Regla1 aplicado a una oración de la base de datos que proponen Go *et al.* (2009).


```

{
  "sentence": "Just picked up my new Canon 50D...it's beautiful!! Prepare for some
seriously awesome photography\n",
  "polarity_found": 1,
  "polarity_original": 4,
  "patterns": [
    {
      "name": "pattern 1",
      "polarity": 1,
      "matches": [
        {
          "matched_sentence": "new Canon",
          "sentence_tagged": [["new", "JJ"], ["Canon", "NNP"]],
          "polarity": 1,
          "splits": [
            {
              "split_sentence": "Canon is new",
              "sentence_tagged": [["Canon", "NNP"], ["is", "TOBE"], ["new", "JJ"]],
              "polarity": 1
            }
          ]
        }
      ],
      {
        "matched_sentence": "seriously awesome photography",
        "sentence_tagged": [["seriously", "RB"], ["awesome", "JJ"], ["photography",
"NN"]],
        "polarity": 1,
        "splits": [
          {
            "split_sentence": "photography is seriously awesome",
            "sentence_tagged": [["photography", "NN"], ["is", "TOBE"],
["seriously", "RB"], ["awesome", "JJ"]],
            "polarity": 1
          }
        ]
      }
    ],
    "matches_count": 2
  ]
}

```

5.1.1.3 Patrón 3

A continuación, se presenta un ejemplo del Patrón3 – Regla1 aplicado a una oración de la base de datos que proponen Go *et al.* (2009).

```
{
  "sentence": "@goldfoil ahhhh jealous, those are beautiful amazing. T_T the design
is so fabulous and awesome.\n",
  "polarity_found": 1,
  "polarity_original": 4,
  "patterns": [
    {
      "name": "pattern 3",
      "polarity": 1,
      "matches": [
        {
          "matched_sentence": "the design is so fabulous and awesome",
          "sentence_tagged": [["the", "DT"], ["design", "NN"], ["is", "TOBE"], ["so",
"RB"], ["fabulous", "JJ"], ["and", "AND"], ["awesome", "JJ"]],
          "polarity": 1,
          "splits": [
            {
              "split_sentence": "design is so fabulous",
              "sentence_tagged": [["the", "DT"], ["design", "NN"], ["is", "TOBE"],
["so", "RB"], ["fabulous", "JJ"]],
              "polarity": 1
            },
            {
              "split_sentence": "design is awesome",
              "sentence_tagged": [["the", "DT"], ["design", "NN"], ["is", "TOBE"],
["awesome", "JJ"]],
              "polarity": 1
            }
          ]
        }
      ],
      "matches_count": 1
    }
  ]
}
```

5.1.2 Ejemplo regla 2

A continuación, se presenta un ejemplo de la regla 2 aplicado a una oración de la base de datos que proponen Go *et al.* (2009).

```
{
  "sentence": "Fuzzball is more fun than AT&amp;\n",
  "polarity_found": 1,
  "polarity_original": 4,
  "patterns": [
    {
      "name": "pattern 1",
      "polarity": 1,
      "matches": [
        {
          "matched_sentence": "Fuzzball is more fun than AT",
          "sentence_tagged": [
            ["Fuzzball", "NN"],
            ["is", "TOBE"],
            ["more", "RBR"],
            ["fun", "JJ"],
            ["than", "THAN"],
            ["AT", "NNP"]
          ],
          "polarity": 1
        }
      ],
      "matches_count": 1
    }
  ]
}
```

5.1.3 Ejemplo regla 3

A continuación, se presenta un ejemplo de la regla 3 aplicado a una oración de la base de datos que proponen Go *et al.* (2009).

```
{
  "sentence": "i love lebron. http://bit.ly/PdHur\n",
  "polarity_found": 1,
  "polarity_original": 4,
  "patterns": [
    {
      "name": "pattern 5",
      "polarity": 1,
      "matches": [
        {
          "matched_sentence": "i love lebron",
          "sentence_tagged": [
            ["i", "NN"],
            ["love", "VBP"],
            ["lebron", "NN"]
          ],
          "polarity": 1
        }
      ],
      "matches_count": 1
    }
  ]
}
```

5.1.4 Ejemplo regla 4

A continuación, se presenta un ejemplo de la regla 4 aplicado a una oración de la base de datos que proponen Go *et al.* (2009).

```
{
  "sentence": "Bleh yeah our dps have problems attacking the wrong target and
stopping dps when asked\n",
  "polarity_found": -1,
  "polarity_original": 0,
  "patterns": [
    {
      "name": "pattern 6",
      "polarity": -1,
      "matches": [
        {
          "matched_sentence": "dps have problems",
          "sentence_tagged": [["dps", "NNS"], ["have", "HAVE"], ["problems", "NNS"]],
          "polarity": -1
        }
      ],
      "matches_count": 1
    }
  ]
}
```

5.2 Resultados

En la Tabla 5-1 se evidencia el número de ocurrencias para cada una de las reglas y patrones encontrados en los mensajes de la base de datos *Sentiment140* (Go *et al.*, 2009). Es importante tener en cuenta que un patrón puede aparecer mas de una vez en un mismo mensaje.

Regla	Número de ocurrencias.
Regla 1 - Patrón 1	42
Regla 1 - Patrón 2	154
Regla 1 - Patrón 3	40
Regla 2	16
Regla 3	84
Regla 4	35

Tabla 5-1 Número de ocurrencias por cada una de las reglas y patrones.

Fuente: Elaboración propia a partir de Go *et al.* (2009).

5.2.1 Precisión del lenguaje controlado

Para medir la precisión del lenguaje controlado propuesto en esta Tesis de Maestría, se utilizan las métricas de *precision*, *recall* y *f-measure* (Christen, 2012). En la Tabla 5-2 se muestran las categorías necesarias para calcular estas métricas:

Sentimiento (S)	Categoría	Descripción
Positivo	Verdadero positivo	Mensaje que se asigna correctamente con polaridad positiva.
	Falso positivo	Mensaje que se asigna incorrectamente con polaridad positiva.
Negativo	Verdadero negativo	Mensaje que se asigna correctamente con polaridad negativa.
	Falso negativo	Mensaje que se asigna incorrectamente con polaridad negativa.
Neutral	Verdadero neutral	Mensaje que se asigna correctamente con polaridad neutral.
	Falso neutral	Mensaje que se asigna incorrectamente con polaridad neutral.

Tabla 5-2 Categorías de sentimientos.

Fuente: Elaboración propia a partir de Christen (2012).

- **Precision:** Con ella se calcula la proporción de mensajes asignados correctamente a un sentimiento (Christen, 2012).

$$Precision = \frac{Verdadero(S)}{Verdadero(S) + Falso(S)}$$

Un valor alto (cercano a 1) establece que un número alto de publicaciones asignadas al sentimiento S se clasifican correctamente. Por el contrario, un valor bajo (cercano a 0)

indica que un alto número de publicaciones no se clasifican correctamente (Christen, 2012).

- **Recall:** Con ella se mide la proporción de verdadero (S) que se identificó correctamente.

$$\text{Recall} = \frac{\text{Verdadero (S)}}{\text{Número de mensajes clasificados en la BD con el sentimiento (S)}}$$

Por lo tanto, un valor alto (cercano a 1) indica que la mayoría de las publicaciones Verdadero (S) también se clasifican correctamente como S (Christen, 2012).

- **F-measure:** Dado que *precision* y *recall* apuntan a diferentes objetivos, existe una tercera métrica llamada *f-measure*. Esta métrica combina *precision* y *recall*, por lo tanto, ofrece una visión general de la precisión del enfoque utilizado (Christen, 2012).

$$F - \text{measure} = 2 * \frac{\text{recall}(S) * \text{precision}(S)}{\text{recall}(S) + \text{precision}(S)}$$

En la Tabla 5-3 se muestran los resultados de las métricas *precision*, *recall* y *f-measure* que se obtienen al aplicar el lenguaje controlado propuesto en esta Tesis de Maestría en la base de datos *Sentiment140*.

Sentimiento (S)	<i>Precision</i>	<i>Recall</i>	<i>F-measure</i>
Positivo	0.56	0.55	0.56
Negativo	0.64	0.51	0.57
Neutral	0.68	0.80	0.73

Tabla 5-3 Métricas discriminadas por sentimiento.

Fuente: Elaboración propia.

El sentimiento neutral obtuvo un 68% de *precision*, un 80% de *recall* y un 73% de *F-measure*. Es importante resaltar que un mensaje se polariza con sentimiento neutral cuando no se encuentra un patrón en dicho mensaje. Por lo anterior, es posible que este sea un buen plan de acción para polarizar un mensaje con sentimiento neutral.

Por otro lado, los porcentajes de *precision*, *recall* y *f-measure* para los sentimientos positivo y negativo evidencian que es necesario definir más reglas para el lenguaje controlado y, además, incrementar la taxonomía de los adjetivos, sustantivos adjetivados, adverbios y verbos.

En la solución y validación que se presentan en esta Tesis de Maestría, se evidencia que las palabras adquieren valor sintáctico, se estandariza la estructura y el formato de los mensajes. Por ello, los mensajes son más precisos e inequívocos y, por consiguiente, son útiles como punto de partida para la automatización del razonamiento.

6. Conclusiones y trabajo futuro

6.1 Conclusiones

- En esta Tesis de Maestría se identificaron cuatro reglas que los usuarios de Twitter utilizan para expresar sentimientos. Para este fin se definieron reglas sintácticas.
- Se propusieron diez grupos de adjetivos, un grupo de verbos, un grupo de sustantivos adjetivados y tres grupos de adverbios para polarizar las opiniones de los usuarios. Para este fin se utilizó etiquetado manual para los adjetivos, sustantivos adjetivados, adverbios y verbos de la base de datos de la validación, además de sus sinónimos y antónimos.
- Se mostró la aplicación del algoritmo desarrollado con un caso de estudio de la vida real. Se encontró que hay 371 ocurrencias de los patrones y reglas en las oraciones de la base de datos escogida.
- Se encuentra que los patrones con mayores ocurrencias son Regla 1 – Patrón 1 y Regla 3.
- Es necesario encontrar más reglas y patrones para el lenguaje controlado, con el fin de mejorar la precisión del método.
- En el método propuesto en esta Tesis de Maestría, un mensaje se polariza con sentimiento neutral cuando no se encuentra un patrón en dicho mensaje. En los porcentajes de *precision*, *recall* y *f-measure* de este sentimiento se evidencia que este podría ser un buen plan de acción para definir esta polaridad.
- Una vez se implementa el lenguaje controlado, las palabras adquieren valor sintáctico, se estandariza la terminología y el formato de la información, por lo cual, los mensajes son más precisos e inequívocos y, por consiguiente, son útiles como punto de partida para la automatización del razonamiento.

6.2 Trabajo futuro

- Para mejorar la precisión del lenguaje controlado, se deben buscar nuevos patrones del lenguaje natural utilizado en Twitter. Para este fin se puede buscar patrones con emoticones y amplificadores de polaridad.
- Se propone el incremento de la taxonomía de los adjetivos, sustantivos adjetivados, adverbios y verbos, con el fin de mejorar la precisión de la polaridad de los tuits.
- Se propone la ampliación del número de casos de estudio.

Bibliografía

- Akundi, A., Tseng, B., Wu, J., Smith, E., Subbalakshmi, M., & Aguirre, F. (2018). Text Mining to Understand the Influence of Social Media Applications on Smartphone Supply Chain. *Procedia Computer Science*. 140, 87-94.
- Al Mohanna, N., & Al-Khalifa, H. S. (2014). How rational are people? Economic behavior based on sentiment analysis. 9th International Conference on Digital Information Management, ICDIM. Phitsanulok, pp. 124-127.
- Algur, S. P., & Patil, R. H. (2017). Sentiment analysis by identifying the speaker's polarity in Twitter data. International Conference on Electrical, Electronics, Communication, Computer, and Optimization Techniques (ICEECCOT). Mysuru, pp. 1-5.
- Allen, J. (1995). *Natural language understanding*. Pearson: Menlo Park.
- Ashna, M. P., & Sunny, A. K. (2017). Lexicon based sentiment analysis system for malayalam language. International Conference on Computing Methodologies and Communication (ICCMC). Erode, pp. 777-783.
- Bharti, S. K., Babu, K. S., & Jena, S. K. (2015). Parsing-based Sarcasm Sentiment Recognition in Twitter Data. Proceedings of the 2015 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining 2015 - ASONAM '15. Paris, pp. 1373-1380.
- Bird, S., Klein, E., & Loper, E. (2009). *Natural language processing with Python: analyzing text with the natural language toolkit*. O'Reilly Media, Inc. Sebastopol.
- Cernian, A., Sgarciu, V., & Martin, B. (2015). Sentiment analysis from product reviews using SentiWordNet as lexical resource. Proceedings of the 7th International Conference on Electronics, Computers and Artificial Intelligence, ECAI. Bucharest, pp. WE-15-WE-18.
- Chomsky, N. (1965). *Aspects of the Theory of Syntax*. MIT Press: Cambridge.
- Christen, P. (2012). *Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection*. Springer. Berlin.
- Czeżowski T. (1979) Connotation and Denotation. *Semiotics in Poland 1984–1969*. Dordrecht, pp. 73-80.
- Diamantini, C., Mircoli, A., & Potena, D. (2016). A negation handling technique for sentiment analysis. International Conference on Collaboration Technologies and Systems, CTS. Orlando, pp. 188-195.
- Gayo-Avello, D. (2013). A meta-analysis of state-of-the-art electoral prediction from Twitter data. *Social Science Computer Review*. 31(6), 649-679.

- Gatti, L., Guerini, M., & Turchi, M. (2016). SentiWords: Deriving a high precision and high coverage lexicon for sentiment analysis. *IEEE Transactions on Affective Computing*, 7(4), 409-421.
- Gelbukh A. & Sidorov G. (2010) Procesamiento automático del español con enfoque en recursos léxicos grandes, Segunda edición, ampliada y revisada. IPN. Ciudad de México.
- Gharatkar, S., Ingle, A., Naik, T., & Save, A. (2017). Review preprocessing using data cleaning and stemming technique. *International Conference on Innovations in Information, Embedded and Communication Systems (ICIIECS)*. Coimbatore, pp. 1-4.
- Gupta, I., & Joshi, N. (2017). Tweet normalization: A knowledge based approach. *International Conference on Infocom Technologies and Unmanned Systems (Trends and Future Directions) (ICTUS)*. Dubai, pp. 157-162.
- Glynn, D., & Robinson, J. A. (2014). *Corpus methods for semantics: Quantitative studies in polysemy and synonymy* (Vol. 43). John Benjamins Publishing Company. Philadelphia.
- Go, A., Bhayani, R., & Huang, L. (2009). Twitter sentiment classification using distant supervision. *CS224N Project Report*, Stanford, pp. 1(12), 2009.
- Hu, X., Tang, J., Gao, H., & Liu, H. (2013). Unsupervised sentiment analysis with emotional signals. *22nd International Conference on World Wide Web – WWW*. Rio de Janeiro, pp. 607–618
- Hulliyah, K., Bakar, N. S. A. A., & Ismail, A. R. (2017). Emotion recognition and brain mapping for sentiment analysis: A review. *Second International Conference on Informatics and Computing (ICIC)*. Jayapura, pp. 1-5.
- Im, T. L., San, P. W., On, C. K., Alfred, R., & Anthony, P. (2013). Analysing market sentiment in financial news using lexical approach. *IEEE Conference on Open Systems (ICOS)*. Kuching, pp. 145-149.
- Jianqiang, Z. (2015). Pre-processing boosting Twitter sentiment analysis?. *IEEE International Conference on Smart City/SocialCom/SustainCom (SmartCity)*. Chengdu, pp. 748-753.
- Jimenez-Zafra, S. M., Martin Valdivia, M. T., Martinez Camara, E., & Urena-Lopez, L. A. (2017). Studying the Scope of Negation for Spanish Sentiment Analysis on Twitter. *IEEE Transactions on Affective Computing*, 14(8), 129-141.
- Jose, R., & Chooralil, V. S. (2015). Prediction of election result by enhanced sentiment analysis on twitter data using word sense disambiguation. *IEEE International Conference Control Communication & Computing India (ICCC)*. Trivandrum, pp. 638-641.
- Khan, A. Z., Atique, M., & Thakare, V. M. (2015). Combining lexicon-based and learning-based methods for Twitter sentiment analysis. *International Journal of Electronics, Communication and Soft Computing Science & Engineering (IJECSCE)*. Ikeja, pp. 89-91.

- Lakkaraju, H., Bhattacharyya, C., Bhattacharya, I., & Merugu, S. (2011). Exploiting Coherence for the simultaneous discovery of latent facets and associated sentiments. SIAM international conference on data mining. Society for Industrial and Applied Mathematics. Mesa, pp. 498-509.
- Li, L. (2016). Identification of informative reviews enhanced by dependency parsing and sentiment analysis. 1st IEEE International Conference on Computer Communication and the Internet, ICCCI. Wuhan, pp. 476–479.
- Liu, T., Ma, Y., & Yang, X. (2018). Service Quality Improvement of Hospital Reservation System Based on Text Sentiment Analysis. 9th International Conference on Information Technology in Medicine and Education (ITME). Hangzhou, pp. 289-293.
- Manglik, E., Sharma, P., Rawat, P., & Tyagi, N. (2013). Ontology based context synonymy web searching. International Conference on Information Systems and Computer Networks. Mathura, pp. 114-118.
- Metaxas, P., Mustafaraj E. , & Gayo-Avello D. (2011). How (Not) to Predict Elections. 2011 IEEE Third International Conference on Privacy, Security, Risk and Trust and 2011 IEEE Third International Conference on Social Computing. Boston, pp. 165-171.
- Mhatre, M., Phondekar, D., Kadam, P., Chawathe, A., & Ghag, K. (2017). Dimensionality reduction for sentiment analysis using pre-processing techniques. International Conference on Computing Methodologies and Communication (ICCMC). Erode, pp. 16-21.
- Mishra, P., Rajnish, R., & Kumar, P. (2016). Sentiment analysis of Twitter data: Case study on digital India. International Conference on Information Technology (InCITe) - The Next Generation IT Summit on the Theme - Internet of Things: Connect your Worlds. Noida, pp. 148-153.
- Mitamura, T., & Nyberg, E.H. (1995). Controlled English for Knowledge-Based MT: Experience with the KANT System. 6th International Conference on Theoretical and Methodological Issues in Machine Translation (TMI95). Pittsburgh, pp. 146-147.
- Murthy, D. (2013). Twitter: Social Communication in the Twitter Age. Polity, Cambridge.
- Neppalli, V. K., Caragea, C., Squicciarini, A., Tapia, A., & Stehle, S. (2017). Sentiment analysis during Hurricane Sandy in emergency response. International journal of disaster risk reduction, 21, 213-222.
- O'Connor, B., Balasubramanyan, R., Routledge, B. R., & Smith, N. A. (2010). From tweets to polls: Linking text sentiment to public opinion time series. 4th International AAAI Conference on Weblogs and Social Media. Washington, pp. 122-129.
- Oomoto, K., Oikawa, H., Yamamoto, E., Yoshida, M., Okabe, M., & Umemura, K. (2017). Polysemy detection in distributed representation of word sense. 9th International Conference on Knowledge and Smart Technology: Crunching Information of Everything, KST. Chonburi, pp. 28-33.
- Pannala, N. U., Nawarathna, C. P., Jayakody, J. T. K., Rupasinghe, L., & Krishnadeva, K. (2016). Supervised Learning Based Approach to Aspect Based Sentiment Analysis. IEEE International Conference on Computer and Information Technology (CIT). Nadi,

pp. 662-666.

- Poria, S., Gelbukh, A., Cambria, E., Yang, P., Hussain, A., & Durrani, T. (2012, October). Merging SenticNet and WordNet-Affect emotion lists for sentiment analysis. *International Conference on Signal Processing (ICSP)*. Beijing, vol. 2, pp. 1251-1255.
- Pozzi, F. A., Fersini, E., Messina, E., & Liu, B. (2017). Chapter 1 - Challenges of Sentiment Analysis in Social Networks: An Overview. In F. A. Pozzi, E. Fersini, E. Messina, & B. Liu (Eds.), *Sentiment Analysis in Social Networks* (pp. 1–11). Boston: Morgan Kaufmann.
- Ravin, Y. & Leacock, C. (2000) *Polysemy: Theoretical and Computational Approaches*. Oxford Univ. Press, Oxford.
- Tellez, E. S., Miranda-Jiménez, S., Graff, M., Moctezuma, D., Siordia, O. S., & Villaseñor, E. A. (2017). A Case Study of Spanish Text Transformations for Twitter Sentiment Analysis. *Expert Systems with Applications*, 81, 457-471
- Xia, Y., Li, X., Cambria, E., & Hussain, A. (2014). A Localization Toolkit for Sentic Net. *IEEE International Conference on Data Mining Workshop*, Shenzhen, pp. 403-408.
- Zapata, C. M., & Rosero, R. (2008). Revisión crítica de la literatura especializada en lenguajes controlados. *Revista Avances en Sistemas e Informática*, 5(3), 27-34.
- Zhang, L., Ghosh, R., Dekhil, M., Hsu, M., & Liu, B. (2011). Combining lexicon-based and learning-based methods for twitter sentiment analysis. In *HP Laboratories Technical Report*. Palo Alto (89 ed.)