

¿Qué son los grandes modelos de lenguaje (LLM)?

Machine learning

Le damos la bienvenida

- ▶ Introducción
- ▶ Ciencia de datos para machine learning
- ▶ Ingeniería de características
- ▶ Aprendizaje supervisado
- ▶ Aprendizaje no supervisado
- ▶ Aprendizaje semisupervisado
- ▶ Aprendizaje de refuerzo
- ▶ Deep learning
- ▼ Generative AI
 - Visión general
 - Modelo generativo
 - IA generativa vs. IA predictiva
 - ▼ Grandes modelos lingüísticos (LLM)
 - Visión general**
 - Modelos de razonamiento
 - Modelos de lenguaje pequeño

× Cerrar

¡Hola! ¿Cómo podemos ayudarte?

Ajuste de instrucciones

Parámetros de LLM

Temperatura de LLM

Puntos de referencia de LLM

Personalización de LLM

- ▶ Generación de imágenes de IA
- ▶ IA multimodal

Autor



Cole Stryker

Staff Editor, AI Models
IBM Think

¿Qué son los LLM?

Los modelos de lenguaje de gran tamaño son modelos de **deep learning** entrenados con grandes volúmenes de datos, lo que los hace capaces de comprender y generar texto natural y otros tipos de contenidos para diversas tareas. Los LLM se basan en un tipo de arquitectura llamada **transformador** que destaca palabras y la captura de patrones en el lenguaje.

Los LLM funcionan como máquinas gigantes que aprenden a predecir repetidamente la siguiente palabra de una secuencia. Al hacerlo, generan un lenguaje que sigue esos patrones.

Los LLM representan un gran salto en la forma de hacer tecnología porque son el primer sistema de IA generalista estructurado a escala, lo que permite la comunicación y el uso que los motores de búsqueda tradicionales y

¡Hola! ¿Cómo podemos ayudarte?

algoritmos para hacer coincidir las palabras con un razonamiento más profundo. Los LLM, con muchas aplicaciones que implican la interpretación de código o redactar una cláusula legal. ágiles, los LLM pueden realizar, con diversidad, que de otro modo serían realizadas por humanos.

Los LLM son la culminación de décadas de progreso del [lenguaje natural](#) (PLN) y el machine learning responsable de la explosión de los avances en la década de 2010 y la década de 2020. Los LLM populares familiares, lo que ha llevado a la [IA generativa](#), también se utilizan ampliamente en las empresas para numerosas funciones empresariales y casos de uso.

Los LLM son fácilmente accesibles para el público. Anthropic, [ChatGPT](#) de Open AI, Copilot de Microsoft de Google, junto con sus modelos BERT y PaLM [Granite](#) en [watsonx.ai](#), que se ha convertido en una plataforma para otros productos de IBM como [watsonx /](#)

Preentrenamiento de lenguaje de gran tamaño

El entrenamiento comienza con una enorme colección de billones de palabras de libros, artículos, sitios web, científicos de datos supervisan la limpieza y eliminación de duplicaciones y contenidos no deseados.

Este texto se divide en unidades más pequeñas durante un proceso de "[tokenización](#)". Los tokens son palabras, subpalabras o caracteres. Esto asegura que las palabras raras y novedosas puedan manejarse de manera efectiva.

Los LLM se entrenan inicialmente con [aprendizaje de machine learning](#) que utiliza datos no etiquetados. El aprendizaje autosupervisado no requiere con anticipación estrechamente relacionado con el aprendizaje supervisado. El rendimiento con respecto a una "verdad de

¡Hola! ¿Cómo podemos ayudarte?

las tareas se diseñan de forma que la verdad etiquetados. En lugar de que se le diga cuál es como en el aprendizaje supervisado, el modelo relaciones en los datos por sí mismo.



Cómo funcionan los modelos de lenguaje de gran

Autoatención

El modelo pasa los tokens a través de una **rec** transformador, introducidos en 2017, son útiles que les permite "prestar atención" a diferentes técnicas es la pieza central del transformador útil en parte porque permite que el **modelo d** entre los tokens, especialmente los que están arquitecturas del transformador también pero proceso sea mucho más eficiente que los métodos permitieron a los LLM manejar grandes **conju**

Una vez que el texto se divide en tokens, cada uno llamado **embedding**. Las redes neuronales convierten donde cada neurona realiza una operación. Las estas capas, y en cada una de ellas, los embeddings convirtiéndose en representaciones contextuales

El objetivo de este proceso es que el modelo palabras, de modo que palabras como "ladra

¡Hola! ¿Cómo podemos ayudarte?

espacio vectorial en un ensayo sobre perros circundantes relacionadas con perros en el [codificaciones posicionales](#), que dan a cada token una puntuación de atención para cada token en la secuencia.

Para calcular la atención, cada embedding se consulta mediante matrices de ponderación aprendidas. Cada consulta representa lo que "busca" un token y cada clave representa la información que contiene cada token y el valor de la clave, escalada por su respectivo peso de atención.

A continuación, las puntuaciones de alineación se multiplican por las consultas y claves. Estas puntuaciones, una vez normalizadas, determinan cuánto de cada vector de clave se usa para el token actual. Este proceso permite que el modelo se centre en el contexto relevante mientras ignora tokens irrelevantes.

Por lo tanto, la [autoatención](#) crea conexiones de una manera más eficiente que las arquitecturas a secuencia. Los LLM pueden aprender estos pesos, que son un tipo de [parámetro de atención](#). Los LLM son un tipo de modelo de machine learning que controla las predicciones. El número de parámetros se refiere al tamaño de un modelo, y algunos LLM contienen miles de millones de parámetros. Los [modelos de lenguaje pequeño](#) son de menor tamaño y menos parámetros, lo que los hace adecuados para entornos con recursos limitados.

Durante el entrenamiento, el modelo hace predicciones basadas en los datos extraídos de sus [datos de entrenamiento](#), y una vez que se hace una predicción, se calcula la pérdida. A través de un ciclo iterativo de ajuste de los pesos del modelo mediante [retropropagación](#), el modelo "aprende" los pesos en las capas que producen las predicciones.

Una vez que esas ponderaciones están suficientes, el modelo puede tomar el [embedding vectorial original](#) de cualquier token y producir una puntuación de alineación "mejor" para cada token. Las ponderaciones de atención que ayudan al modelo a centrarse en el contexto relevante.

¡Hola! ¿Cómo podemos ayudarte?

resultado final es un modelo que ha aprendido estructuras de razonamiento, estilos de escri

Fine-tuning de mod gran tamaño

Después del entrenamiento (o en el contexto "preentrenamiento"), los LLM pueden ajustar contextos. Por ejemplo, un modelo fundacion de conocimiento general puede ajustarse en para crear un [chatbot](#) para el campo legal.

Estas son algunas de las formas más comunes utilizar un método o una combinación de vari



Fine tuning de modelos de lenguaje de gran tama de gran tamaño supervis

El fine-tuning suele producirse en un context mucho más pequeño y etiquetado. El modelo mejor a la nueva verdad de base (en este caso

¡Hola! ¿Cómo podemos ayudarte?

Mientras que el preentrenamiento pretende ser general, el fine-tuning adapta un modelo de propósito general a tareas específicas como el resumen, la clasificación o la atención al cliente. Estas tareas representan nuevos tipos de tareas. El fine-tuning se realiza a partir de ejemplos cercanos a los ejemplos proporcionados por los usuarios, en lugar de recursos que el entrenamiento desde cero.

El fine-tuning supervisado también es útil para el ajuste de dominio, como entrenar un modelo en documentos de respuesta de preguntas relacionadas con la atención al cliente.

Aprendizaje por refuerzo humano

Para refinar aún más los modelos, los científicos utilizan el aprendizaje por refuerzo a partir de feedback humano (RLHF). Los humanos clasifican los resultados del modelo y los resultados que los humanos clasifican más altamente se utilizan para la alineación, un proceso que consiste en hacer que los modelos sean seguros y coherentes con los valores humanos.

El RLHF también es particularmente útil para el ajuste de estilo. Se puede ajustar para responder de una manera específica, como la marca. La alineación estilística implica entrenar el modelo para producir resultados en un estilo específico.

Modelos de razonamiento

El fine-tuning puramente supervisado enseña a los modelos a realizar tareas específicas. Sin embargo, el razonamiento a menudo requiere necesariamente fomentar un mejor razonamiento a través de varios pasos. Estas tareas no siempre tienen una solución única. El aprendizaje por refuerzo se utiliza a menudo para entrenar LLM que se han ajustado para dividir problemas complejos en pasos más sencillos. Los modelos a menudo llamados "trazas de razonamiento", que se vuelven cada vez más sofisticados de entrenar modelos para seguir una cadena de pensamiento y otras estrategias de razonamiento.

Ajuste de instrucciones

¡Hola! ¿Cómo podemos ayudarte?

Otra forma de [personalización de LLM](#) es el [ajuste de hiperparámetros](#), que se refiere a la configuración de los hiperparámetros del modelo, específicamente para mejorar la capacidad de generalización del modelo a nuevas tareas. Las muestras de entrada de un conjunto de datos se utilizan para ajustar el modelo a su totalidad en tareas que se asemejan a las de entrenamiento; los resultados demuestran que el modelo puede generalizar mejor. Dado que los LLM preentrenados no están inicialmente alineados con instrucciones u objetivos conversacionales, el ajuste de hiperparámetros puede ayudar a alinear mejor el modelo con la intención del usuario.

Uso de modelos de lenguaje de gran tamaño

Una vez entrenados, los modelos de lenguaje de gran tamaño procesan las instrucciones tokenizando la instrucción, pasando los tokens al transformador para generar texto token a token. El proceso de generar los tokens siguientes potenciales y emitirlos se repite hasta que se genera la respuesta final de antemano; utiliza todas las capacidades del modelo de entrenamiento para predecir un token a la vez.

La forma más fácil y rápida de obtener conocimiento de un LLM de uso general es a través del [prompt engineering](#). Los usuarios pueden modificar las instrucciones de ejemplo, una instrucción como "responda como un experto capacitado" podría arrojar resultados más relevantes. También se recomienda el uso de LLM para asesoramiento.

Los LLM tienen otras estrategias para controlar la salida. El [temperatura](#), que controla la aleatoriedad del texto generado, y el muestreo top-k/top-p, que limita el conjunto de tokens probables, equilibrando la creatividad y la coherencia.

La [ventana de contexto](#) es el número máximo de tokens que se pueden utilizar a la vez al generar texto. Los primeros modelos de LLM tenían ventanas de contexto de unos pocos cientos de tokens, pero los modelos más nuevos tienen cientos de miles de tokens, lo que permite casos de uso como resumir documentos.

¡Hola! ¿Cómo podemos ayudarte?

asistencia de código en grandes bases de código largas con los usuarios.

La **generación aumentada por recuperación** (RAG) es un paradigma de IA **preentrenado** con bases de conocimiento externas más relevantes con un mayor nivel de precisión y ventana de contexto del modelo, por lo que genera respuestas, sin necesidad de volver a entrenar la base de datos de servicios meteorológicos diarias, o proporcionar información para un usuario sobre el informe

AI Academy



Por qué los modelos fundacionales son el paradigma para la IA

Conozca una nueva clase de modelos de IA capaces de desbloquear nuevos insights y productividad, y utilice nuestra guía

[Ir al episodio](#) →

Implementación de

¡Hola! ¿Cómo podemos ayudarte?

Crear un LLM desde cero es un proceso complejo. Los LLM más populares son el resultado de inmensa experiencia humana, por lo que la mayoría son desarrollados por empresas tecnológicas con amplios recursos.

Sin embargo, muchos de estos modelos son accesibles a través de API. Los desarrolladores pueden utilizarlos para crear chatbots, sistemas de recuperación de conocimiento y mucho más. Para un mayor control sobre los modelos, el código abierto se pueden implementar localmente. Kaggle y otras plataformas hacen que el desarrollo sea más accesible.

Los desarrolladores pueden utilizar los LLM con la IA. Uno de los desarrollos más interesantes es la IA no sólo piensan; hacen. Por sí mismo, la IA basada en el contexto, pero pueden integrarse con otros sistemas externos para realizar tareas como conducir un vehículo autónomo.

Casos de uso de modelos de gran tamaño

Los LLM están redefiniendo los procesos empresariales en innumerables casos de uso en muchos sectores.

- **Generación de texto:** los LLM pueden generar contenido, como redactar correos electrónicos y documentos legales en respuesta a instrucciones.
- **Resumen de textos:** los LLM pueden resumir investigaciones, documentación corporativa y documentos adaptados al formato de resultado y estilo.
- **Asistentes de IA:** los chatbots impulsados por IA responden preguntas y proporcionar información detallada de atención al cliente en tiempo real.

¡Hola! ¿Cómo podemos ayudarte?

- **Generación de código:** las plataformas de desarrolladores a crear aplicaciones, enco problemas de seguridad en múltiples leng entre ellos.
- **Análisis de sentimientos:** se analiza el to feedback de los clientes a escala.
- **Traducción de idiomas:** la traducción aut amplia a organizaciones de todos los idior capacidades multilingües.
- Razonamiento: los LLM pueden resolver p de varios pasos y explicar conceptos com

Evaluación de LLM

Los LLM son herramientas potentes, pero vieri principales preocupaciones es la precisión. D información que es falsa o engañosa y que su reflejar y amplificar los **sesgos** presentes en s resultados injustos u ofensivos. Además, sus entrenar y ejecutar LLM requiere grandes can energía, lo que plantea problemas tanto de c

Los profesionales pueden mitigar estos aspec **gobierno integral de la IA**, los procesos, estar garantizar que los sistemas y herramientas d del gobierno consiste en evaluar los modelos **puntos de referencia de LLM** proporcionan pu comparación de modelos. Dado que los LLM s de realizar una amplia variedad de tareas, su en lugar de un único punto de referencia. Los cualidades como la precisión, la eficiencia, la determinar el rendimiento de un modelo.

Los LLM también se evalúan sobre la base de como el red-teaming, en la que los evaluador produzca respuestas inseguras o sesgadas p: evaluaciones de imparcialidad y sesgo puede LLM reproduzcan estereotipos dañinos o desi

¡Hola! ¿Cómo podemos ayudarte?

Los LLM también se suelen evaluar en función de energía, el rendimiento de tokens, la huella de carbono y el costo. Las métricas de contexto largas son algunas de las métricas con las que los LLM pueden llegar a los resultados.

Una breve historia de

La historia de los LLM se remonta a los primeros modelos de lenguaje natural, cuando los investigadores usaban métodos estadísticos para modelar el texto. Estos modelos aprendían patrones de palabras locales, pero no entendían la semántica más profunda.

Un cambio importante se produjo en la década de los 90 con embeddings de palabras y palabras como vectores en un espacio continuo. Los modelos de relaciones semánticas. Los modelos de secuencia (RNN) y las redes de memoria larga a corto plazo para los datos secuenciales.

En 2017, Vaswani *et al.* introdujeron la [arquitectura de codificador-decodificador](#) en el histórico documento "Attention is all you need". Los transformadores hicieron posible entrenar modelos de lenguaje que marcaron el comienzo de la era moderna de LLM. Los modelos de solo codificador, demostró el poder de los transformadores. Mientras que la serie de transformadores generativos basada en una variante solo de decodificador generativo en texto a escala de internet podría ser notablemente fluida. Casi al mismo tiempo, los modelos como el T5 de Google y el BART de Facebook completaron la secuencia a secuencia para tareas de traducción. (2019) atrajo la atención por su capacidad para generar texto que GPT-3 (2020), con 175 mil millones de parámetros de fuerza transformadora en la IA.

Además, las nuevas arquitecturas están desafiando a los transformadores en los LLM. Los [modelos Mixture of Experts](#) usan un espacio de estados con actualizaciones selectivas para una información pasada, lo que les permite alcanzar un mayor alcance. Los [LLM de difusión](#) comienzan con un

¡Hola! ¿Cómo podemos ayudarte?

paso a paso, guiados por un modelo aprendic
Ambas arquitecturas pueden ser mucho más

Libro electrónico

Cómo elegir el modelo fundacional adecuado

Aprenda a elegir el enfoque
correcto en la preparación de
conjuntos de datos y el empleo
de modelos fundacionales.

[Lea el e-book](#)



Recursos

¡Hola! ¿Cómo podemos
ayudarte?

Modelos de IA

Explore IBM Granite

Descubra IBM Granite, nuestra familia de modelos de IA abiertos, de alto rendimiento y fiables, diseñados para la empresa y optimizados para escalar sus

Libro electrónico

Cómo elegir el modelo fundacional adecuado

Aprenda a seleccionar el modelo fundacional de IA más adecuado para su caso de uso.

[Lea el e-book](#)



Artículo

Descubra el potencial de los LLM

Busque artículos, blogs y tutoriales de IBM Developer y profundice en ellos para ampliar sus conocimientos sobre los LLM.

[Explore los artículos](#)



¡Hola! ¿Cómo podemos ayudarte?

Guía

La guía del CEO para la optimización de modelos

Aprenda a impulsar continuamente a los equipos para que mejoren el rendimiento de los modelos y superen a la competencia utilizando las últimas técnicas e infraestructuras de IA.

[Lea la guía](#)



Informe

Un enfoque diferenciado de los modelos fundacionales de la IA

Explore el valor de los modelos fundacionales de nivel empresarial que proporcionan confianza, rendimiento y beneficios rentables a todos los sectores.

[Lea el informe](#)



Libro electrónico

Desbloquee el poder de la IA generativa + ML

Aprenda a incorporar la IA generativa, el machine learning y los

¡Hola! ¿Cómo podemos ayudarte?

modelos fundacionales en sus operaciones empresariales para mejorar el rendimiento.

[Lea el e-book](#)



Informe

IA en Acción 2024

Lea acerca de las 2000 organizaciones a las que encuestamos sobre sus iniciativas de IA para descubrir qué funciona, qué no y cómo puede adelantarse.


[Lea el informe](#)



1 / 2




Soluciones relacionadas



Modelos fundacionales

Explore la biblioteca de modelos fundacionales de IBM en la cartera de watsonx para escalar la IA generativa para su negocio con confianza.

[Descubra watsonx.ai](#) →




Soluciones de inteligencia artificial

Ponga la IA a trabajar en su negocio con la e

IBM ¡Hola! ¿Cómo podemos ayudarte?

[Explore las soluciones de IA](#) →



Consultoría y servicios de IA

Reinvente las operaciones y flujos de trabajo críticos añadiendo IA para maximizar las experiencias, la toma de decisiones en tiempo real y el valor empresarial.

[Explore los servicios de IA](#) →

Dé el siguiente paso

Explore la biblioteca de modelos fundacionales de IBM en la cartera de IBM watsonx para escalar la IA generativa para su negocio con confianza.

[Explore watsonx.ai](#)



[Explore las soluciones de IA](#)



¡Hola! ¿Cómo podemos ayudarte?

Notas a pie de página

1. “[Attention is all you need](#)”. Vaswani et al, arXiv. 12 de junio de 2017.

¡Hola! ¿Cómo podemos ayudarte?