

Universidad Central

Facultad de Ingeniería y Ciencias Básicas

Maestría en Analítica de Datos



¿Amor u odio en Twitter? Análisis de Sentimientos del Banco de Bogotá basado en
Procesamiento de Lenguaje Natural.

Tesis de Maestría.

Angelica María Susatama Ruiz

Claudia Alejandra Hernández Divantoque

Cristian Felipe Calderón Pérez

Trabajo de grado como requisito para optar el título de:

Magister

Bogotá, Colombia

2022

Universidad Central
Facultad de Ingeniería y Ciencias Básicas
Maestría en Analítica de Datos



¿Amor u odio en Twitter? Análisis de Sentimientos del Banco de Bogotá basado en
Procesamiento de Lenguaje Natural.

Tesis de Maestría.

Angelica María Susatama Ruiz - 1022357822

Claudia Alejandra Hernández Divantoque - 1014184913

Cristian Felipe Calderón Pérez - 1013650017

Director (a)

Jorge Enrique Mejía Quiroga, PhD

Bogotá, Colombia

2022

Aprobación

Director de Tesis

Codirector(a) de Tesis

Firma

Firma

Nombres Completos

Nombres Completos

Títulos

Títulos

Jurados de la Tesis

Jurado

Jurado

Firma

Firma

Nombres Completos

Nombres Completos

Títulos

Títulos

Jurado

Firma

Nombres Completos

Títulos

Dedicatoria

Este trabajo de grado está dedicado a nuestros padres, que siempre han confiado en que día a día seamos mejores personas y profesionales, entendiendo que los días y actividades en familia se tendrían que posponer.

A nuestras parejas que nos dieron el impulso para iniciar este proceso, por apoyarnos en las largas jornadas de trabajo que llevaban a que la noche fuera nuestra más fiel compañera y el tinto nuestro mejor amigo.

Por último, a nuestro director, por el tiempo, sus enseñanzas, su dedicación y apoyo.

Resumen

El Banco de Bogotá (BdB) al igual que muchas empresas, ha incursionado en el mundo de las redes sociales, sin embargo, aún no cuenta con un seguimiento o análisis propio de la información que genera una de ellas, Twitter, por lo que se tiene una alianza con un proveedor. Este se encarga de extraer los tweets en donde se mencionó al banco, los envía a través de correo electrónico al área de comunicaciones del banco con más de 3 envíos diarios según el periodo indicado en la solicitud, motivo por el cual, los datos obtenidos no están siendo utilizados de manera óptima y se está perdiendo una oportunidad bastante grande que le permita obtener beneficios y valor. Con este trabajo se quiere llegar a la identificación de información en textos no estructurados basados en el análisis de sentimientos, combinando distintas técnicas de procesamiento natural, apoyándonos en minería de datos y algoritmos de aprendizaje supervisado. Para lograr obtener un amplio conocimiento del usuario frente a sus menciones hacia el banco, el objetivo principal será implementar una técnica basada en procesamiento de lenguaje natural con el fin de realizar análisis de sentimientos con respecto a los comentarios realizados hacia el BdB en la red social Twitter. El camino iniciará realizando una investigación que permita identificar el método óptimo para el análisis de sentimientos de tweets basados en el procesamiento de lenguaje natural, luego, se aplicarán modelos de AS usando técnicas de procesamiento de lenguaje natural para clasificar los tweets en base a los sentimientos de los usuarios para conocer su opinión con respecto al BdB y por último se evaluarán los resultados generados por los modelos de clasificación implementados, a través de diferentes métricas que permitan identificar cual tuvo mejor desempeño. Apoyados en la metodología ASUM-DM se divide el trabajo en 5 grandes fases: Análisis, diseño, modelamiento, evaluación e implementación. En la fase 1 se realiza el entendimiento del negocio y su relación con la red social Twitter. En la fase 2 se diseña la forma en que se extraerán los Tweets, los métodos de limpieza que se utilizarán, se revisan los métodos de PLN y AS, y por último la forma en que se mostrarán los resultados. En la fase 3, apoyados de los modelos de AS TextBlob y Vader se procesan los

datos y se genera una clasificación de los Tweets en positivo, negativo y neutro. En la fase 4 se realiza un análisis de los resultados tomando una muestra de estos y comparando la clasificación ente cada uno de los modelos. Finalmente, en la fase 5 el desarrollo se mantiene en una fase pre-productiva para una posterior puesta en marcha con el BdB. Todo este desarrollo permitirá identificar el sentimiento de amor u odio en los comentarios generados en Twitter hacia el BdB.

Palabras clave:

Análisis de Sentimientos, Red Social, Procesamiento de Lenguaje Natural, Sector Financiero, Clasificación.

Abstract

The Banco de Bogotá (BdB), like many companies, has ventured into the world of social networks; however, it still does not have monitoring or analysis of the information generated by one of them, Twitter, so it has an alliance with a supplier. This supplier is in charge of extracting the tweets where the bank was mentioned, sending them via email to the bank's communications area with more than three daily messages according to the period indicated in the request, which is why the data obtained are not being used most efficiently; and you're missing out on a pretty big opportunity for profit and value. The purpose of this work is to approach the identification of information in unstructured texts based on sentiment analysis, combining different natural processing techniques supported by data mining and supervised learning algorithms. In order to obtain a broad knowledge of the user regarding his mentions of the bank, the main objective will be to implement a technique based on natural language processing to perform a feeling analysis regarding the comments made towards the BdB in the Twitter social network. The path will begin by carrying out an investigation that allows identifying the optimal method for the analysis of sentiments of tweets based on natural language processing. Then, AS models will be applied using natural language processing techniques to classify tweets based on the sentiments of the users to know their opinion regarding the BdB, and finally, the results generated by the implemented classification models will be evaluated, through different metrics that allow identifying which one had the best performance. Supported by the ASUM-DM methodology, the work is divided into five major phases: Analysis, design, modeling, evaluation, and implementation. In phase 1, the understanding of the business and its relationship with the social network Twitter is carried out. In phase 2, how the Tweets will be extracted are designed, the cleaning methods that will be used, the PLN and AS methods are reviewed, and finally, how the results will be displayed. In phase 3, supported by the AS TextBlob and Vader models, the data is processed and the classification of the Tweets is generated as positive, negative, and neutral. In phase 4, an analysis of the results is carried

out; taking a sample of these and comparing the classification between each of the models. Finally, in phase 5, the development remains in a pre-productive phase for a later start-up with the BdB. All this development will make possible to identify the feeling of love or hate in the comments generated on Twitter towards BdB.

Keywords:

Sentiment Analysis, Social Network, Natural Language Processing, Financial Sector, Classification.

Índice

Dedicatoria	4
Resumen	5
Abstract	7
Introducción	14
Planteamiento del problema y justificación	16
Objetivos	17
Objetivo general	17
Objetivos específicos	17
Antecedentes	18
Antecedentes técnicos de PLN aplicadas al AS	22
Antecedentes de Análisis de sentimientos en Redes Sociales del Sector Bancario en Colombia	27
Metodología	28
1. Análisis	29
2. Diseño	30
3. Modelamiento	32
4. Evaluación	37
5. Implementar	38
Resultados	39
Análisis de clasificación de Vader vs Textblob	40
¿Amor u odio en Twitter del BdB?	45

	10
Discusión de los resultados	51
Conclusiones	53
Lista de referencias	55

Índice de figuras

1.	Cantidad de personas que usan Twitter.	18
2.	Artículos científicos sobre Procesamiento de Lenguaje Natural.	20
3.	Artículos científicos sobre Procesamiento de Lenguaje Natural en la industria bancaria.	20
4.	Intensidad de características del léxico.	25
5.	Analytics Solutions Unified Method (ASUM).	28
6.	Subdivisiones de fases de las metodología ASUM.	29
7.	Arquitectura utilizada en el desarrollo del proyecto.	30
8.	Página general.	45
9.	Página detallada.	46
10.	Nube de palabras positivas OTROS.	47
11.	Nube de palabras negativas OTROS.	48
12.	Nube de palabras negativas BdB.	49
13.	Tweets por mes BdB.	49
14.	Tweets por mes OTROS BdB.	50
15.	Tweets por Día de la semana.	50

Índice de cuadros

1.	Comparación léxicos.	26
2.	Base de datos Resultado Vader.	36
3.	Base de datos Resultado Textblob.	37
4.	Matriz de Confusión.	38
5.	Comparativo modelos y proceso manual	40
6.	Matriz Confusión Vader.	41
7.	Matriz Confusión Textblob.	41
8.	Valores por categoría de Vader.	42
9.	Valores por categoría de Textblob.	42
10.	Resultados por métrica y categoría.	44
11.	Total Tweets.	46
12.	Comentarios positivos.	47
13.	Comentarios negativos.	48

Lista de siglas y abreviaturas

Sigla	Inglés	Español
AS	Sentiment Analysis	Análisis de sentimientos
PLN	Natural Language Processing	Procesamiento de lenguaje natural
BdB	Banco de Bogotá	Banco de Bogotá
AWS	Amazon Web Services	Amazon Web Services
NB	Naive Bayes	
ME	Maximum Entropy (MaxEnt, or ME)	
AMT	Amazon Mechanical Turk	
ASUM-DM	Analytics Solutions Unified Method	
CRISP-DM	Cross industry standard process for data mining	
API	Application Programming	Interfaces de Programación de Aplicaciones
VP		Valores Positivos
FP		Falsos Positivos
VN		Verdaderos Negativos
FN		Falsos Negativos
WSD	Word Sense Desambiguation	Desambiguación Sentido de la Palabra
NLTK	Natural Language Toolking	Kit de Herramientas de Lenguaje Natural

Introducción

El análisis de sentimientos (AS) está inmerso en el campo del Procesamiento de Lenguaje Natural (PLN) y busca identificar, extraer y clasificar opiniones emitidas en un texto mediante un tratamiento o procesamiento computacional.

Los inicios del AS se ubican a principios del siglo XX en diversos estudios sobre opinión pública, cuando se buscaba medirla por medio de cuestionarios y así cuantificar dichos resultados. Dichos estudios, permitieron que después del 2000 tuviera auge el análisis de sentimientos, aunque la mayoría de artículos sobre el tema datan desde el año 2004 en adelante e incluso el tema como tal empieza a ser interés del público en general.

De la misma forma, el PLN centra sus inicios a mediados del siglo XX debido a la constante necesidad de tener sistemas que permitieran la comunicación inteligente entre máquinas y personas. Por ejemplo, durante la Segunda Guerra Mundial se diseñó un sistema que permitía traducir, de manera automática, textos entre diferentes idiomas. Adicional a esto, años después, se desarrolló el programa CANDIDE (Weaver, W. 1955), el cual tenía como objetivo la generación de traducciones automáticas sin necesidad de usar herramientas diferentes a sistemas netamente estadísticos. A diferencia del sistema generado en la Segunda Guerra Mundial, este tuvo resultados muy significativos y positivos ya que la coincidencia era muy alta, lo que fue un hito para la época y permite que hoy en día se tengan herramientas como Google Translate.

Ahora bien, nuestro trabajo se enfocará en una entidad bancaria, más específicamente en el Banco de Bogotá (BdB). Poniendo un poco de contexto, fue el primer banco creado en Colombia, cuenta con una trayectoria de 150 años y tiene como objetivo brindar productos y servicios de calidad al país, en la actualidad hace parte del grupo Aval, su sede principal se encuentra ubicada en la ciudad de Bogotá, cuenta con más de 1.000 oficinas a nivel nacional y aproximadamente 5 millones de clientes.

Ante la necesidad de tener más contacto con sus clientes y los diversos productos que estos tienen con la entidad, junto con la exigencia de captar nuevos consumidores, en el año 2011

y ante la constante evolución de las redes sociales, el BdB decidió ponerse a la vanguardia y crear su servicio en Twitter (@BancodeBogota). Con esta y todas las posibilidades que ofrece la plataforma cualquier usuario desde su cuenta puede interactuar con la cuenta del BdB. Allí es posible publicar tweets dirigidos al BdB tanto positiva como negativamente, expresar su punto de vista y presentar cualquier reclamo o felicitación, haciendo de esta interacción un acceso directo para visualizar incluso la reputación del banco. Es por este motivo, que analizar toda la información que genera esta red social es importante para mejorar la calidad de los productos o servicios.

Planteamiento del problema y justificación

El Banco de Bogotá no cuenta con un seguimiento o análisis propio de la información que se genera en Twitter, por lo que se tiene una alianza con un proveedor. Este se encarga de extraer los tweets en donde se mencionó al banco (@bancodebogota) y los envía a través de correo electrónico al área de comunicaciones del banco. Este llega sin un formato y sin una estructura, allí simplemente se recibe el tweet respectivo, junto con la fecha y una calificación del texto, la cual se divide en positiva, negativa o neutra. Otro aspecto para considerar es la fecha de envío de estos por parte del proveedor de acuerdo con la necesidad del BdB, ya que son más de 3 envíos diarios según el periodo indicado en la solicitud, lo que hace menos eficiente el proceso y conlleva a que la bandeja de correos se vea más saturada y no se lean los mismos. Adicional, es importante aclarar que no hay un repositorio para ir almacenando los datos recibidos. Por consiguiente, los datos obtenidos no están siendo utilizados de la manera óptima y se está perdiendo una oportunidad bastante grande que le permita obtener beneficios y valor. En esencia, el banco está desperdiciando una fuente muy rica de información que es la opinión del cliente frente a los servicios recibidos y es quien le da vida y razón a la entidad.

En síntesis, el problema de este trabajo está enfocado en la identificación de información en textos no estructurados basados en el análisis de sentimientos, combinando distintas técnicas de procesamiento natural, apoyándonos en minería de datos y algoritmos de aprendizaje supervisado. Por tal motivo, el PLN llega a ser útil para efectuar un seguimiento de los comentarios realizados en las redes sociales tales como Twitter. Adicional, se incluirán algunos puntos de visualización que permitan observar la distribución de las palabras más usadas y lograr obtener un amplio conocimiento del usuario frente a sus menciones hacia el banco.

Objetivos

Objetivo general

Implementar una técnica basada en procesamiento de lenguaje natural con el fin de realizar análisis de sentimientos con respecto a los comentarios realizados hacia el BdB en la red social Twitter.

Objetivos específicos

- Realizar una investigación que permita identificar el método óptimo para el análisis de sentimientos de tweets basados en el procesamiento de lenguaje natural.
- Aplicar modelos de AS usando técnicas de procesamiento de lenguaje natural para clasificar los tweets en base a los sentimientos de los usuarios para conocer su opinión con respecto al BdB.
- Evaluar los resultados generados por los modelos de clasificación implementados, a través de diferentes métricas que permitan identificar cual tuvo mejor desempeño.

Antecedentes

Sobre el año 2002 comenzaron a aparecer sitios Web promocionando las redes de círculos de amigos en línea. La popularidad de estos sitios creció rápidamente y compañías como, por ejemplo, Myspace y LinkedIn surgieron en el año 2003, Google lanzó Orkut en 2004 y en el mismo año se dio a conocer Facebook, y en el año 2006 se lanzó Twitter (Nieves, C. D., 2018).




Figura 1. Cantidad de personas que usan Twitter.

Tomado de *Twitter dejará de publicar sus usuarios* por Moreno, G., 2019.

Una de las redes sociales que más auge ha tenido es Twitter. Esta red permite crear perfiles individuales basados en el nivel de permisos que cada usuario determine. Los usuarios pueden seguir a otros usuarios y así convertirse en seguidores. Esta red permite que los grupos de amigos, familiares y compañeros de trabajo se comuniquen y estén en contacto a través de mensajes rápidos y frecuentes. Las personas publican tweets que pueden contener fotos, videos, enlaces y texto. Estos mensajes se publican en el perfil personal, se envían a sus segui-

dores y también se pueden encontrar a través de la búsqueda de Twitter.

El volumen de información que genera una red social como Twitter podría ser analizada mediante técnicas como: el procesamiento del lenguaje natural (PLN) y el análisis de sentimientos. El PLN es: “la habilidad que tiene una máquina para procesar la información comunicada, no simplemente las letras o los sonidos del lenguaje. Un traductor automático sería un ejemplo de dispositivo o software de PLN” (Gelbukh, A., 2010). Pero y ¿qué es el lenguaje natural?, pues es la forma en que el humano busca comunicarse habitualmente con otros humanos. En definitiva, el PLN permite que las máquinas entiendan el lenguaje del humano y lo procese para generar resultados que permitan un análisis.

El PLN tuvo sus orígenes a mediados del siglo XX con la aparición de una nueva disciplina dentro de las ciencias de la computación. Por este tiempo se vio la necesidad de contar con un sistema que permitiera traducir un texto en diferentes idiomas y de forma automática. Uno de los sistemas que se crearon en aquella época fue el conocido como Experimento de Georgetown-IBM, en 1954 (Pauli, 2019). Su enfoque principalmente fue la traducción automática de una serie de frases de temas políticos, ciencias y matemáticas que generaron una impresión del idioma ruso al inglés, este desarrollo generó unas expectativas bastante altas en la sociedad asociando el PLN a sistemas lo suficientemente inteligentes para que la comunicación entre personas y máquinas se hiciese mediante el uso de lenguaje natural.

En la figura 2 se observa que hacia el 2005 con 2000 artículos en la base de datos de bibliografía de Scopus se inició un súbito interés del PLN como campo de estudio. Del 2015 al 2021 el PLN aumentó en casi un 50 %, en el 2021 se cuenta con 11000 artículos sobre este tema lo que equivale a un logro teniendo en cuenta que el campo era reciente. En cuanto a las citas estas aumentaron de forma rápida en comparación con otros campos con más trayectoria.




Figura 2. Artículos científicos sobre Procesamiento de Lenguaje Natural.

Los artículos científicos sobre Procesamiento de Lenguaje Natural en la industria bancaria obtenidos desde Scopus, presentaron lapsos de tiempo donde no se evidencian incrementos. Fue en 2013 cuando se generó el primer avance significativo con 5 artículos publicados, sin embargo, estos disminuyeron a 2 en 2014. No obstante, el interés prestado en temas relacionados con la industria bancaria basados en PLN incrementó notoriamente para el año 2020 con un total de 24 artículos publicados como se observa en la figura 3.




Figura 3. Artículos científicos sobre Procesamiento de Lenguaje Natural en la industria bancaria.

A lo largo de este trabajo abordaremos el análisis de sentimientos basados en el PLN. A partir de ellos se usará la similitud semántica para proporcionar información del estado de ánimo o grado de satisfacción de un determinado usuario analizando sus comentarios. El análisis de sentimientos es una serie de métodos, técnicas y herramientas para detectar y extraer información subjetiva, como opiniones y actitudes (Liu, 2019).

El interés por entender con mayor profundidad la opinión de las personas tuvo sus orígenes de acuerdo con estudios realizados a principios del siglo XX, por medio de cuestionarios que permitían realizar una medición se intentó captar la opinión pública. Y en 1937 se crea la primera revista científica de opinión (Public opinion quarterly, Online)

También se encontraron escritos de temas como cadenas de opinión y el análisis de subjetividad de los textos para el año 1990. En una búsqueda de literatura realizada por Mäntylä (2018) hallaron artículos que coincidieron con la investigación de la opinión pública con naturaleza principalmente política, sobre la Segunda Guerra Mundial. Con esto se observó cómo los líderes se empezaron a preocupar por la opinión de sus pares o subalternos pues ayudaban a prepararse para la oposición o para mejorar sus propuestas.

Según Mäntylä (2018), en su artículo The evolution of sentiment analysis, luego de que el análisis de texto o comentarios tuviera sus primeros pines no se logró ahondar más en estos temas hasta el resurgimiento del análisis de sentimientos moderno ocurrido en el 2000, el cual estuvo marcado principalmente por las revisiones de productos disponibles en la Web. Lo que lleva a comprender por qué la mayoría de los artículos publicados de análisis de sentimiento aumenta notablemente después del 2004, desde entonces el uso del análisis de sentimientos ha llegado a muchas otras áreas, como la predicción de los mercados financieros.

El procesamiento del lenguaje natural y el análisis de sentimientos ha abordado muchos problemas que contribuyen a la aplicabilidad y avance en temas de análisis de opiniones, como la detección de ironías y soporte multilingüe. Además, con respecto a las emociones, los esfuerzos están avanzando desde la simple detección de la polaridad hasta los matices más

complejos de las emociones y la diferenciación de las sensaciones negativas como la ira y el dolor. El área de análisis de sentimientos se ha vuelto tan grande que cualquier investigador individual enfrentaría varios problemas al realizar un seguimiento de todas las actividades en el área y la sobrecarga de información (Mäntylä , 2018).

El análisis de sentimientos fue pasando de revisión de comentarios de productos en línea a realizar análisis de texto en redes sociales como Twitter, Facebook, entre otras. Este campo de investigación ha permitido generar un acercamiento entre los usuarios y las empresas, dar un servicio de calidad, ofrecer nuevos productos, segmentar los clientes de acuerdo a sus publicaciones, y un sinfín de beneficios.

Antecedentes técnicos de PLN aplicadas al AS

Las técnicas encargadas de desempeñar dichos análisis deben ser precisas y efectivas, así mismo se basan en léxicos preexistentes contruidos manualmente. Estas técnicas tienen como puntos de referencia léxicos utilizados ampliamente y que son la base de muchas de las usadas en el PLN, como Vader en el presente proyecto. En primera instancia mencionaremos LIWC, GI & Hu-Liu basados en el documento de Hutto, C. J., & Gilbert, E. (2014), en estos tres las palabras se clasifican en clases binarias según su orientación semántica (positivo o negativo).

LIWC es una herramienta de análisis de sentimiento que es fácil de usar, transparente, rápida y precisa. Como resultado, ha sido ampliamente utilizado por sociólogos, psicólogos, informáticos y lingüistas en una serie de dominios de educación y redes sociales (Hutto & Gilbert, 2014). Por ejemplo, el léxico de LIWC se ha utilizado para extraer indicios de sentimiento político de los tweets (Tumasjan, Sprenger, Sandner y Welp, 2010), Es importante aclarar que LIWC no considera elementos tales como emoticones, iniciales o acrónimos que llegan a ser importantes en el análisis.

GI es una aplicación de análisis de texto que usa uno de los léxicos antiguos que se han contruido manualmente, se ha venido mejorando desde 1966 y es usada constantemente. Su

léxico se ha utilizado ampliamente en varios trabajos para determinar automáticamente las propiedades de sentimiento del texto (Esuli y Sebastiani, 2005). Al igual que LIWC carece de esa característica que permite asignarle intensidad a las palabras que transmiten sentimientos. Hu-Liu por su parte, sí está un poco en sintonía con expresiones de sentimientos en textos de redes sociales, aunque tampoco captura emoticones. Este fue construido a partir de una base de datos léxica en inglés llamada WordNet y contiene actualmente un aproximado de 6800 palabras en su léxico.

Ahora bien, se usan otros léxicos como ANEW y SenticNet que manejan la intensidad según el sentimiento basado en el texto. The Affective Norms for English Words (ANEW) proporciona un conjunto de calificaciones emocionales normativas para 1.034 palabras en inglés (Bradley & Lang, 1999). Es aquí cuando a diferencia de LIWC o GI, las palabras se clasifican según su intensidad. Esta clasificación se ve reflejada en puntuaciones de 1 a 9 donde 5 es neutral, menores a 5 se pueden considerar negativas y mayores a 5 positivas. SenticNet es un recurso semántico y afectivo disponible públicamente para el análisis de opiniones y sentimientos a nivel de concepto (Cambria, Havasi y Hussain, 2012). Este léxico está compuesto por aproximadamente 12000 conceptos de sentido común como ira, adoración y admiración. Por último, para que el rendimiento del análisis sea mejor se usa la comprensión de propiedades léxicas más profundas. Un léxico puede ajustarse aún más, de acuerdo con un proceso de desambiguación del sentido de las palabras (WSD) (Akkaya, Wiebe y Mihalcea, 2009). Esto quiere decir básicamente, qué sentido de una palabra determinada se usa en una oración cuando esta tiene diferentes significados contextuales.

El trabajo mencionado anteriormente se basa en léxicos que requieren de creaciones y validaciones manuales por lo que se acude a enfoques de aprendizaje automático y así las características del texto que sean importantes en el texto sean “aprendidas”. A partir de los diferentes tipos de léxicos y de los enfoques de aprendizaje automático, se buscaba construir un modelo de análisis de sentimientos que funcione de manera correcta dentro del ámbito

de las redes sociales, aparte que no requiera datos de entrenamiento, pero si use un léxico (sensible a polaridad e intensidad) de sentimientos previamente construido. Este léxico, al ser construido manualmente, llega a ser un proceso complejo que incluso puede tener errores, por lo que basarse en léxicos previamente construidos se considera como una base. Dicha construcción, toma una lista de palabras de bancos de palabras ya establecidos y nombrados en instancias previas de este documento (LIWC, ANEW y GI), adicional se incorporó una lista de emoticones junto con expresiones que representan sentimientos como LOL o WTF.

A partir de lo anterior, se obtuvieron más de 9.000 características léxicas que posteriormente se evaluaron para validar la aplicabilidad de estas a las expresiones de sentimiento y así adquirir una estimación puntual válida del sentimiento (intensidad). Adicionalmente, se recopiló una calificación de intensidad para cada una de las características léxicas a partir de 10 evaluadores humanos, por lo que se llegó a más de 90.000 características léxicas. La clasificación que se hizo se dio en una escala de -4 a 4, donde -4 es extremadamente negativo y 4 extremadamente positivo, mientras que 0 es una escala neutral.

Las calificaciones se generaron a través de Amazon Mechanical Turk o AMT. Este es un sitio web de microempresas en el cual los trabajadores reciben dinero elaborando tareas menores, para este caso la selección de los sujetos fue a través de un proceso dividido en varias etapas y así los seleccionados tuvieran las mejores cualidades para el ejercicio. Entre las pruebas elaboradas, una de ellas consistía en un test de lectura y comprensión en inglés, donde la calificación debía superar el 80 %, posteriormente completar sesiones de capacitación para calificación de sentimiento con puntuación mayor al 90 %.

A continuación, se muestra la interfaz usada para determinar la intensidad de cada característica comprendida en el léxico.

ROFL	Description: Rolling On Floor Laughing
-------------	--

☐ [-1] Slightly Negative

☐ [-2] Moderately Negative

☐ [-3] Very Negative

☐ [-4] Extremely Negative

☐ [0] Neutral (or Neither, N/A)

☐ [1] Slightly Positive

☐ [2] Moderately Positive

☐ [3] Very Positive

☐ [4] Extremely Positive

Figura 4. Intensidad de características del léxico.

Tomado de *VADER: A parsimonious rule-based model for sentiment analysis of social media text* (p.221), por Hutto, C. J., & Gilbert, E., 2014.

Este ejercicio, resultó en poco más de 7.500 características léxicas, ya que se mantuvieron las características léxicas que tenían una calificación media distinta de cero y cuya desviación estándar fuera inferior a 2.5, esto teniendo en cuenta a los 10 evaluadores independientes. Este fue el léxico Vader definitivo y el cual cuenta con la valencia asociada a cada característica. Un análisis posterior tomado de una muestra de 800 tweets, dividida intencionalmente en mitad positivos y la otra mitad negativos permitieron identificar cinco puntos clave que influyen en la intensidad del sentimiento.

1. La puntuación aumenta la intensidad sin modificar la orientación semántica.
2. El uso de las mayúsculas en palabras relevantes o el uso de mayúsculas en todas las palabras aumenta la intensidad.
3. Las palabras de refuerzo afectan la intensidad del sentimiento dependiendo de la palabra que se llegue a usar.
4. La conjunción adversativa “but”, pero en español, señala un cambio en la polaridad del sentimiento, siendo dominante el sentimiento que sigue a la conjunción.
5. Casi en el 90% de los casos la negación cambia la polaridad del texto cuando el trigramma¹ precede a una característica léxica cargada de sentimientos.

A partir de estas 5 premisas se tomaron 30 tweets de referencia y a partir de dicho texto se

¹Una manera de comprender el significado de las palabras en base al contexto

elaboraron de 6 a 10 variaciones. Estas variaciones dieron como resultado aproximadamente a 200 tweets artificiales que fueron aplicados a otro conjunto similar. Posterior a esto, otros trabajadores seleccionados de AMT se encargaron de evaluar el impacto de dichas variaciones en la intensidad del sentimiento. Esto permitió incorporar al modelo Vader las diferencias medias entre cada distribución, por ejemplo, se identificó que el signo de exclamación aumentó la intensidad con una diferencia media de 0.291, al igual que aplicar la condición 4 aumentó en un 50 % la intensidad del texto después de la conjunción “but”. Esto permite enfatizar la intensidad del sentimiento en la columna Compound, por ende, esta será la calificación por usar y así determinar el sentimiento del tweet en el desarrollo del presente trabajo.

Para la evaluación de resultados se tomó a Vader como léxico de sentimientos principal frente a otros 7 léxicos ya establecidos y funcionales. Los resultados obtenidos muestran que Vader es bastante preciso y funciona muy bien en el ámbito de las redes sociales, como lo muestra el cuadro 1.

	Correlation to ground truth (mean of 20 human raters)	3-class (positive, negative, neutral) Classification Accuracy Metrics		
		Overall Precision	Overall Recall	Overall F1 score
Social Media Text (4,200 Tweets)				
Ind. Humans	0.888	0.95	0.76	0.84
VADER	0.881	0.99	0.94	0.96
Hu-Liu04	0.756	0.94	0.66	0.77
SCN	0.568	0.81	0.75	0.75
GI	0.580	0.84	0.58	0.69
SWN	0.488	0.75	0.62	0.67
LIWC	0.622	0.94	0.48	0.63
ANEW	0.492	0.83	0.48	0.60
WSD	0.438	0.70	0.49	0.56

Cuadro 1: Comparación léxicos.

Tomado de *VADER: A parsimonious rule-based model for sentiment analysis of social media text* (p.223), por Hutto, C. J., & Gilbert, E., 2014.

Según la evaluación realizada por Hutto & Gilbert (2014) se muestran diferentes ejemplos donde Vader tiene el mejor desempeño ya que el coeficiente de correlación de Pearson es muy

parecido al evaluador humano y en cuanto al F1 se observa que es muy alto frente a los demás lo cual puede notar que la precisión y la tasa de verdaderos positivos correctamente identificados es muy buena.

Antecedentes de Análisis de sentimientos en Redes Sociales del Sector Bancario en Colombia

Los antecedentes de análisis de sentimientos en el sector bancario en Colombia contienen poca información en términos investigativos. Se observa un estudio no formal realizado por Barros (2020). En este estudio tomaron 3 bancos colombianos (Bancolombia, Banco de Bogotá y Davivienda), los datos los generaron a partir de la API de Twitter, desde Jupyter Notebook de AWS SageMaker, con hashtag específicos de cada uno de los bancos mencionados, generando así toda la información correspondiente a los comentarios de los clientes. Utilizaron algunos modelos de AWS pre-entrenados, que le permitieron clasificar cada comentario en tres puntajes (scores) totalmente diferentes: positivos, negativos y neutrales.

En ese mismo sentido, las preguntas planteadas para el análisis fueron:

¿Qué banco tiene mayor número de tweets?

¿Cuál es la percepción de los clientes de la ciudad donde el banco tiene su sede principal?

¿Cuál es la percepción de los clientes clasificados por ciudades?

En el análisis realizado se concluyó que

“el banco que tuvo mayor número de tweets en las fechas comprendidas entre 16/06/2020 y 23/06/2020 fue Bancolombia con un total de 49 frente a 7 y 32 de Banco de Bogotá y Davivienda respectivamente, se puede concluir de esta manera que los clientes de Bancolombia fueron más activos en las fechas especificadas frente a los clientes de los otros dos bancos. Es importante resaltar que para el caso de Banco de Bogotá y Davivienda cuyas sedes principales se encuentran en la ciudad de Bogotá sus clientes tienen una percepción neutra. Caso contrario sucede con Bancolombia con sede principal en Medellín donde presentó mayor índice de percepción negativa hacia el banco comparado con la percepción positiva” (Amador, C. J. B, 2020).

Metodología

Para llevar a cabo el presente trabajo de grado la metodología que se usará es ASUM-DM (Analytics Solutions Unified Method) propuesta por IBM en el año 2015. Dicha metodología está basada en CRISP-DM (Cross industry standard process for data mining). ASUM-DM hace énfasis en las nuevas prácticas en la ciencia de datos como el uso de volúmenes de datos muy grandes, la incorporación de análisis de texto, en el modelado predictivo y la automatización de algunos procesos (Bahrepour, M., 2018).

Esta metodología de minería de datos fue seleccionada entre otras gracias a que con su diseño se puede efectuar una implementación completa del ciclo de vida de un proyecto. Ayuda a acelerar el tiempo para generar valor y disminución de riesgos mediante el establecimiento de enfoques y procesos coherentes que aumentan la eficiencia de su implementación (Bahrepour, M., 2018). Aporta, además lineamientos y reglas para cumplir con los objetivos trazados permitiendo establecer planes de trabajo completos.

Esta metodología se basa principalmente en 5 grupos 1. (Analizar), 2. (Diseñar), 3. (Configurar y construir) 4. (Implementar) 5. (Operar y optimizar)




Figura 5. Analytics Solutions Unified Method (ASUM).

Tomado de *Exploratory Data Analysis of Fault Injection Campaigns* (p.195), por Cerveira & Kocsis, 2018.

Estos a su vez se dividen en 10 fases que permiten detallar de una manera más ordenada el

trabajo realizado en el proyecto.




Figura 6. Subdivisiones de fases de las metodología ASUM.
Tomado de Perfil Alianza Caoba.

A continuación, se desarrollan cada una de las fases mencionadas en la figura 6:

1. Análisis

Comprensión del Negocio.

La falta de consumo y análisis de información de fuentes como Twitter hace que las entidades no generen provecho de las bondades del procesamiento de lenguaje natural que por medio de sus diferentes modelos permiten entender de mejor manera a sus principales objetivos: Los clientes.

Enfoque analítico.

El enfoque analítico de este proyecto está basado en el uso de un modelo apoyado en Léxico para el Análisis de sentimientos.

2. Diseño

Para este proyecto se elaboró una solución, la cual parte de un proceso de extracción de tweets, que luego se modela en un entorno de desarrollo, posteriormente se almacena en una base de datos para finalmente plasmarla en una herramienta de visualización (Figura 7). El proceso de extracción se realiza por medio de la conexión a la API de Twitter, permitiendo obtener los datos básicos registrados en el momento en que el usuario publica el Tweet.

Anaconda es el entorno que permite efectuar las transformaciones necesarias de la información que se almacena en la base de datos seleccionada PostgreSQL. Por último, la etapa de visualización se desarrolla en la herramienta Power BI que permitirá comprender y analizar los resultados del proceso para facilitar la toma de decisiones del negocio.




Figura 7. Arquitectura utilizada en el desarrollo del proyecto.

Tomado de Fuente propia.

Requisitos de los datos. Para la elaboración del proceso se incluyó información obtenida a través del API de Twitter, basándonos en tres menciones: @bancodebogota, @banco de bogotá, @bancobogota. El primero corresponde a la cuenta oficial del banco, mientras que los dos restantes son variantes que los usuarios tienden a utilizar para referirse a la entidad. A partir de estos se generan los campos: y a continuación detallamos los más importantes:

- ID: Dígito numérico único de identificación del Tweet.
- Date: Fecha de publicación del Tweet.
- Language: Idioma del Tweet.
- Tweet: Escrito de máximo 280 caracteres donde el usuario expresa opiniones y sentimientos.
- Usuario: Indica el usuario que genera el Tweet

Recolección de los datos. Nos basaremos en los comentarios generados a través de la plataforma Twitter donde mencionen la cuenta oficial del Banco de Bogotá (@bancodebogota, @banco de bogotá, @bancobogota). Para poder efectuar dicho proceso debemos realizar la respectiva autenticación frente a la API de Twitter y de esta manera poder generar los diversos procedimientos que son requeridos. Esta autenticación requiere la creación de una aplicación en Twitter, para ello se accede a apps.twitter.com. Al crear dicha aplicación serán proporcionadas 4 credenciales. Estas son:

1. consumer_key = ""
2. consumer_secret = ""
3. access_token = ""
4. access_token_secret = ""

Con estas 4 credenciales ya listas, debemos declararlas con su respectivo contenido. Junto con esto, se procede a crear en Spyder (entorno gratuito de código abierto escrito en python) una clase con el método que realiza la conexión al API de Twitter, para lo cual nos apoyamos en la librería denominada Tweepy y la librería Json. Tweepy nos permite acceder, comunicarnos e

interactuar con el API de Twitter haciendo llamados a diversas funciones mientras que JSON muestra la información de una manera agradable o bonita.

Se usarán dos líneas adicionales (`auth = tweepy.OAuthHandler(consumer_key, consumer_secret)` & `auth.set_access_token(access_token, access_token_secret)`) que permitirán efectuar la autenticación invocando las credenciales previamente declaradas. Finalmente se creó una variable llamada API que será la que nos permite realizar los llamados al API de twitter usando tweepy.

Dentro de esta variable se declaran dos parámetros para evitar que el programa se caiga si nos quedamos sin el cupo que brinda Twitter para descargar datos. Estos lo que hacen es esperar que se vuelva a habilitar el cupo para continuar el proceso.

Preparación de los datos.

- Emojis: La polaridad se ve afectada por los emojis, motivo por el cual se toman en cuenta en el análisis
- Stop words: Se eliminan las palabras que no cuentan con suficiente importancia dentro del Tweet, palabras vacías por su definición en español.²
- Caracteres especiales: Se eliminan caracteres especiales y signos de puntuación
- Mayúsculas: La intensidad varía cuando una palabra lleva mayúsculas, motivo por el cual no se le aplica ninguna transformación
- Traducción: La traducción de los tweets a idioma inglés se realiza por medio de una API de Python gratuita (`google_trans_new`), esta interfaz fue definida sólo para uso académico por lo cual tiene ciertas restricciones de traducción con volúmenes muy altos de datos.

3. Modelamiento

Preprocesamiento de datos. La limpieza de datos permite identificar datos repetidos, incorrectos o no pertinentes, este paso hace parte del inicio del modelamiento del proyecto dando

²Ejemplos de Stopwods o palabras vacías: de, el, la, en, como, bien. Son conjunciones, preposiciones, adverbios y artículos.

uso a funciones propias de Python en Spyder para llevar a cabo esta tarea. La eliminación de los datos duplicados fue el punto de partida asegurando de esta manera no contar con Tweets repetidos dentro de la base. Adicionalmente los retweets no se tienen en cuenta dentro del proceso de extracción. Se realiza la limpieza con el uso de expresiones regulares por medio de la función RE de Python, aplicada de forma que si coincide algún conjunto de cadenas como ejemplo: 'http\S+', '#', 'l', '@[A-Za-z0-9]+' se eliminan estos patrones de texto. Otra cadena utilizada es string.punctuation la cual contiene todos los signos de puntuación permitiendo de forma eficaz ser eliminados en cada uno de los Tweets.

Continuando con el preprocesamiento se realizó una eliminación de datos inútiles o palabras de parada (Stop Words) tanto en idioma español como en inglés. Estas palabras no tienen un significado por sí solas, sino que modifican o acompañan a otras, este grupo suele estar conformado por artículos, pronombres, preposiciones, adverbios e incluso algunos verbos. (Olave, 2021).

Finalmente, para lograr como requisito previo a aplicar los modelos de análisis de sentimientos se realizó una traducción de los Tweets en los que se nombra al BdB estos son escritos en español, por lo tanto, es necesario traducirlos al inglés, debido a que el léxico construido para la librería de análisis de sentimientos denominada vader se elaboró en este último idioma. Para este fin se invoca la librería denominada google_trans_new que se encarga de traducir el texto indicado al idioma requerido. Es importante aclarar, que el traductor al ser gratuito tiene un límite de traducciones diarias por lo que no es posible enviar en una misma ejecución una gran cantidad de registros.

Una vez realizada la descarga y traducción de los tweets se busca la forma de almacenar los datos para poder ser analizados en cualquier momento. Se toma la decisión de usar una base de datos estructurada, después de indagar diferentes opciones, se escoge la base de datos PostgreSQL, esta es una base de datos “PostgreSQL es un potente sistema de base de datos relacional de objetos de código abierto con más de 30 años de desarrollo activo que le

ha ganado una sólida reputación por su fiabilidad, solidez de funciones y rendimiento”. (PostgreSQL>About, 1996).

Se realiza la instalación de la base de datos PostgreSQL y de la librería de python psycopg2, esta última permite la conexión desde el ambiente de trabajo de Spyder (lenguaje python) a la base de datos. Se configuran las cadenas de conexión entre las dos plataformas y una vez comprobada, se incluye el código que permite enviar datos a PostgreSQL desde spyder, se crea una tabla llamada datos, esta contiene las columnas correspondientes a: ID, date, Tweet, Language, TweetsIngles, FinalTweet, TweetLimpio, User. La información guardada en estos campos permite ser analizada en cualquier momento del proceso.

Debido a que la cantidad de tweets que se pueden descargar solo corresponde a 7 días inmediatamente atrás, es necesario correr el proceso cada semana para poder recolectar una cantidad suficiente de datos. Debido a esto se realiza una automatización para que por medio de una tarea programada de Windows los lunes de todas las semanas se ejecuten los programas que descargan y almacenan los Tweets. La automatización consiste en crear un archivo con formato bat que apunta a la ruta de los ejecutables de python y a los archivos con el código que permite generar los datos usados en el presente proyecto:

- Archivo cls_carga_datos: contiene todos los métodos que permiten la descarga, traducción, y análisis de los Tweets
- Archivo usar_clase_Twitter: permite invocar los métodos del archivo anterior.

Se realizan pruebas en las máquinas de cada uno de los integrantes para determinar los tiempos de procesamiento, se observa que en el equipo que tiene mejores especificaciones de hardware (Procesador Core I5 10TH Gen, 8GB RAM, Disco Duro SSD 512GB) el proceso dura alrededor de 7 minutos, motivo por el cual se decide realizar la automatización en esa máquina.

Procesamiento de los datos. El análisis de sentimientos aplicado en el presente proyecto está basado y fue aplicado mediante un modelo simple basado en reglas de léxico denominado Vader (Valence Aware Dictionary and sEntiment Reasoner). Se debe instalar y luego invocar

VaderSentiment para posteriormente usarlo. Para dicho análisis, generamos un método que tome el texto del comentario y a partir de este genere un resultado basado en puntuaciones. El sentimiento se verá expresado de la siguiente manera:

- neu/Neutral : La probabilidad de que el sentimiento sea neutro
- pos/Positive : La probabilidad de que el sentimiento sea positivo
- neg/Negative : La probabilidad de que el sentimiento sea negativo

Adicional a esto, se puede traer una métrica que permite calcular la suma de todas las calificaciones del léxico y toma valores de -1 a 1 lo cual permite obtener la intensidad del tweet.

compound/Compound: La puntuación compuesta normalizada

Bajo estas condiciones, y con base a lo anteriormente suministrado se crea una nueva columna que clasifica el compuesto o Compound de la siguiente forma:

$-0.05 < \text{Compound} < 0.05 \rightarrow \text{Neutral}$

$\text{Compound} \leq -0.05 \rightarrow \text{Negative}$

$\text{Compound} \geq 0.05 \rightarrow \text{Positive}$

Una vez evaluados los datos usando Vader, se almacenan en una tabla llamada Resultado-Vader, en la base de datos de postgresQL, la cual contiene el tweet evaluado y los campos anteriormente mencionados. La columna Compound nos permitirá identificar de una manera más específica la clasificación dada para cada tweet basándose en las 5 reglas mencionadas en la sección de antecedentes técnicos, razón por la cual no son usadas las columnas Negative, Neutral y Positive. Ver cuadro 2.

postgres/postgres@PostgreSQL 12								
Data Output Explain Messages Notifications								
	ID bigint	date text	Compound double precision	Negative double precision	Neutral double precision	Positive double precision		FinalTweet text
1	1431074481821343756	27-08-2021	0	0	1	0		Julysieran mjossecallos bancodebogota I left Messa
2	1431074209799811073	27-08-2021	0.5574	0.104	0.577	0.319		MjoseBallos Hello Maria Let us validate case Share t
3	1431073533719945220	27-08-2021	-0.0772	0.208	0.604	0.188		Julysieran bancodebogota I almost stay Market Boyfr
4	1431073424496119808	27-08-2021	0.3182	0.093	0.728	0.179		MjoseBogota bancodebogota Yes I tried pay withdraw
5	1431073119238774784	27-08-2021	-0.3182	0.365	0.635	0		MjoseBallos bancodebogota happens 🤔
6	1431072260899676162	27-08-2021	-0.5423	0.236	0.671	0.093		Good evening bancodebogota Are maintenance platfo
7	1431071088755236865	27-08-2021	0	0	1	0		[...] informed clients cost services offer
8	1431071088755216386	27-08-2021	0.6705	0	0.766	0.234		[...] Hello welcome Red Facebook thank write us We t
9	1431066622811414529	27-08-2021	-0.5267	0.24	0.667	0.093		Grupoaval bancodebogota bco occidient bco popular b
10	1431065945234190341	27-08-2021	-0.6697	0.243	0.757	0		BanCodeBogota Robe X Collect ATM Retreats more
11	1431064258981376001	27-08-2021	0.5994	0	0.67	0.33		Juandepapel Hello Juan please greet you Indicious D
12	1431063823394525186	27-08-2021	0	0	1	0		How I communicate Bancodebogota exterior I urgentl
13	1431061555739779072	27-08-2021	0.5423	0	0.471	0.529		Bancodebogota I feel overwhelmed much generosity
14	1431059671268331524	27-08-2021	0.8176	0	0.533	0.467		[...] You contacted area commissioned send data If w
15	1431059510051971074	27-08-2021	0.4215	0.14	0.562	0.298		[...] Hello We offer inconvenience We tell channel hel

Cuadro 2: Base de datos Resultado Vader.

El texto de la fila 13 (ver cuadro 2) está clasificado en el umbral positivo debido a la generosidad recibida por el BdB.

Con el fin de comparar los resultados arrojados por el modelo de Vader y comprobar la precisión del mismo, se realiza el ejercicio de clasificación con otro método de análisis de sentimientos llamado Textblob. Este se apoya en el poder de NLTK y así logra su máximo potencial. Esta última, es básicamente una plataforma usada para crear programas de Python, funciona como un conjunto de herramientas de lenguaje natural donde existen diversas bibliotecas para el uso de acuerdo a la necesidad. Las ventajas de este, radican en la facilidad de uso y la gran documentación que tiene, además de ser gratuito y de código abierto.

Basado en lo anterior,

“TextBlob es una biblioteca de Python para procesar datos textuales. Proporciona una API simple para sumergirse en tareas comunes de procesamiento de lenguaje natural (NLP), como el etiquetado de partes del discurso, la extracción de frases nominales, el análisis de sentimientos, la clasificación, la traducción y más.” (Loria, 2020).

Textblob devuelve la polaridad de una oración, esta toma valores entre -1 y 1, las oraciones

con valores -1 se define como sentimiento negativo y las oraciones con valores en 1 se define como sentimiento positivo, las palabras de negación invierten la polaridad. Mientras que las definidas en 0 son catalogadas como Neutras. Para poder utilizar esta herramienta es necesario instalar la librería textblob, la cual se invoca desde el programa que se realiza el análisis sobre los tweets descargados. Este análisis se almacena en una tabla llamada ResultadoTextBlob, la cual contiene el tweet evaluado y la evaluación de polaridad. (Ver cuadro 3)

postgres/postgres@PostgreSQL 12				
Data Output Explain Messages Notifications				
ID	date	Polarity	Tweet	
bigint	text	double precision	text	
1	1431074481821343756	27-08-2021	0	@JudySierraN @MJoseCeballos @BancodeBogota Me salia mensaje excedí monto dinero
2	1431074209799811073	27-08-2021	0.25	@MJoseCeballos Hola, Maria. Permitenos validar caso. Compártenos favor través Mensaje Directo número cédula junto pantal
3	1431073533719945220	27-08-2021	0	@JudySierraN @BancodeBogota Yo tampoco casi quedo mercadito novio salvó 🙄
4	1431073424496119808	27-08-2021	0	@MJoseCeballos @BancodeBogota Sí, intenté pagar, retirar efectivo entrar página pude hacer nada.
5	1431073119238774784	27-08-2021	0	@MJoseCeballos @BancodeBogota Me pasa mismo 😊
6	1431072260899676162	27-08-2021	0.09999999999999998	Buenas noches @BancodeBogota ¿Están realizando algún mantenimiento plataformas? Intenté pagar tarjeta almacén generó e
7	1431071088755236865	27-08-2021	0	@juniorrojas2014 Informados clientes acerca costo servicios ofrecemos.
8	1431071088755216386	27-08-2021	0.4	@juniorrojas2014 Hola bienvenido red Facebook, gracias escribimos. Te contamos tarifas aplicables cada servicios Banco esti
9	1431066622811414529	27-08-2021	0.6	@grupoavai @BancodeBogota @Bco_Occidente @Bco_Popular @Banco_AvVillas Bloque bloque Luis Carlos Sarmiento país car

Cuadro 3: Base de datos Resultado Textblob.

4. Evaluación

Para evaluar la clasificación de los modelos de Vader y textblob se califican manualmente una muestra Tweets (para más detalle dirigirse a la sección de resultados), una vez realizado dicho proceso se trabaja con las matrices de confusión: “Es una de las métricas más relevantes en el aprendizaje automático ya que describe el rendimiento de cualquier modelo implementado” (Arias, 2020).

En el siguiente cuadro se representa una matriz de confusión con sus diferentes opciones de clasificación.

VALORES PREDICCIÓN	Verdaderos Positivos	Falsos Positivos
	Falsos Negativos	Verdaderos Negativos
VALORES REALES		

Cuadro 4: Matriz de Confusión.

A continuación, se define cada uno de los cuadrantes del cuadro anterior:

- Verdadero positivo: El valor es positivo y el modelo también predijo que era positivo.
- Verdadero negativo: El valor es negativo y el modelo también predijo que era negativo.
- Falso negativo: El valor es positivo, y el modelo predijo que es negativo.
- Falso positivo: El valor es negativo, y el modelo predijo es positivo.

5. Implementar

Este trabajo terminaría en una fase preproductiva teniendo en cuenta que todas las herramientas utilizadas son de versión gratuita, por lo tanto, tiene limitantes como la cantidad de usuarios, cantidad de servidores, cantidad de información a descargar (uso de API básico y gratuito), entre otros. Para llevar el proyecto actual a una fase productiva se deben evaluar las herramientas permitidas y la debida seguridad que requiere el banco, además de establecer los proveedores y costos que esto implique, lo cual no está dentro del alcance de este proyecto.

Resultados

A la fecha de elaboración del presente documento se cuenta con 13.044 Tweets descargados en un período de 6 meses comprendido entre agosto 2021 y enero 2022, usando las menciones de @bancodebogota, @banco de bogotá, @bancobogota. Tomamos una muestra cuyo tamaño está calculado estadísticamente, para elaborar la matriz de confusión y posteriormente sus respectivas métricas que nos permitirán comparar los resultados de los modelos usados en el proyecto y así poder proyectar de una manera confiable los resultados de los mismos. Se deben tener en cuenta tres ítems: El tamaño de la población (en nuestro caso la cantidad total de tweets descargados), el margen de error y el nivel de confianza. A continuación, se muestra la fórmula que nos permitió calcular el tamaño de la muestra:

$$n = \frac{N * Z_{\alpha}^2 * p * q}{e^2 * (N - 1) + Z_{\alpha}^2 * p * q} \quad (1)$$

N= Tamaño total de la muestra

Z= Parámetro estadístico dependiente del nivel de confianza

e= Error de estimación máximo aceptado

p= Probabilidad de éxito

q= Probabilidad de fracaso

El resultado de efectuar dicho cálculo, nos da un tamaño de muestra buscado (n) de 373 tweets.

Según esto, procedemos a tomar aleatoriamente dicha cantidad de nuestra base de datos tanto para Vader como Textblob teniendo en cuenta que los tweets deben ser iguales en ambos casos. Con dicha muestra ya extraída, manualmente le asignamos una calificación a cada registro que nos permite comparar contra los modelos previamente usados. La calificación manualmente dada, se establece con base en nuestra percepción de la siguiente manera: Los tweets con valores -1 se definen como sentimiento negativo y los tweets con valores en 1 se

definen como sentimiento positivo, mientras que los tweets con valor 0 se definen como sentimiento neutro. Esta definición se basó en la clasificación que usan los modelos donde su rango de clasificación se define para cada tweet está definido entre -1 y 1, a partir de esto se asignaron los correspondientes valores teniendo en cuenta el contexto de la oración junto con las palabras allí contenidas.

El resultado del proceso manual y los modelos se representa en el siguiente cuadro:

	VADER	MANUAL	TEXTBLOB
POSITIVOS	204	132	161
NEGATIVOS	94	131	75
NEUTROS	75	110	137
Total	373	373	373

Cuadro 5: Comparativo modelos y proceso manual

Como se indicó al principio de esta sección, se elaboran las matrices de confusión de acuerdo al modelo implementado.

Análisis de clasificación de Vader vs Textblob

Matrices de confusión. Se construyen las matrices de confusión con base en los resultados obtenidos para cada uno de nuestros modelos. En el Cuadro 6 la matriz de confusión del modelo Vader se observa que de la muestra tomada este clasificó 373 Tweets entre positivo, negativo y neutro, sin embargo, aproximadamente el 25 % de estos se clasificaron como positivos siendo negativos y no clasifica ningún tweet negativo siendo positivo.

		VALORES REALES		
		Positivo	Negativo	Neutro
VALORES PREDICCIÓN	Positivo	132	72	0
	Negativo	0	94	0
	Neutro	0	0	75

Cuadro 6: Matriz Confusión Vader.

La matriz de confusión para el modelo de Textblob (Cuadro 7) arrojó un total de 373 tweets entre positivos, negativos y neutros, en la distribución se tiene una clasificación de 132 positivos y 75 negativos los cuales fueron acertadamente catalogados, este algoritmo clasificó 29 tweet positivo siendo negativos, esta es una cifra pequeña con respecto al total de tweets. Al igual que Vader no clasifica ningún tweet negativo siendo positivo.

		VALORES REALES		
		Positivo	Negativo	Neutro
VALORES PREDICCIÓN	Positivo	132	29	0
	Negativo	0	75	27
	Neutro	0	0	110

Cuadro 7: Matriz Confusión Textblob.

Métricas. Por medio de los valores obtenidos en las matrices de confusión, se obtiene la exactitud, la precisión, la sensibilidad y la especificidad. A continuación, notaciones aplicadas para las fórmulas, sus respectivos valores según la categoría (positivo, negativo y neutro) y el modelo:

- VP: valores positivos
- FP: falsos positivos
- VN: verdaderos negativos
- FN: falsos negativos

Vader			
	Positivos	Negativos	Neutros
VP	132	94	75
FP	72	0	0
VN	169	207	298
FN	0	72	0

Cuadro 8: Valores por categoría de Vader.

Textblob			
	Positivos	Negativos	Neutros
VP	132	75	110
FP	29	27	0
VN	212	242	236
FN	0	29	27

Cuadro 9: Valores por categoría de Textblob.

Se definen las diferentes métricas a utilizar y su correspondiente formula:

Exactitud

La fórmula a utilizar es:

$$(VP + VN) / (VP + FP + FN + VN) \quad (2)$$

Precisión

Esta nos permite identificar qué tan cerca está el resultado de medir un valor verdadero.

La fórmula a utilizar es:

$$VP/(VP + FP) \quad (3)$$

Sensibilidad

La métrica de sensibilidad tiene como objetivo el análisis de los resultados verdaderos, es decir, la fracción de casos positivos correctamente clasificados, esta métrica es también conocida como la tasa de verdaderos positivos.

Para calcular esta fracción se aplica la formula:

$$VP/(VP + FN) \quad (4)$$

Especificidad

La métrica de especificidad tiene como objetivo el análisis de los resultados negativos, tomando los casos que fueron correctamente clasificados como negativos por cada modelo evaluado, llamado también la tasa de verdaderos negativos.

Para calcular esta fracción se aplica la formula:

$$VP/(VP + FP) \quad (5)$$

Una vez aplicadas las fórmulas de cada una de las métricas se obtienen los siguientes resultados: (ver cuadro 10)

		Exactitud	Precisión	Sensibilidad	Especificidad
Positivos	Vader	0.8070	0.6471	1.000	0.7012
	Textblob	0.9223	0.8199	1.000	0.8797
Negativos	Vader	0.8070	1.000	0.5663	1.000
	Textblob	0.8499	0.7353	0.7212	0.8996
Neutros	Vader	1.000	1.000	1.000	1.000
	Textblob	0.9276	1.000	0.8029	1.000

Cuadro 10: Resultados por métrica y categoría.

La exactitud de ambos modelos está por encima del 80 % para las diferentes categorías, para los valores positivos y negativos Textblob presenta una exactitud mayor a diferencia de los neutros donde Vader lo supera.

La precisión está dividida en las diferentes categorías, Textblob es mejor en la clasificación de los positivos mientras que Vader lo supera en los negativos, por otra parte, los neutros son correctamente clasificados en ambos casos.

Los dos modelos tanto Vader como Textblob arrojan un 100 % de sensibilidad, lo cual indica que los dos pueden determinar la polaridad positiva de un tweet dentro del conjunto de positivos.

En el caso de la sensibilidad Vader clasifica de mejor manera los valores negativos frente a Textblob.

¿Amor u odio en Twitter del BdB?

Para evidenciar los resultados de la clasificación de los modelos con el total de Tweets recolectados, se desarrolló un tablero en Power BI, el cual contiene dos páginas, las cuales se muestran a continuación. Una de ellas contiene una visual general y otra que tiene el detalle para hilar un poco más en dichos resultados.

(Ver tablero de resultados: Tablero de resultados)

En la primera página se encontrará el total de tweets recolectados, se podrá interactuar con las fechas de publicación y con los diferentes estados de sentimiento, además de diferenciar y comparar los modelos usados junto con los usuarios que generaron los tweets.

Los usuarios se dividieron en dos grupos, el primero de ellos está basado en los tweets que fueron realizados por la cuenta oficial del BdB donde algunos de estos son respuestas a interacciones de los usuarios o comunicaciones informativas. El segundo grupo denominado OTROS, contiene todos los tweets realizados por los usuarios con una cuenta activa en Twitter que desean interactuar con el BdB.





Figura 8. Página general.



- | | TEXTBLOB | VADER |
|-----------------|----------|--------|
| POSITIVO | 5.935 | 6.917 |
| NEUTRAL | 4.912 | 3.124 |
| NEGATIVO | 2.197 | 3.003 |
| | 13.044 | 13.044 |

La mayor cantidad de tweets son positivos, esta será la primera clasificación por abordar:

- En los tweets clasificados como positivos, se evidencian gran cantidad de comentarios agradables de respuesta por parte de la cuenta del BdB, como un criterio corporativo de respuesta a solicitudes o quejas interpuestas por parte de los usuarios. El cuadro 13 muestra la clasificación de los tweets positivos de acuerdo a Textblob y Vader, la cuenta de BdB genera la mayor cantidad de Tweets dentro de la clasificación como positivos.

	TEXTBLOB	VADER
OTROS	2.655	3.405
USR BDB	3.280	3.512
	5.935	6.917

Cuadro 12: Comentarios positivos.

- Los comentarios positivos dados por la cuenta del BdB en su mayoría son respuestas automáticas donde sobresale la palabra Mensaje, esto ocurre cuando se le solicita al usuario expresar su inconveniente de forma interna, para garantizar la privacidad de los datos y posteriormente intentar solucionar el tema.
- En la clasificación de comentarios positivos dentro de la categoría OTROS se puede observar mayor recurrencia en temas relacionados con productos del banco como Cuentas, Crédito, Tarjeta como se observa en la figura 10, lo que permite inferir que los tweets son generados por usuarios que tienen algún producto del portafolio del BdB y expresan la correspondiente satisfacción.



Figura 10. Nube de palabras positivas OTROS.

Para los tweets clasificados negativamente se puede observar:

- El cuadro 14 muestra la cantidad de comentarios clasificados como negativos, donde los usuarios denominados en la categoría OTROS representan la mayor cantidad. En este caso Vader cataloga más comentarios negativos con respecto a Textblob.

	TEXTBLOB	VADER
OTROS	1.681	2.301
USR_BDB	516	702
	2.197	3.003

Cuadro 13: Comentarios negativos.

- Analizando los tweets clasificados de manera negativa son en su mayoría realizados por usuarios que presentan inconformidades con el servicio o problemas con sus cuentas o sus tarjetas de crédito. Además, se encuentran adjetivos como Peor, Pésimo, que señalan la inconformidad o el "odio" hacia el BdB. Finalmente, se muestran 194 repeticiones de la palabra SFCsupervisor³, lo que indicaría que los usuarios hacen un llamado por medio de la cuenta de Twitter @SFCsupervisor a esta entidad de control para escalar los inconvenientes presentados con el BdB. Ver figura 11.



Figura 11. Nube de palabras negativas OTROS.

- Para el grupo de comentarios negativos generados por la cuenta del BdB en la nube de

³Superintendencia Financiera de Colombia. <https://www.superfinanciera.gov.co/jsp/index.jsf>

palabras de la figura 12, se observan palabras como Lamentamos, disculpas, ayudarte, con las cuales se pretende ofrecer disculpas por los problemas presentados con los servicios o productos de este.



Figura 12. Nube de palabras negativas BdB.

La visualización nos permite obtener otros resultados como:

- De los 6 meses de información descargada se observa que octubre es el mes en el que más tweets se obtuvieron hacia el BdB y a su vez el sentimiento positivo fue el más representativo (Ver figura 13). Sin embargo, al revisar con detalle los dos grupos de usuario, los tweets del grupo OTROS en su mayoría son clasificados como neutral (Ver figura 14).




Figura 13. Tweets por mes BdB.




Figura 14. Tweets por mes OTROS BdB.

- En el rango de tiempo analizado, el lunes es en el que más comentarios son realizados, esto puede deberse a que es el primer día de la semana y en el cual la gente retoma sus actividades.
- Por otro lado, el día en que menos se publican Tweets es el domingo, esto puede deberse a que este día es de descanso por lo que la gente puede llegar a pensar que el comentario posiblemente no será contestado.




Figura 15. Tweets por Día de la semana.

Discusión de los resultados

Se obtuvieron resultados interesantes basados en datos extraídos exclusivamente de Twitter para el BdB como foco de nuestro trabajo y poder así identificar comportamientos particulares.

Las cifras mostradas en la visualización a partir de la clasificación dada por los modelos nos indica que el sentir de los comentarios es mayormente positivo, donde Vader arroja una cifra superior comparándola con Textblob y analizando este resultado con respecto a la métrica de exactitud, se obtienen 75 % y 87 % respectivamente. Lo que indica que Vader tiene más falsos positivos, es decir comentarios positivos que pueden ser negativos o neutros. Para el grupo de negativos Vader genera una especificidad menor con respecto a Textblob con un 56 % y un 72 % respectivamente lo que indica que Textblob clasifica mejor los comentarios negativos.

Se pudo evidenciar que la cuenta del BdB genera respuesta a los diferentes comentarios dados por los usuarios y que dependiendo de la necesidad varía en el contenido del texto resultante. Estas repuestas incluyen en muchos casos disculpas por la situación presentada y les invita a comunicarse directamente para resolverla. Según esto, no queda evidencia en claro de la solución brindada a los diversos problemas.

Teniendo en cuenta lo anterior y el resultado de las métricas, se puede entender porque los comentarios positivos y neutrales son los más representativos en cuanto a cantidad se refiere, en parte por la cantidad de respuestas en contexto cordial, de comunicaciones, noticias o promociones que se realizan teniendo en cuenta el Twitter oficial del BdB. También vemos que la respuesta por parte del BdB es dada independiente del día de la semana, ya que de lunes a domingo hay interacciones. De acuerdo con esto, el lunes alcanza la mayor actividad debido a que es el día inicial de la semana y es cuando se retoman muchas de las actividades cotidianas.

Un punto importante que afecta en la polaridad dada a cada tweet es el rango establecido para clasificar cada sentimiento en positivo, neutral o negativo, el rango para neutral ($-0.05 < \text{Compound} < 0.05$) es mínimo en comparación al positivo y el negativo. Sin embargo, la cantidad de tweets clasificados como neutral es considerable a pesar del rango indicado, Textblob

representa un 37 % mientras que Vader representa un 23 % del total.

Conclusiones

- Como se observa en el cuadro 1 y de acuerdo con las premisas bajo las cuales señalan a Vader como un léxico de sentimientos bastante preciso, podemos señalar que en nuestro ejercicio no fue tan alto dicho puntaje y esto se debe principalmente a una razón: el idioma. Para nuestro análisis de sentimientos hicimos la traducción de español a inglés y así lograr aprovechar el léxico que maneja Vader, pero desafortunadamente evidenciamos que muchas de las palabras de la jerga colombiana no se traducen y las consecuencias se ven en el valor de sentimiento asignado a cada Tweet, cuando diversas palabras que en nuestro contexto significan ofensas o desconcierto, para la traducción no son reconocidas y el puntaje se ve afectado y en el resultando los valores son más alejados a los dados manualmente.

- En el caso de Textblob que está basado en técnicas de PLN para desempeñar el análisis de sentimientos, y el cual usamos para comparar con Vader, sucede lo mismo en cuanto a la traducción se refiere y a las diferentes palabras propias del léxico colombiano, la polaridad arrojada por este se acerca un poco más a la clasificación manual que se realizó por los autores del presente trabajo, lo que hace de este un mejor modelo teniendo en cuenta la premisa ya mencionada de la traducción.

- Los niveles de servicio ofrecidos por el BdB son un tema fundamental que debe ser tratado y mejorado para que la satisfacción y el sentimiento hacia este sea más favorable y el reconocimiento sea realmente positivo.

- La recolección de tweets evidencia que las respuestas dadas por la cuenta del BdB representan una cantidad considerable del total, sobre todo en los comentarios positivos, por lo que dicha división es fundamental para conocer las opiniones de los usuarios.

- Dentro de los comentarios positivos se pueden encontrar los nombres de otros bancos, las posibles razones de esto recaen que dentro de la oración no hay palabras que gramaticalmente denoten negatividad, por ejemplo “Bancolombia es mejor que el BdB”. Sin embargo, el contexto de esta oración indica algún tipo de inconformidad hacia el BdB.

- Otro ejemplo bajo esta casuística son los tweets donde se nombran de manera informativa los diferentes bancos o se hace algún tipo de promoción, tal como: “disfruta nuestra clase de cocina que preparamos junto Banco Davivienda.”
- En respuesta a la pregunta ¿Amor u odio en Twitter del BdB? De acuerdo con el trabajo realizado y con los resultados obtenidos se concluye que hay más amor que odio hacia el BdB, sin embargo, al tener en cuenta los puntos desarrollados se podrían generar cambios que demuestren el verdadero sentimiento hacia el BdB.

Lista de referencias

- Abbate, J. (1999). *Inventing the Internet* (1a ed.). The MIT Press.
- Amarouche, K., Benbrahim, H., & Kassou, I. (2015). Product opinion mining for competitive intelligence. *Proceedings of the Computer Science*, 73, 358–365
- Akkaya, C., Wiebe, J., & Mihalcea, R. (2009). Subjectivity word sense disambiguation. In *Proc. EMNLP-09*.
- Amador, C. J. B. (2020). Análisis de sentimientos en el sector bancario usando Twitter API y AWS. <https://www.linkedin.com/pulse/an%C3%A1lisis-de-sentimientos-en-el-sector-bancario-usando-barros-amador/>
- Arias, E. (2020). Desarrollo de un modelo predictivo con inteligencia artificial para establecer clasificación ASA a pacientes en una consulta preanestésica. http://bibliotecadigital.udea.edu.co/bitstream/10495/15251/1/AriasErika_2020_DesarrolloModeloPredictivo.pdf
- Bahrepour, M. (2018). luminis.eu. Obtenido de <https://sharing.luminis.eu/blog/theforgotten-step-in-crisp-dm-and-asum-dm-methodologies/>
- Barnes, J. (1954). Class and committees in a Norwegian Island Parish. *Human Relations*, 7(1), 39–58. <https://doi.org/DOI:10.1177/001872675400700102>
- BBC News Mundo. (2019). Six Degrees: cómo fue y quién creó la primera red social de internet, inspirada por la teoría de los «seis grados». <https://www.bbc.com/mundo/noticias-48558989>
- Bennett, S. (2013). A Brief History Of Social Media (1969–2012) [INFOGRAPHIC]. *Adweek*. <https://www.adweek.com/performance-marketing/social-media-1969-2012/>
- Bogotá, B. (2016). Tuit BdB. <https://www.bancodebogota.com/wps/portal/banco-de-bogota/bogota/nuestra-organizacion/sala-de-prensa/2016/tuit-bdb/>
- Boyd D. M. & Ellison N.B. (2007). «Social network sites: Definition, history, and scholarship». *Journal of Computer-Mediated Communication*, 13 (1), article 11. Consultado el 4

de diciembre de 2008

Bradley, M. M., & Lang, P. J. (1999). Affective norms for English words (ANEW): Instruction manual and affective ratings.

Cambria, E., Havasi, C., & Hussain, A. (2012). SenticNet 2. In Proc. AAAI IFAI RSC-12. Núñez Valdés, J., Alfonso Pérez, M., Bueno Guillén, S., Diánez del Valle, M.d.R. y Elías Olivenza, M.d.C.d. (2004). Siete puentes, un camino: Königsberg. Suma: revista sobre la enseñanza y aprendizaje de las matemáticas, 45, 69-78.

CAOBA - Universidad de Los Andes. (2017). Perfil Alianza Caoba. Bogotá: Universidad de Los Andes

Ceruzzi, P. (2003). A History of Modern Computing (2nd ed). MIT press.

Cerveira, Frederico & Kocsis, Imre & Barbosa, Raul & Madeira, Henrique & Pataricza, András. (2018). Exploratory Data Analysis of Fault Injection Campaigns. 191-202. 10.1109/QRS.2018.00033.

Esuli, A., & Sebastiani, F. (2005). Determining the semantic orientation of terms through gloss classification. In Proc. ICIKM-05.

Flores Cueto, J. J., Morán Corzo, J. J., & Rodríguez Vila, J. J. (2009). Las redes sociales. Universidad de San Martín de Porres, 3, 1-15.

Gelbukh, A. (2010). Procesamiento de Lenguaje Natural y sus Aplicaciones. Komputer Sapiens, 6–11.

Hutto, C. J., & Gilbert, E. (2014). Vader: A parsimonious rule-based model for sentiment analysis of social media text. In E. Adar & P. Resnick (Eds.), Proceedings of the eighth international AAAI conference on weblogs and social media (pp. 216–225). Palo Alto: AAAI Press Jurafsky D. & Manning C. . Natural Language Processing Course. Stanford University, 2012.

Lasar, M. (2011). Who invented the personal computer? (hint: not IBM). Recuperado de <https://arstechnica.com/tech-policy/2011/06/did-ibm-invent-the-personal-computer-answer-no/>

Liu, B. (2010). Sentiment Analysis and Subjectivity. In N. Indurkha and F. J.

Liu, B. (2012). Sentiment analysis and opinion mining. Morgan & Claypool Publishers. Chicago, United States.

Mäntylä, M. V., Graziotin, D., & Kuutila, M. (2018). The evolution of sentiment analysis—A review of research topics, venues, and top cited papers. *Computer Science Review*, 27, 16–32. <https://doi.org/10.1016/j.cosrev.2017.10.002>

Moreno, G. (2019). Twitter dejará de publicar sus usuarios. Statista. <https://es.statista.com/grafico/17792/usuarios-activos-mensuales-de-twitter/>

Pauli, P.A. (2019). Análisis de sentimiento Comparación de algoritmos predictivos y métodos utilizando un lexicon español. Instituto Tecnológico de Buenos Aires – itba escuela de ingeniería informática. (pp. 8).

PostgreSQL: About. (1996). The PostgreSQL Global Development Group. Recuperado 5 de septiembre de 2021, de <https://www.postgresql.org/about/>

Public opinion quarterly. [Online]. Available: <http://poq.oxfordjournals.org>. (Accessed 2 December 2016)

Sánchez Balmaseda, María Isabel (2002) Análisis de redes sociales e historia: Una metodología para el estudio de redes clientelares. [Tesis] Santos, F. (1989). El concepto de red social. *Reis*, (48), 137-152. doi:10.2307/40183465

Shah, P. (2020). Sentiment Analysis using TextBlob - Towards Data Science. Medium. <https://towardsdatascience.com/my-absolute-go-to-for-sentiment-analysis-textblob-3ac3a11d524>

TextBlobreco Simplified Text Processing — TextBlob 0.16.0 documentation. (2020). TextBlob. Recuperado 2020, de <https://textblob.readthedocs.io/en/dev/>

Tumasjan, A., Sprenger, T. O., Sandner, P. G., & Welpe, I. M. (2010). Predicting Elections with Twitter:. In Proc. ICWSM-10.

Tweet Binder: herramienta de análisis de hashtags. (2021, March 9). Tweet Binder. <https://>

www.tweetbinder.com/es/

Weaver, W. (1955). Translations. In W. N. Locke & A. D. Booth (Eds.), *Machine translations of Languages: Fourteen essays* (1st ed., p. 243). John Wiley & Sons